

많이 줄수록 여럿일수록 정말 더 잘할까

에이전트 논문 10편 읽기 — alphaXiv 2026년 8월

-
- A. 무엇을, 얼마나 줄 것인가 — 하네스 · 상태 · 작업공간
 - B. 얼마나 쪼갤 것인가 — 경계의 거버넌스 · 조율 비용
 - C. 무엇을 기억할 것인가 — 기억의 형태와 정책
 - D. 어떻게 썰 것인가 — 프롬프트의 값 · 과정 지표 · 명세

차례

들어가며 — 많이 줄수록, 여럿일수록 정말 더 잘할까	3
제1장 · 도구를 다 쥐여주면 에이전트가 더 잘할까	5
제2장 · 새 대화창을 열면 왜 일이 처음으로 돌아갈까	11
제3장 · 내가 읽은 파일과 내가 고친 파일은 같은 버전인가	17
제4장 · 일은 끝났는데 지켜야 할 걸 안 지켰다	23
제5장 · 여덟 명이 붙으면 여덟 배로 빨라질까	29
제6장 · 많이 찾아다 주면 에이전트가 더 잘 판단할까	35
제7장 · “왜 그렇게 정했더라”를 어디에 남길 것인가	41
제8장 · 내가 넣은 한 줄은 대체 얼마짜리인가	47
제9장 · 잘 나온 결과 하나로 실력을 판단해도 될까	53
제10장 · 만들기 전에 “약속”을 먼저 쓰게 했더니	58
맺음말 — 숫자는 직관의 어디를 고쳤나	64

들어가며 — 많이 줄수록, 여럿일수록 정말 더 잘할까

2026년 8월, alphaXiv 피드에 올라온 논문 153편 중에서 10편을 골랐습니다. 뽑은 기준은 하나였습니다. **에이전트에 무언가를 더해 줬을 때 실제로 무슨 일이 일어나는지 숫자로 켜 논문이었다는 것.**

도구를 더 주면? 대화창을 새로 열면? 에이전트를 여러 개로 쪼개면? 기억을 더 찾아다 주면? 결과 점수 하나만 보면? — 이 다섯 질문에 업계는 오랫동안 직관으로 답해 왔습니다. “당연히 더 주는 게 낫지”, “쪼개면 역할 분담이 되니까 낫지”, “기억은 많을수록 좋지”. 이 책의 결론을 미리 말하면, 그 직관들은 2026년 8월의 측정 앞에서 대체로 무너졌습니다. **더 줄수록 좋다는 가정은 공짜가 아니었습니다. 늘어난 만큼 어딘가에서 비용이 생겼고, 이 논문들은 그 새는 지점을 처음으로 계량했습니다.**

사람 조직에서 이미 알던 일입니다. 개발자를 두 명 더 뽑으면 회의가 늘어나고, 인수인계에서 정보가 새고, 누가 알아서 헛갈리기 시작합니다. 브록스의 「맨먼스 미신」이 1975년에 말한 것과 같은 구조가 AI 에이전트에서 다시 나타나고 있습니다. 다만 하나 다릅니다. 사람 조직에서는 “커뮤니케이션 비용이 늘었다”고 정성적으로만 말할 수 있었지만, 에이전트에서는 토큰 수, 메시지 건수, 사실이 증발한 비율, 재현에 든 비용의 배수로 **숫자 그대로** 잡힙니다. 이 책은 그 숫자들을 모아 읽는 책입니다.

네 가지 질문, 열 장

10편을 따로 읽으면 흩어집니다. 네 가지 질문으로 묶으면 서로가 서로의 답이 됩니다.

A. 무엇을, 얼마나 줄 것인가 — 1장 하네스 프로비저닝, 2장 AstronOS, 3장 StagedWorkspace. 에이전트를 감싸는 환경(하네스)에 도구·정보·상태를 얼마나 제공할 것인가. 세 편의 공통 결론은 “넉넉하게 주는 것은 공짜가 아니다”입니다. 안 쓰는 도구 설명도 입력에 들어가 값을 치르고(1장), 넘길 상태를 잘못 고르면 일이 처음부터 다시 굴러가며(2장), 뷰와 원본의 버전이 어긋나면 에이전트는 없는 사실을 근거로 판단합니다(3장).

B. 얼마나 쪼갤 것인가 — 4장 경계에서의 거버넌스, 5장 에이전트들의 조율. 컴포넌트로 쪼개면 32B급 모델에서는 규정상 중요한 사실의 85%가 넘겨주는 경계에서 증발하고(4장), 팀이 커지면 통신비가 초기에 거의 제공으로 늘다가 브로드캐스트로 우회합니다(5장). 쪼개는 것은 이득이 아니라 거래입니다. 한쪽에서는 규정이, 다른 쪽에서는 토큰이 셉니다.

C. 무엇을 기억할 것인가 — 6장 메모리 저장 기반 평가, 7장 온톨로지 프로젝트 메모리. 기억을 많이 찾아 넣어 주는 것이 판단에 도움이 되는 종류의 일(사실 조회)과 오히려 해가 되는 종류의 일(순차적 의사결정)이 갈립니다(6장). 그리고 무엇을 기억하느냐만큼 중요한 것이 **무엇이 무엇을 대체했는가**를 기억하는 방식입니다 — 폐기된 결정까지 붙들어야 “왜 지금 코드가 이 모양인가”가 보입니다(7장).

D. 어떻게 썰 것인가 — 8장 프롬프트의 가치, 9장 최종 점수를 넘어, 10장 명세 주도 테스트. 결과 점수만 보면 비용이 안 보입니다. 프롬프트 한 줄의 값어치를 비트로 재는 방법(8장), 최종 점수 뒤의 과정 병목을 가르는 지표(9장), “약속”을 먼저 쓰게 하는 사실상 공짜인 개입(10장)이 여기 들어 있습니다.

왼쪽 두 묶음(A, B)은 만들기 전에 정하는 설계 결정, 오른쪽 두 묶음(C, D)은 만든 뒤에 관리하는 운영 결정입니다. 설계에서 내린 결정이 운영의 비용을 만듭니다. 이 화살표를 옆두에 두고 읽으면 10편이 하나의 이야기가 됩니다.

이 책을 읽는 방법

각 장은 같은 뼈대를 씁니다. **한 줄 요약 → 무엇이 문제였나 → 어떻게 답했나 → 무엇이 밝혀졌나 → 나의 해석 → 한계와 남는 의문 → 실무에 가져갈 것 → 다른 장과 이어지는 지점.** 앞의 네 절은 논문이 하는 말이고, 뒤의 네 절은 이 책이 하는 말입니다. 시간이 없으면 각 장의 “실무에 가져갈 것” 절만 훑고 걸리는 장으로 돌아오세요.

읽는 순서는 목적에 따라 고르면 됩니다.

- **짧은 길 (30분):** 10장 → 4장 → 5장. 오늘 당장 바꿀 수 있는 가장 싼 습관(10장)과, “쪼개면 무슨 일이 생기느냐”를 실측한 한 쌍(4·5장).
- **설계자의 길 (2시간):** 1장 → 4장 → 5장 → 2장 → 3장. 무엇을 줄 것인가에서 시작해 상태와 산출물을 붙드는 법까지.
- **측정하는 사람의 길 (2시간):** 8장 → 9장 → 6장 → 7장. 감으로 판단하던 것을 숫자로 바꾸는 경로.

읽을 때 조심할 세 가지

첫째, **대부분 단일 도메인·단일 벤치마크 실험입니다.** 4장은 금융 규제, 5장은 코딩 과제, 1장은 인프라 운영 두 곳 뿐이고 — 심지어 1장은 두 도메인의 결론이 서로 반대였습니다. 남의 벤치마크 결론을 내 환경에 그대로 옮기지 마세요. 방향만 빌리고, 내 환경에서 다시 재는 것이 맞습니다.

둘째, **자기 방법을 유리하게 시험했을 여지가** 논문마다 있습니다. 특히 7장은 비교 대상 질문 유형 자체가 유사도 검색이 원래 약한 종류로 골라져 있고 저자가 단독이며 질의 엔진이 자체 기술입니다. 8장은 실험 규모가 작습니다. 각 장의 “한계와 남는 의문” 절은 장식이 아니라 본문입니다.

셋째, 이 책의 해석은 각 논문의 **초록·공개 개요·전문**을 근거로 했지만, 인용해 전달할 일이 생기면 원문을 한 번 확인하세요. 각 장 머리에 arXiv와 alphaXiv 링크가 있습니다.

읽고 나서 딱 하나만 바꾼다면 10장의 습관 — 만들기 전에 조건(사전조건, 사후조건, 미정의 동작)부터 쓰는 것 — 을 권합니다. 비용이 거의 없고, 효과가 실제 코드베이스에서 측정된 유일한 항목이기 때문입니다.

그럼 1장에서 만납시다.

제1장 · 도구를 다 쥐여주면 에이전트가 더 잘할까

“원문: Task-Aware Harness Provisioning for LLM Agents in Mission-Critical Infrastructure Operations — arXiv:2608.17433 · Liangtao Lin, Qingang Zhang, Zhaomeng Zhu, Tianwei Zhang, Yonggang Wen · Nanyang Technological University” “링크: <https://www.alphaxiv.org/abs/2608.17433> · <https://arxiv.org/abs/2608.17433>”

한 줄 요약

에이전트에게 도구를 다 쥐여주는 것은 친절이 아니라 비용이다 — 그리고 어느 쪽이 이득인지는 도메인마다 다르게 답이 나온다.

무엇이 문제였나

에이전트는 혼자서는 아무것도 하지 못합니다. 어떤 정보를 볼 수 있는지, 어떤 도구를 쓸 수 있는지, 어떤 행동까지 허용되는지 — 이 세 가지를 정하는 껍데기가 모델을 감싸고 있고, 논문은 이것 **하네스(harness)** 라고 부릅니다. 신입사원에게 비유하면 모델은 그 사람의 능력이고, 하네스는 책상에 놓아준 서류철과 시스템 계정과 결재 권한입니다.

문제는 이 하네스를 관행적으로 **한 벌로 고정**한다는 것입니다. 조회 도구, 제어 도구, 문서, 로그, 권한 — 어떤 일이 들어와도 같은 만능 세트를 물려줍니다. 설계자 입장에서 합리적인 선택입니다. 들어올 일을 미리 알 수 없으니 다 붙여두는 게 안전하고, “그 도구가 없어서 못 했다”는 실패보단 낫다고 느껴지니까요.

그런데 이 안전에는 값이 붙습니다. 안 쓰는 도구의 설명과 안 보는 문서까지 매번 모델의 입력으로 들어갑니다. 비용이 느는 것뿐 아니라, 선택지가 많을수록 엉뚱한 도구를 집을 확률도 같이 올라갑니다. 출장 수리 기사에게 모든 공구를 다 넣은 가방을 들려 보내는 것과 같습니다. 없어서 못 고치는 일은 없어지지만, 기사는 매번 그 무게를 지고 다니고 필요한 렌치 하나를 찾느라 가방을 뒤집습니다.

논문은 여기에 항목 하나를 더 넣습니다. 미션 크리티컬 인프라에서 과잉 제공은 지갑만의 문제가 아니라 **노출의 문제**라는 것 — 필요 없는 데이터를 에이전트에게 보여준다는 것 자체를 정보보호 관점의 비용으로 셉니다. 덜 주는 것이 아끼기만이 아니라 좁히기이기도 한 셈입니다.

기존의 개선 시도도 있었습니다. 관련 자원을 검색해 내어주는 방식, 미리 정한 규칙으로 권한을 주는 방식, 에이전트 스스로 필요한 자원을 고르게 하는 방식. 저자들의 정리는 이 모두가 “**유용할 것을 추론**”하지만 “**충분한 것을 측정**”하지는 않는다는 것입니다. 틀린 추론은 과잉과 과소 양쪽으로 흘러갑니다.

저자들은 여기서 질문의 축을 바꿉니다. “얼마나 줄까”가 아니라 “**이 일이 요구하는 것과 환경이 제공하는 것이 맞나**” — 즉 자원 매칭(resource-matching) 문제로 재정의합니다. 맞춤의 문제가 되면 답이 하나가 아니어도 자연스러워집니다. 일마다 답이 다른 것이 기본값이 되니까요.

어떻게 답했나

매칭 문제로 정의했으면 양쪽을 썰 자가 필요합니다. 저자들은 두 자를 준비했습니다.

작업 쪽 자 — 12개의 좌표. 인프라 운영 작업을 겉으로 보이는 업무 이름이 아니라, 그 밑에 깔린 물리 시스템의 수학적 표현으로 분류합니다. 부분 관측 시스템은 관측 신호 y , 잠재 상태 x , 시스템의 구조와 메커니즘 m (위상·다이내믹·제약·제어 로직)으로 쪼갤 수 있고, 모든 운영 과제는 결국 이 세 대상 중 하나를 물어보거나 건드리는 일입니다. 여기에 출력 모드(정보를 **보고**하는가, 개입을 **선택**하는가)와 시점(현재인가, 미래인가)의 두 축을 더하면 $2 \times 2 \times 3 = 12$ 개의 **정식 과제 좌표**가 나옵니다. “냉각 점검”과 “부하 계산”이 이름은 달라도 같은 좌표에 앉으면 한 칸에 묶입니다. 익숙한 이름들은 이 좌표의 특정한 점입니다 — 이상 감지는 〈보고, 현재, y 〉, 진단은 〈보고, 현재, m 〉, 예측은 〈보고, 미래, y 〉. 기존 라벨을 버린 이유는 이들이 도메인마다 정의가 흔들리고 과제 공간을 빈틈없이 덮지 못하기 때문입니다.

환경 쪽 자 — 다섯 단계 사다리. 하네스 구성을 제공하는 정보의 양과 유형으로 줄 세웁니다. 핵심은 사다리가 **누적적**이라는 것 — 위의 등급은 아래 등급의 모든 것을 포함합니다.

등급	이름	이 등급에서 더해지는 것
K1	모델 단독 추론	없음. 과제 문구와 모델의 매개지식뿐
K2	정적 지식	매뉴얼, SOP, 사양서, 설계문서, 규칙 기반
K3	시계열 관측	텔레메트리, 로그, 알람, 시계열 예측
K4	구조와 물리	위상, 구성 요소 관계, 지배 방정식, 물리 제약, 제어 로직
K5	순방향 시뮬레이션	실행 가능한 시뮬레이션, 디지털트윈 롤아웃, 반사실 평가, 가정 미래에 대한 최적화

논문이 거듭 강조하길, K5는 **최대 제공**이지 **성능 최적**이 아닙니다 — 제공이 늘면 쓸데없는 증거·비용·행동 기회도 같이 늘기 때문입니다.

양쪽에 자가 생기면 “이 칸의 작업에는 이 등급의 환경”이라는 대응표(task-to-harness 매핑)를 그릴 수 있습니다. 대응 규칙은 소박합니다 — 그 칸의 최고 점수에서 0.05 이내를 내는 **가장 낮은** 등급을 고른다. 비슷하면 싼 쪽을 택하는 것입니다.

이 대응표를 두 소스로 만든 것이 이 논문의 독특한 지점입니다. 하나는 **연구 문헌 마이닝** — arXiv·Semantic Scholar·OpenAlex에서 최근 10년(2016–2026) 인프라 운영 연구 후보 약 2,000편을 굶어 1,220편에 과제 좌표와 하네스 등급 주석을 단 것입니다. 섹터 어휘만으로 검색해 분포가 질의가 아니라 논문에서 나오게 했고, 모델 주석자 셋의 다수결로 라벨을 확정했습니다. 다른 하나는 **통제된 에이전트 실행 측정** — 데이터센터 액체 냉각(10랙 데이터홀, 130노드 유체망, 약 910열 텔레메트리의 열·수력 디지털트윈)과 전력망(IEEE-14, 142열 텔레메트리) 시뮬레이션에서 12좌표 $\times$ 10과제 $\times$ 2도메인 = **240개의 검증된 과제**를 만들고, 실행자·프로토콜·채점을 모두 고정한 채 K1부터 K5까지 하네스만 바꿔가며 돌린 것입니다. 과제마다 결정론적 오라클이 정답을 만들고 프로그램 검증과 사람 검증을 둘 다 통과시켰습니다. 문헌만 쓰면 남의 세팅에 갇히고 실측만 쓰면 표본이 좁습니다. 둘을 겹칩니다.

이 대응표 위에서 제안하는 알고리즘이 **맵 가이드 확장(map-guided escalation)**입니다. 동작은 놀랄 만큼 단순합니다. 실행 지도가 가리키는 태스크 특화 하네스로 시작하고, 자체 점검(self-check)이 실패한 뒤에야 완전 제공으로 확장합니다. 그게 전부입니다.

눈여겨볼 단어는 “뒤에야”입니다. 확장이 기본값이 아니라 예외이고, 확장 여부를 사람이 아니라 실행 중의 자체 점검 결과가 결정합니다. 기존 시스템은 모든 태스크가 처음부터 완전 제공으로 직행합니다. 이 알고리즘은 완전 제공을 없애지 않고 안전망으로 남겨두되, 거기 가는 빈도를 줄입니다. 미션 크리티컬 영역에서 중요한 구분입니다 — 실패했을 때 돌아갈 곳이 없는 최적화는 이 바닥에서 채택되지 않습니다. 설계 디테일 두 개가 더 있습니다. 확장은 한 칸씩 기어오르지 않고 K5로 곧장 점프하고(중간 단계에서 멈추는 경우가 드물다는 것을 부록 실험으로 확인), 재시도에 가져가는 것은 첫 시도의 텍스트 결론만입니다 — 도구 출력·캐시는 경계를 넘지 못해 실패 흔적이 재시도를 오염시키지 않습니다.

무엇이 밝혀졌나

평가는 두 도메인에서 이뤄졌습니다. 데이터센터 액체 냉각과 전력망. 그리고 두 도메인의 답이 같았습니다 — 이게 이 논문에서 가장 정직하고 가장 쓸모 있는 부분입니다.

먼저 전체 스왑의 풍경부터. 같은 실행자(GPT-5.4 고정, 도구 호출 최대 20회, 300초 제한)를 K1부터 K5까지 돌린 결과, 과제 클래스별로 “충분한 최저 등급”은 액체 냉각에서 K2-K5, 전력망에서 K3-K5까지 제각각이었습니다. 성능은 단조롭지 않아서, 액체 냉각 12개 클래스 중 5개, 전력망 중 4개가 K5 미만에서 최고점을 냈습니다. 가장 극적인 사례 — 잠재 상태를 묻는 현재 관측 과제(액체 냉각)는 K3에서 0.59를 내다가 K5에서 0.46으로 떨어집니다. 시뮬레이션이 생기자 에이전트가 추세를 읽어야 할 자리에서 반사실 실험을 돌리기 시작한 것입니다. 뜻밖의 수치 하나. 액체 냉각 전체 평균에서 K2(0.216)가 K1(0.253)보다 **낮습니다**. 매뉴얼 묶음만 엮는 것은 중립이 아니라 해가 될 수 있다는, 문서 과잉에 대한 가장 직접적인 경고입니다.

문헌 쪽 지도도 같은 방향을 가리킵니다. 1,220편의 분포에서 평균 등급은 보고→개입으로 +0.45, 현재→미래로 +0.39 올라가고, 대상별로는 관측 신호 3.53 < 메커니즘 3.65 < 잠재 상태 4.06 순으로 깊어집니다. 전체의 53%가 K3에, 28%가 K5에 몰려 있고 K4는 13%에 불과합니다 — 현장 관행은 “계측으로 충분하거나, 아니면 시뮬레이션까지 가거나”의 이분법이라는 읽기가 가능합니다.

이제 정책 비교입니다. 테스트 분할(클래스당 5과제·3회 반복)에서 아홉 정책과 배치 불가능한 참고선 둘을 나란히 놓습니다. 토큰은 완전 제공 대비 배수입니다.

정책	선택 방식	액체 냉각 정확도	토큰	전력망 정확도	토큰
완전 제공 Full-K5	항상 최대	0.652	1.00배	0.806	1.00배
ITR	의미 기반 자원 검색	0.670	0.99배	0.780	1.02배
LLM 라우팅	모델이 등급 판단	0.626	0.93배	0.744	1.03배
LLM+경험칙	판단에 플레이북 첨부	0.655	0.96배	0.766	1.09배
AutoMix	학습된 계단식 캐스케이드	0.639	1.94배	0.785	2.61배
Blind-ESC	K1에서 무조건 등반	0.664	1.33배	0.742	1.75배
문헌 지도 조회	문헌 최빈 등급	0.658	0.89배	0.664	1.01배
실행 지도 조회	실측 최저 충분 등급	0.670	0.86배	0.762	0.88배
맵 가이드 확장	실행 지도 + 자체 점검	0.715	1.15배	0.782	1.03배
(참고) 클래스 오라클	클래스별 최적, 비배치	0.694	—	0.809	—
(참고) 태스크 오라클	건별 최적, 비배치	0.783	—	0.843	—

읽을 거리가 많습니다. 의미 기반 검색(ITR)은 정확도가 나쁘지 않으면서 토큰을 거의 못 아깁니다 — 관련성은 “유용할 것”을 찾지 “충분한 만큼”을 찾지 못한다는 뜻입니다. 학습된 캐스케이드(AutoMix)는 전력망에서 토큰 2.61배, K1부터 기어오르는 Blind-ESC는 지연이 5.33배까지 갑니다. 측정된 표 하나를 찾아보는 것은 공짜인데, “ 스스로 판단하기”와 “배우기”는 비쌉니다. 그리고 문헌 지도와 실행 지도는 액체 냉각에서 비슷하지만(0.658 대 0.670) 전력망에서 갈라집니다(0.664 대 0.762) — 문헌은 사전 지식이 되어주지만 그 도메인·그 실행자에 맞추는 건 결국 실측입니다.

액체 냉각에서는 도구와 정보를 덜 줬는데 정확도가 0.063 올라갔습니다. 통계를 정직하게 읽으면 — 실행 지도 조회의 완전 제공 대비 이득(+0.018)은 신뢰구간이 0을 포함해 “통계적으로 구분 안 되는 정확도, 14% 적은 토큰”이 조회의 정당한 자기소개입니다. 반면 맵 가이드 확장은 0.652에서 0.715로, **정적 천장인 클래스 오라클(0.694)조차 넘어섭니다**. 시작점을 재어 맞추고 예외만 확장하는 구조가 클래스 단위 최적을 미리 고르는 것보다 나은 결과를 낸 것입니다. 확장이 실제로 발동한 비율은 액체 냉각 11.7%, 전력망 13.9%(평균 시도 1.12/1.14회) — 자체 점검은 라우터가 아니라 보험 증서입니다. 비용 쪽도 같이 봐야 합니다. 같은 도메인에서 반성 기반 방법인 Reflexion과

비슷한 정확도(0.715 대 0.711)를 **토큰 48% 적게** 쓰고 달성했고, 경험 검색 방법인 ExpeL은 정확도를 0.016 더 올리지만 토큰이 44% 더 듭니다. Reflexion은 실패한 시도를 스스로 되돌아보고 재시도하게 만드는 널리 쓰이는 방법인데, 반성과 재시도는 효과가 있는 대신 시도 횟수만큼 토큰을 먹습니다. 처음부터 맞는 구성으로 시작하면 되돌아볼 일 자체가 줄어든다는 것이 여기서 확인된 셈입니다.

전력망에서는 결과가 뒤집힙니다. 완전 제공이 여전히 정확도 최적이었고(0.806, 조회보다 통계적으로 유의하게 높습니다), 맵 기반 프로비저닝이 준 것은 “정확도를 조금 내주고 비용을 아끼는” 선택지였습니다. 공짜 점심이 아니라 대안입니다.

항목	액체 냉각(데이터센터)	전력망(IEEE-14)
정확도 1위	맵 가이드 확장 0.715	완전 제공 0.806
완전 제공 대비	+0.063, 토큰 1.15배	맵 계열은 모두 하회
값싼 대안	실행 지도 조회 0.670, 토큰 0.86배	실행 지도 조회 0.762, 토큰 0.88배
K5의 몸값	토큰 최다, 지연 50.2초로 최고	토큰이 K3·K4보다 적고 7.7초
파레토 모양	왼쪽에서 이미 꺾임 — 적게 줘도 충분	끝까지 우상향 — 줄수록 좋음
물리적 이유	분 단위 열역학, 과거 추세로 좁게 추론 가능	준정태 시스템, 전력조류가 곧 완전한 시뮬레이션

마지막 줄은 논문의 설명을 제가 압축한 것입니다 — 전력망은 준정태라 K5가 토큰도 지연도 싸게 먹히고, 액체 냉각은 실제 동역학이 있어 K5 롤아웃이 비쌉니다. 두 파레토가 갈리는 물리적 뿌리가 여기 있습니다.

한 가지 더 — GPT-5.4로 켜 실행 지도를 재보정 없이 Qwen3.5-72B에 옮기자 액체 냉각에서 완전 제공(0.706)보다 나아졌고(0.726), 전력망에서는 근접했습니다(0.797 대 0.808). Qwen 한 번의 실행으로 새로 켜 지도는 두 도메인 모두에서 오히려 훨씬 나빴습니다(0.626, 0.762). 지도는 실행자를 가로질러 옮겨 가지만, 지도 자체는 강한 실행자의 반복 측정에서 나온다는 것 — 측정의 품질이 측정 대상만큼 중요하다는 결과입니다.

저자들의 결론은 이렇습니다. 하네스 프로비저닝에는 **보편 최적점이 없고, 도메인에 따라 모양이 달라지는 정확도-비용 파레토 프론티어를 따른다**. 어떤 도메인의 곡선은 왼쪽에서 이미 꺾여 “적게 줘도 충분”하고, 어떤 도메인의 곡선은 끝까지 올라가 “줄수록 좋다”입니다.

나의 해석

이 절부터는 논문의 숫자 위에 얹은 제 읽기입니다 — 논문의 말과 제 해석을 구분해서 읽어주세요.

이 논문에서 제가 가장 무겁게 듣는 부분은 숫자가 아니라 **두 도메인의 결과가 정반대라는 사실 자체**입니다. 연구 하나가 “덜 주는 게 낫다”고 말했다면 그건 또 하나의 유행이 됐을 겁니다. 그런데 이 논문은 같은 알고리즘을 두 현장에 적용해 한쪽에서는 이기고 다른 쪽에서는 지는 것을 그대로 보여줬습니다. 이 정직함이 실무자에게 주는 것이 큼니다.

왜 갈리는지 논문은 단정하지 않지만, 제 읽기는 이렇습니다. 두 도메인의 차이는 결국 **“정보가 많을수록 유리한 일인가, 선택이 적을수록 유리한 일인가”**의 차이입니다. 액체 냉각 진단은 제한된 센서와 문서 안에서 좁게 추론하는 일이라 선택지를 줄이는 것이 오류를 줄입니다. 반면 전력망 운영은 넓은 상태를 동시에 보아야 하는 일이라 시야를 좁히는 것이 곧 실수입니다. 하네스는 결국 **시야의 폭** 이고, 필요한 시야의 폭은 일이 정하는 것입니다. 여기에 논문의 부록 디테일을 하나 없으면 — 시야의 **값**까지 물리가 정합니다. 같은 K5라도 전력망에서는 싸고 액체 냉각에서는 비쌉니다.

두 번째 읽기는 **확장의 방향성**에 관한 것입니다. 요즘 에이전트 담론은 “도구를 더 붙이고, MCP로 더 연결하고, 컨텍스트에 더 넣는” 방향으로 흐릅니다. 이 논문은 그 방향이 최적이 아닐 수 있다는 것을 도메인 하나에서 보여줬고, 동시에 그 반대 방향(“다 걷어내라”)도 정답이 아님을 다른 도메인에서 보여줬습니다. 남는 것은 방향이 아니라 **측**

정하는 습관입니다. 남의 곡선을 믿지 말고 내 곡선을 그리는 것. 그리고 그 습관의 진입 장벽은 생각보다 낮습니다 — 측정된 조회료가 LLM 라우팅보다 정확하고 학습된 캐스케이드보다 쌉니다. 측정은 화려할 필요가 없습니다. 표이면 충분합니다.

세 번째 — 자체 점검이라는 장치의 위치가 마음에 듭니다. “조금 시작하라”는 조언은 흔하지만, 대개는 “사람이 판단해서 넓혀라”에서 끝납니다. 여기서는 **실행 중인 에이전트 자신의 실패 판정**이 확장을 촉발합니다. 사람의 개입 없이 도구가 스스로 “지금 가진 걸로는 못 하겠다”를 말할 수 있어야 이 구조는 스케일합니다. 이번 전문 확인으로 이 장치의 실제 크기도 알게 되었습니다 — 확장은 8건 중 1건꼴로만 발동합니다. 자체 점검은 매 순간 재분배하는 라우터가 아니라, 이미 맞춰진 시작점 위에 얹는 꼬리보험입니다. 물론 이것이 이 방법의 급소이기도 합니다(아래 한계 절에서 다룹니다).

넷째, 짧지만 빠가 있는 수치 하나. 액체 냉각 전체 평균에서 K2가 K1보다 낮다는 것 — 문서 더미는 중성적인 추가 물이 아니라 개입이라는 뜻입니다. “일단 문서를 다 넣어”가 얼마나 흔한 기본값인지 생각하면, 이 수치는 그 관행에 대한 가장 값싼 반박입니다.

한계와 남는 의문

도메인이 둘뿐이고, 그 둘의 답이 반대다. 표본 두 개로 “도메인마다 다르다”를 말하면 정확히 두 가지 사례가 있다는 것 이상은 말할 수 없습니다. 세 번째 도메인이 어느 쪽에 붙을지는 이 논문으로 알 수 없습니다. 실행자 방향의 일반성은 확인됐지만(GPT-5.4 지도가 Qwen3.5-72B에서 효과 유지) 도메인 방향은 열려 있습니다. 또한 평가 전체가 시뮬레이션 위입니다. 논문 스스로 남기는 한계 — 센서 불확실성, 분포 이동, 조직의 절차와 인간 승인 같은 실전 조건이 담기지 않았습니

자체 점검의 오류는 측정됐지만, 위험한 쪽이 우세하다. 확장을 촉발하는 실패 감지(거짓 경보)보다 실패를 놓치는 오탐(거짓 통과)이 지배적이라는 것이 논문의 정성 분석 결론이고, K1부터 기어오는 Blind-ESC가 제자리에 머무는 이유이기도 합니다 — 자신만만하게 틀린 답은 재시도를 발동시키지 않으니까요. 미션 크리티컬에서 위험한 방향은 정확히 이쪽입니다. 못 하는데 못 하는 줄 모르면 좁은 구성으로 잘못된 답을 확신 있게 내놓습니다. 거짓 통과

“덜 주는 게 낫다”가 성립하는 메커니즘은 정성적으로만 있다. 오류 분석은 두 가지 양상을 이름 붙입니다 — 시뮬레이션이 생기면 추세를 읽어야 할 자리에서 반사실 실험을 돌리는 과잉 제공의 역효과, 민감도 스위치가 도구 호출 예산을 태우는 낭비. 다만 각 양상이 성능 하락의 몇 퍼센트를 차지하는지 정량 분해는 없습니다. 인용할 때 “논문이 관찰한 양상”과 “논문이 분해한 인과”는 구분해야 합니다.

문헌 지도는 관행의 기록이지 검증된 충분성이 아니다. 논문 스스로 출판 편향과 주석 편향을 인정합니다. 희소한 좌표의 문제도 구체적입니다 — 개입·현재·잠재 상태 좌표에는 표본이 5편뿐이고, 개입·미래·잠재 상태 좌표는 11편 전부

지도는 켜 조건에 묶여 있다. 실행 지도는 켜 실행자·하네스 구현·프로토콜·허용 오차(0.05)의 함수입니다. 허용 오차에 대해서는 0.05–0.15 구간에서 결론이 흔들리지 않는다는 민감도 분석이 있지만, 도구를 통째로 바꾸면 재보정이 필요할 수 있습니다. 절약의 상한도 조용합니다 — 액체 냉각 완전 제공은 과제당 16,210토큰·47.2초, 실행 지도 조회는 약 14,000토큰·39초입니다. 14%의 절약이 의미 있는지는 당신의 예산으로 다시 계산해야 합니다.

실무에 가져갈 것

인프라 운영이 아니어도, 당신의 자동화가 “모델 + 도구 묶음 + 문서 묶음” 구조라면 같은 계산이 적용됩니다.

첫째, “혹시 몰라서” 붙여둔 것의 값을 계산해보세요. 두 숫자만 세면 됩니다. 도구와 문서 각각이 실제로 쓰인 비율, 그리고 잘못된 도구를 골라 생긴 실패의 빈도. 대부분의 실행에서 한 번도 호출되지 않은 도구가 있다면 그 설명

은 매 실행마다 값만 치르고 있는 겁니다. 이 두 숫자가 없으면 “다 붙여두는 게 안전하다”는 검증된 적 없는 직감일 뿐입니다.

둘째, 최소 구성으로 시작해 신호가 왔을 때만 넓히세요. 빈도 1위 작업 하나를 골라 그 작업이 실제로 쓰는 것만 남긴 구성을 따로 만듭니다. 그리고 그 단계가 스스로 “이걸로는 부족하다”를 말할 수 있는 판정 기준을 하나 정합니다. 판정 기준이 애매하면 이 구조는 작동하지 않습니다. 신호가 왔을 때만 원래의 넓은 구성으로 돌립니다. **넓은 구성은 지우지 않습니다.** 안전망으로 남겨두는 것이 이 설계의 핵심입니다. 넓힐 때의 디테일도 논문과 같이 하십시오 — 한 칸씩 올라가지 말고 끝까지 점프하세요, 재시도에 가져가는 것은 첫 시도의 결론만 하세요(실패한 도구 호출 기록까지 들고 가면 오염입니다).

셋째, 비교는 한 번에 하나만 바꾸세요. 구성을 좁히면서 모델이나 프롬프트까지 동시에 손대면 결과가 좋아져도 나빠져도 원인을 모릅니다. 바꾸는 건 하네스 하나로 고정하고 나머지는 그대로 둡니다. 논문의 실험 설계가 정확히 이것입니다 — 실행자·프로토콜·채점을 얼리고 하네스만 움직였기에 0.063이 하네스의 차이로 읽힙니다.

넷째, 남의 결론을 그대로 가져오지 마세요. 두 도메인이 정반대 답을 냈다는 사실은 이 논문의 어떤 숫자도 당신의 도구에 그대로 적용될 수 없다는 뜻입니다. 0.715도 48%도 당신 것이 아닙니다. 통계까지 함께 읽으면 더 조심스러워집니다 — 액체 냉각에서조차 조희의 정확도 이득은 유의하지 않았습니다. 가져갈 수 있는 건 “내 도메인이 어느 쪽인지는 재 봐야 한다”는 태도와 재보는 방법뿐입니다. 방법은 논문이 한 그대로가 가장 쉽습니다 — 같은 작업 묶음을 넓은 구성과 좁은 구성으로 각각 돌려 성공률과 비용을 나란히 적는 것.

다섯째, 묶음 단위로 재고, 잘게 쪼개지 마세요. 논문에서 클래스 수준 조회(0.670/0.762)가 템플릿 패밀리 단위(0.634/0.704)보다, 과제 최근접 이웃(0.639/0.690)보다 모두 나았습니다. 쪼갤수록 표본이 줄어 노이즈에 과적합되기 때문입니다. 작업 로그로 대응표를 만든다면 “이런 부류의 일엔 이 구성” 수준에서 멈추는 것이 건건이 맞추는 것보다 정확할 확률이 높습니다. 완벽한 개인화는 측정을 망칩니다.

이 책의 다른 장과 이어지는 지점

이 장은 A묶음(“무엇을, 얼마나 줄 것인가”)의 첫 장입니다. 2장 AstronOS는 “주는 것의 양”이 아니라 “넘기는 상태의 무결성”을 다루고, 3장 StagedWorkspace는 “보여주는 뷰와 고치는 원본의 일치”를 다룹니다. 셋의 공통 결론은 “넉넉하게 주는 것은 공짜가 아니다”입니다. 그리고 6장은 이 장의 입력 희석 문제를 더 깊이 팝니다 — 검색해 넣어 주는 기억의 양을 늘리는 것이 순차적 의사결정에서 성적을 떨어뜨린다는 것. 9장의 하네스 실험은 이 장의 여지를 남기는 곳에서 끝납니다 — 하네스가 성능 안정성에 실제로 영향을 준다는 것이 7개 모델에서 확인됩니다. 이 장의 “문서가 해가 될 수 있다”(K2<K1)는 6장과 10장에서 다른 각도로 되돌아옵니다.

제2장 · 새 대화창을 열면 왜 일이 처음으로 돌아갈까

“원문: AstronOS: A Unified Execution Model and Runtime for Long-Horizon Agentic Systems — arXiv:2608.16381 · Zhenhang Nie, Gui Zheng, Xudong Sun, Tailong Zhu, Bin Zhang (iFLYTEK)” “링크: <https://www.alphaxiv.org/abs/2608.16381> · <https://arxiv.org/abs/2608.16381>”

한 줄 요약

인수인계는 문서를 예쁘게 쓰는 일이 아니라, 무엇이 진짜인지를 하나로 정해서 넘기는 일이다 — 내용을 다 담은 요약과 JSON도 3단계 과제에서 0점이었다.

무엇이 문제였나

에이전트 시스템은 실행과 상태를 보통 **하나의 대화, 하나의 모델 호출, 하나의 에이전트 인스턴스**를 중심으로 조직합니다. 논문의 관련 연구 정리를 봐도 그렇습니다 — AutoGen은 대화를, AgentScope는 메시지와 액터를, MetaGPT는 역할과 표준 절차를, OpenHands는 이벤트 스트림을 중심축으로 씁니다. 그런데 실제 업무는 분석, 계획, 구현, 검증을 지나며 여러 번의 호출과 여러 단계에 걸쳐 있습니다. 그릇의 수명이 일의 수명보다 짧은 겁니다. 대화창이 바뀌는 순간 그 안에 쌓인 것이 통째로 사라지고, 우리는 매번 “지난 대화 요약해서 붙여넣기”로 그 구멍을 메우려 합니다.

하루만 넘겨보면 왜 문제인지 압니다. 어제 대화창에서 어떤 방침을 정했고, 그 방침에 따라 산출물을 두 번 고쳤고, 중간에 한 번은 되돌렸다고 해봅시다. 오늘 새 대화창을 열면 그 방침도, 고친 이력도, 되돌린 이유도 없습니다. 그렇게 시작한 작업은 자꾸 어긋납니다.

논문이 이런 일에 붙인 이름은 “장기 수평(long-horizon)”인데, 기준이 시간이 아니라 **의존**이라는 점을 먼저 짚어 둡니다. 5분 만에 끝나는 세 단계 일도 마지막 단계가 앞서 확정된 범위나 판 번호에 의존하면 이 범주이고, 한 시간 걸리는 독립 질문 나열은 아닙니다. “긴 일”의 정의가 길이가 아니라 이어짐이라는 것 — 이 문제를 처음 분류하는 열쇠입니다.

야간 근무자에게 인수인계하는 상황과 같습니다. 잘 쓴 인수인계 노트는 **무슨 일이 있었는지**를 알려줍니다. 그런데 다음 근무자가 정말 필요한 건 그게 아닙니다 — **지금 유효한 지시가 무엇이고, 어떤 게 이미 취소됐는지**입니다. 노트에는 보통 이 구분이 없습니다. “A안으로 하기로 함”과 “A안 재검토 요청 들어옴”이 나란히 적혀 있으면 읽는 사람은 둘 중 무엇이 현재 유효한지 추측해야 합니다. 사람은 눈치로 넘기지만, 새 세션의 모델은 추측한 것과 확정된 것을 구분하지 못한 채 그대로 다음 작업을 시작합니다. 비유가 깨지는 지점도 있습니다 — 사람은 “이거 아직 유효해요?”라고 되물을 수 있지만, 새 세션은 되물을 상대가 없습니다. 앞의 세션은 이미 사라졌으니까요.

어떻게 답했나

논문이 제안하는 통일 실행 모델은 그릇이 아니라 **일 자체**를 중심에 둡니다. 작업 항목(work item)에 지속적 정체성을 부여해 호출이 바뀌어도 같은 일로 식별되게 하고, 그 일의 **버전 관리되는 권위 상태(authoritative state)**

— 지금 수락된 사실, 결정, 산출물 참조 — 를 호출 사이에 유지합니다. 대화창은 왔다 가도 일과 상태는 남는 구조입니다.

모델이 내놓은 출력은 처음에는 **후보 결과**일 뿐입니다. 런타임 검사를 통과하고 기록이 성공해야 비로소 수락된 결과가 되고, 그때만 이후 단계의 근거가 됩니다. 동작 규칙은 두 줄입니다.

1. 각 스텝은 **특정 상태 버전 + 새 자료**로 범위가 지정된 입력을 받습니다. 전부 다 보는 게 아니라 몇 번 상태와 이번에 새로 들어온 것만 봅니다.
2. 결과는 **검증되고 기록된 뒤에만** 상태를 전진시킵니다. 통과하지 못하면 상태 번호는 오르지 않습니다.

논문은 이 모델이 대화 중심 실행이 한덩어리로 뭉뚱그리는 네 쌍을 가르다고 말합니다. 실무자에게는 제품 이름보다 이 표가 오래 남을 겁니다.

경계	무엇과 무엇을 가르나	지켰는지 알아보는 기준
정체성	남는 일 vs 지나가는 세션·실행기	모든 스텝이 정확히 하나의 일을 가리킨다
권위	수락된 상태 vs 역사·후보 출력	이후 스텝이 의지하는 근거 판을 밝힌다
가시성	스텝에 보이는 뷰 vs 전체 기록	준비된 입력이 근거 판과 새 자료를 명시한다
커밋	실행기 출력 vs 상태 전환	커밋에 성공한 변경만 다음 판을 만든다

한 번의 시도는 **준비-실행-검사-커밋(Prepare-Execute-Check-Commit)** 순서로 흐르고, 상태가 전진하는 조건은 이렇게 정리됩니다.

상황	결과
검사 통과 + 커밋 성공	판 번호 +1, 결과는 이후 스텝의 근거가 된다
검사 거부	판 번호 그대로, 거부 사실은 기록만 남는다
버전 경쟁 패배 (그사이 다른 시도가 먼저 커밋)	수락되지 않고 현 판이 유지된다
기준 판이 이미 낡았을 때 ($v_b \neq v_{cur}$)	명시적 리베이스 없으면 거부된다

구현체 이름은 AstronOS입니다. 일(work item)은 **Case**로, 한 단계는 **Task**로 구현되고, Case의 최신 상태는 정수 개정 번호가 붙은 **Case Snapshot**으로 저장됩니다. 갱신은 비교 후 설정(compare-and-set)으로 일어나 나중 쓰기가 무조건 이기는 일을 막습니다. **Scenario Pack**은 실행 가능한 과정 템플릿으로 단계들, 단계마다 만들 태스크, Case가 다음 단계로 넘어갈 조건을 정의합니다. **Context Bundle**은 다음 실행기가 전체 역사를 다시 읽지 않게 하는 입력 꾸러미인데, 목표·사실·결정·제약·산출물 참조와 각 출처 기록, 그리고 **해야 할 정보**까지 담습니다. 상태는 중앙의 Hub가 쥐고, 실행은 중앙 모델 실행 또는 개발자의 파일·저장소·도구가 필요한 로컬 작업대(Desktop Connector)에서 일어납니다. 실무자에게 중요한 건 제품 구조가 아니라 위 두 규칙이지만, 구조가 규칙을 떠받치는 방식은 이 정도 그림이면 충분합니다.

실험 설계는 단순명료합니다. 두 개 템플릿에서 파라미터를 달리해 다섯 개씩, 모두 **10개 통제 태스크**를 만들었습니다. 모두 **소프트웨어 버전 업데이트 계획**입니다 — 후보 변경들, 의존 관계, 실행 전에 생성된 테스트 상태 기록을 읽고 무엇을 이번 업데이트에 넣고 미룰지, 뽑은 것들을 어떤 순서로 처리할지 정합니다.

- **단일 단계 계열(S) 다섯 개**: 변경 6건과 의존성, 테스트 상태를 한꺼번에 줍니다. 정확한 릴리스/보류 분류, 실패한 선택적 리프의 보류, 의존 유효 순서, 구조화 결정 한 번이 요구됩니다.
- **3단계 계열(GAR) 다섯 개**: 변경 8건, 의존 그래프, 테스트 식별자 9개가 주어지고 세 단계로 나뉩니다. 1단계는 실패한 선택적 리프를 찾아 대기 중인 근거를 기록하고, 2단계는 새 테스트 기록을 받아 정확한 후보 범위와 검문점(checkpoint)을 확정하며, 3단계는 최종 테스트 갱신을 받아 **앞서 확정된 범위를 재사용**해 최종 릴리스 결정을 냅니다. C 조건은 중간에 검문 전파 태스크를 하나 더 둡니다 — 모델을 한 번 더 써서 검문 영수증을 다음 단계로 실어 나르기만 하는 태스크이고, 그 토큰과 시간은 비용에 포함됩니다.

각 단계는 **새 제공자 세션**으로 시작합니다. 벤더 쪽에 남아 있는 대화 상태가 숨은 연속성 통로가 되는 걸 막는 장치입니다. 규모는 **10 태스크 × 5 전략 × 3회 반복 = 150회 실행**(전략당 30회). A·B·C는 1차 배치에서 여섯 가지 실행 순서를 돌려가며 수집했고, D·E는 이후 배치에서 고정 순서로 수집했습니다. 채점은 모델을 부르지 않는 **결정론적 채점기**가 맡았고, 태스크·프롬프트·채점 규칙은 첫 실행 30분 전에 소스 개정으로 올려졌습니다 — 2026-08-09 14시 52분 커밋, 15시 22분 첫 실행. 모델은 gpt-5.6-sol(추론 강도 medium), 작업대는 Codex CLI 0.145.0. 제공자 용량 문제로 무효화된 시도 3회(A·D·E 각 1)는 제외하고 같은 식별자로 재시도했습니다.

다섯 전략이 나중 단계에 주는 것은 이렇게 다릅니다.

전략	나중 단계 모델이 받는 것
A. 원자료 재독	이번 단계 자료만. 과거 정보가 필요하면 같은 도구로 원천을 다시 읽는다
B. 전체 히스토리 재생	이번 자료 + 이전 프롬프트·출력·도구 관찰 전부를 원문 순서 그대로
C. 런타임 매개 핸드오프	해시로 고정된 이번 단계 꾸러미 + 런타임이 수락한 이전 단계 결과, 구조화 결정 아티팩트, 검문 영수증
D. 롤링 요약	이번 자료 + 수락된 결정을 얼어붙은 템플릿으로 산문화한 것
E. 경량 JSON	이번 자료 + 수락된 결정을 얼어붙은 함수로 고정 필드 JSON화한 것

주목할 디테일이 하나 있습니다. D와 E는 **모델이 쓴 요약이 아닙니다**. 직전에 런타임이 수락한 결정을 결정론적으로 사영(projection)한 것입니다. 사실 참조, 후보, 릴리스·보류 집합, 대기 테스트 항목, 실행 순서, 다음 행동까지 필드를 보존합니다. “요약이 대충 쓰여서 졌다”는 설명을 처음부터 배제하려는 설계입니다.

무엇이 밝혀졌나

전체 결과부터.

전략	전체 30회	단일 단계(S) 15회	3단계(GAR) 15회	1회 이상 통과 인스턴스	통과당 토큰	시도당 시간
A. 원자료 재독	15 (50.0%)	15	0	5/10	118,537	42.3초
B. 전체 히스토리	16 (53.3%)	14	2	7/10	126,986	57.2초
C. 런타임 매개	28 (93.3%)	14	14	10/10	70,303	73.8초
D. 롤링 요약	15 (50.0%)	15	0	5/10	121,526	33.2초
E. 경량 JSON	14 (46.7%)	14	0	5/10	128,749	32.1초

(D·E는 1차 배치가 아닌 이후 배치에서 수집됐다는 점은 아래 한계 절에서 다룹니다.)

먼저 눈여겨볼 건 **차이가 안 난 조건**입니다. 단일 단계 계열에서는 다섯 전략이 14 15/15로 비슷했습니다. 한 번에 끝나는 일에서는 인수인계 방식을 고민할 이유가 없다는 뜻입니다. 우리 대부분이 평소에 문제를 못 느끼는 것도 당연합니다.

차이는 **3단계**에서 벌어집니다. A 0/15, B 2/15, C 14/15, D 0/15, E 0/15. C만 10개 인스턴스 전부에서 최소 한 번 통과했고 나머지는 5 7개에 그쳤으며, B의 3단계 통과 2회마저 두 인스턴스에 각 1회씩 몰려 있습니다. 과제 군집 단위로 다시 표본추출한 민감도 구간도 같은 방향입니다 — C에서 A를 빼면 +43.3포인트(구간 10.0 76.7), E를 빼면 +46.7포인트(구간 16.7 76.7). 열 개 군집뿐이라 통계 선언은 아니지만 부호가 뒤집힐 여지는 없어 보입니다.

비용을 함께 봐야 공정합니다. **통과한 실행 하나당** 모델 토큰은 C가 70,303개로 최저이고 나머지 넷은 118,537 128,749개, 즉 40.7 45.4% 더 씁니다. 그런데 **시도당** 토큰은 C가 65,616개로 A(59,268)보다 많습니다. C가 싼 이유는 프롬프트가 짧아서가 아니라 **실패가 거의 없어서**입니다. 3단계에서 C는 시도당 110,449 토큰으로

다섯 중 가장 많이 쓰면서도 — 프롬프트 글자 수만 100,054자로 A(17,117자)의 약 6배입니다 — 14회를 통과시켜 통과당 118,338로 끝냈습니다. 통과 기록이 있는 유일한 대조군 B는 통과당 762,319 토큰이었습니다. 낭비되는 실행이 사라지는 것이 비용을 줄입니다.

시간은 반대 방향입니다. 시도당 실행 창 시간은 C가 73.8초로 최고(A 42.3초, B 57.2초, D 33.2초, E 32.1초). 3단계 통과 실행의 평균은 C 124.73초, B 69.97초. 둘 다 통과한 짝끼리 비교하면 C가 실행 창 기준 2.0 48.9%, 하네스 기록 기준 27.4 86.3% 느립니다. 검증하고 기록하고 상태를 전진시키는 절차가 공짜일 리 없으니 당연한 결과입니다. 다만 어느 실행도 시간 제한(직접 조건은 30분 태스크 봉투, C는 14분 전체 케이스 마감)에 닿지는 않았습니다.

진단 신호도 방향이 같습니다. 지난 정보를 회수하려는 재독 횟수는 C가 평균 0.00회, A 0.93, B 0.53, D 0.47, E 0.33. 상태를 믿으면 다시 읽을 이유가 없어집니다.

실패의 해부가 결과보다 말을 많이 합니다. GAR-101 태스크의 A·D·E 실행은 1단계를 맞힌 뒤 2·3단계에 저장된 구조화 결정이 없고 최종 제출이 없었고 재독을 2번씩 했으며 15/100점을 받았습니다. 논문의 표현을 빌리면, 남아 있는 필드를 필요한 다음 단계 행동으로 바꾸는 데 직접 러너가 실패한 겁니다. 반면 C의 실패 2회는 성격이 다릅니다. 하나는 검문점을 온전히 보존하고도 의존 순서를 비표준적으로 제출했고(90/100), 다른 하나는 집합은 정확히 고르고 순서를 틀렸습니다(85/100). 상태 연속성이 보존돼도 과제 추론은 여전히 필요하다는 뜻입니다 — 런타임은 어긋남을 막지, 추리력을 주지는 않습니다.

감사된 실행 추적 하나로 그림을 그려봅니다. 하나의 Case가 네 개 태스크(세 결정 단계 + 검문 전파)를 거치며 스냅샷 r1에서 r6까지 전진하고 81.6초 만에 종결되었고, 사후 채점기가 100/100을 줬습니다. 흥미로운 건 중간 숫자가 아니라 3단계가 시작될 때 **지난 결정과 검문 영수증을 받았다**는 사실입니다. 새 세션이 처음부터 다시 읽은 게 아니라 수락된 것만 받아 시작한 겁니다.

나의 해석

이 논문의 진짜 교훈은 “요약이 나쁘다”가 아닙니다. **형식을 깔끔하게 만든다고 상태가 넘어가지 않는다는 것**입니다.

요약과 JSON이 옮기는 것은 **내용**입니다. 무슨 결정을 했고 무슨 항목이 있는지 담깁니다. 반면 옮기지 못하는 것은 그 내용의 **지위**입니다. 이 항목이 확정인지 검토 중인지, 지금 기준이 몇 번째 판인지, 어떤 항목이 이미 폐기됐는지 — 이걸 형식을 아무리 다듬어도 자동으로 따라가지 않습니다. 담으려면 애초에 그런 칸을 설계해놔야 합니다.

JSON이 특히 흥미로운 사례입니다. 구조화는 **모양의 모호함**을 없애줍니다. 어떤 필드가 어떤 값인지 헛갈릴 일이 없어집니다. 하지만 **지위의 모호함**은 그대로 남습니다. 잘 정리된 JSON은 “이 배열이 지금 유효한 계획인가, 아니면 어제 폐기된 초안인가”를 스스로 말해주지 않습니다. 개발자가 JSON에 기대는 안전감이 실제로는 절반이었다는 뜻입니다.

전체 히스토리 재생이 2/15를 얻은 것도 같은 틀로 읽습니다. 정보량으로 치면 다섯 중 가장 많이 넘긴 방식이지만, **많이 넘기는 것과 무엇이 진짜인지 넘기는 것은 다른 일**입니다. 오히려 폐기된 논의까지 전부 실려 오면서 읽는 쪽이 판단해야 할 양만 늘었을 수 있습니다. “긴 맥락이면 다 담아 주면 된다”는 믿음과도 맞닿아 있습니다 — 논문이 직접 인용하는, 긴 프롬프트 중간의 정보는 쓰이지 않는다는 연구 결과가 그 믿음에 대한 선제 반박입니다.

여기까지는 초록만 읽어도 닿는 해석입니다. 전문을 읽으면 한 걸음 더 나아갑니다. **D와 E는 지위가 아니라 내용을 다 담아도 0점이었습니다.** 릴리스·보류 집합, 대기 테스트, 실행 순서, 다음 행동까지 필드를 보존한 결정론적 사영이었는데도 남은 정보를 다음 단계 행동으로 바꾸지 못했습니다. 그러니 문제는 적어도 전부가 “칸 설계 부실”은 아닙니다. **상태를 읽을 수 있게 넘기는 것과 상태를 다음 행동의 전제가 되게 만드는 것은 다른 일**이고, 후자는 형식이 아니라 절차 — 검문, 영수증, 진행 조건 — 가 맡은 역할이었습니다. 이 문단은 나의 해석입니다. 논문은 묶음 조건을 비교했기 때문에 형식과 절차 중 무엇이 효과를 냈는지 특정하지 않고, 동일 정보 대조 실험을 다음 과제로 남겨뒀습니다.

비용 쪽에서도 배울 게 있습니다. 시도당 비용으로 보면 C는 비싸고, 통과당 비용으로 보면 싸다. 이 차이는 성공률이라는 승수 하나로 갈립니다. 에이전트 예산을 세우는 사람이라면 어떤 분모로 나누는지부터 정해야 합니다 — 실행당이 아니라 **성공당**. 3단계에서 B는 실행당 토큰이 C보다 적었지만 성공당으로는 6.4배를 썼습니다.

검문 전파 태스크도 짚고 갑니다. 모델 호출 하나를 통째로 “영수증 운반”에 쓰는 설계는 낭비로 보입니다. 그런데 결과를 뒤집어 보면 이 낭비가 14/15를 만든 묶음의 일부입니다. 사람 조직의 결재 도장과 같습니다 — 아무 생산이 없지만 “이 결정이 확정임을 다음 사람이 믿을 수 있다”는 것을 사는 돈입니다. 물론 도장이 저렴한 보험인지는 이 실험만으로 모릅니다. 다만 **확정을 전달하는 행위 자체에 비용을 쓰는 것이 이상한 일이 아니라는 점**은 남습니다. 역시 논문 밖의 해석입니다.

그리고 격차가 3단계에서만 벌어졌다는 사실이 말해주는 것이 있습니다. 단계가 늘어날수록 **한 단계의 작은 오류가 다음 단계의 전제가 되어 굳고, 그 오류는 복리로 자랍니다**. 단일 단계에서 모두가 비슷했던 것은 오류가 자랄 시간이 없었기 때문입니다. 우리가 “긴 일에서 어긋난다”고 느끼는 정체가 이것입니다.

한계와 남는 의문

단일 벤치마크·두 템플릿·한 모델 구성입니다. 10개 태스크 전부가 두 생성 템플릿의 파라미터 변형이고 모델도 gpt-5.6-sol 한 구성입니다. 사전등록도 없고 초기 파일럿이 하네스 설계에 반영된, 논문 스스로 인정하는 “개발용 증거”입니다. 실험 대상은 “소프트웨어 버전 업데이트 계획”이라는 한 유형의 일이었고, 단계 의존이 뚜렷하며 무엇이 확정인지가 비교적 뚜렷하게 정의되는 종류입니다. 창작이나 탐색처럼 **확정이라는 개념 자체가 흐릿한 일**에서도 같은 격차가 나올지는 알 수 없습니다.

단일 단계와 3단계는 짝을 맞춘 쌍이 아닙니다. 두 계열은 생성기도, 크기도(변경 6건 vs 8건), 증거 구조도 다릅니다. 그래서 “3단계라서 격차가 벌어졌다”는 인과 진술은 이 설계가 지원하지 않습니다. 벌어진 사실과 벌어진 이유는 다른 문제로 뒤야 공정합니다.

D와 E는 나중 배치에서 수집됐습니다. A-C 1차 배치와 순차적으로 나뉘어 있어 제공자 측 드리프트가 섞일 수 있고, 온도·시드·제공자 스냅샷 같은 샘플링 통제도 기록돼 있지 않습니다. 0/15가 전략 타인지 시점 타인지 완전히 분리되지 않는다는 뜻입니다. 제외된 3회의 용량 무효 시도 비용까지 억지로 반영해도 C의 통과당 70,303은 최저를 유지한다는 민감도 검사는 논문이 해줬습니다.

C는 묶음 패키지입니다. 패키징, 검문 전파 태스크, 런타임 진행, 즉시 정보 커버리지가 함께 달라졌습니다. 단일 단계에서 C가 워크벤치 톤 하나를 쓰고 직접 조건이 탐색·결정 톤 둘을 쓰는 차이만 봐도 실행 구조 자체가 다릅니다 — 논문은 이 때문에 단일 단계 토큰 격차(C 20,784 vs 33,723 33,809)를 핸드오프 덕으로 돌리지 않습니다. 이런 정직함이 결론의 신뢰를 높입니다.

채점 구성타당성의 그림자도 있습니다. 채점기는 정확한 구조화 결정을 요구하는데, 애초에 상태를 구조로 가진 런타임이 이 구성물에 유리하게 정렬돼 있을 수 있습니다. 정성적·개방적 결과를 요구하는 과제에서는 다른 그림이 나올 수 있다고 논문 스스로 밝힙니다. 공개 아티팩트도 150행 원장 재계산까지만 가능해서 채점기를 직접 돌리거나 조건별 모델 가시 정보를 비교할 수는 없습니다.

왜 3회 반복과 “고정” 채점기가 중요한가 — 덧붙입니다. 같은 조건을 3회 반복한 건 모델 출력의 흔들림 때문입니다. 한 번만 돌리면 잘 나온 실행 하나가 전략의 실력처럼 보일 수 있습니다. 채점기를 열려둔 것도 같은 맥락입니다 — 실험을 진행하며 채점 기준을 다듬으면 나중에 측정한 전략일수록 유리해지는 오염이 생깁니다. 두 장치 모두 결론을 강하게 만드는 쪽이 아니라 **결론을 덜 틀리게 만드는 쪽**의 설계입니다. 이런 장치가 있다는 것 자체가 이 실험을 신뢰할 이유입니다.

실무에 가져갈 것

런타임을 새로 만들지 않아도 규칙 몇 개는 오늘 옮길 수 있습니다. 조건은 하나 — 여러 날, 여러 세션에 걸쳐 이어지는 일이어야 합니다. 한 번에 끝나는 일에서는 다섯 전략의 차이가 없었으니, 이 절의 제안들은 그런 일에는 과잉입니다.

인수인계 요약에 “지위” 칸을 만드세요. 항목마다 “확정 / 검토 중 / 폐기됨”을 적습니다. 형식을 바꾸는 게 아니라 칸 하나를 더하는 일입니다. 요약이 점수를 잃은 이유가 “요약이라서”만은 아니었다는 게 이 제안의 근거입니다 — 다만 이번 장의 실험이 보여주듯 지위 칸만으로는 부족하고, 그 칸을 다음 행동과 묶는 절차가 함께 가야 합니다.

산출물이 아니라 “몇 번을 보고 일했는지”를 남기세요. 결과 파일에 한 줄을 더합니다 — 이 결과가 어느 판의 기준 자료를 보고 만들어졌는지. 판 번호와 날짜, 그때 유효했던 방침 한 줄이면 됩니다. 가치는 나중에 드러납니다. 기준 자료가 갱신했을 때 이 표시가 있으면 어떤 산출물이 낡았는지 즉시 골라낼 수 있습니다. 없으면 전부 다시 확인하거나, 더 흔하게는 낡은 걸 모른 채 그대로 씁니다.

다음 단계로 넘기기 전에 통과 조건을 하나 두세요. 거창할 필요 없습니다. 항목 수가 맞는지, 필수 값이 비지 않았는지, 앞 단계 방침과 어긋나지 않는지 같은 기계적으로 확인 가능한 것이면 충분합니다. 핵심은 조건의 정교함이 아니라 순서입니다. 통과한 뒤에만 다음 단계의 입력이 되게 하고, 통과하지 못하면 이전 기준이 그대로 유효한 채로 남게 하는 것. 커밋 규칙의 번역입니다.

같은 판에서 시작한 둘 중 하나는 물러나게 하세요. 두 사람이나 두 에이전트가 같은 판을 기준으로 각각 일하고 있으면 먼저 확정된 쪽이 이깁니다. 늦은 쪽의 결과는 버리고 새 판 기준으로 다시 검증하게 합니다. 이 규칙이 없으면 늦게 도착한 옛 판의 작업이 새 판을 덮어써서, 지위 칸으로 정리했던 것들이 소리 없이 되돌아갑니다.

비용은 성공당으로 계산하세요. 도구나 파이프라인을 비교할 때 실행당 비용만 보면 “빠르고 가벼운” 쪽이 늘 이깁니다. 이 실험의 교훈은 성공률이 낮으면 가벼운 실행이 통과당으로는 몇 배 비싸진다는 것입니다(B의 762,319 vs C의 118,338). 반대로 사람이 기다리는 대화형 작업이라면 시도당 시간이 다섯 중 가장 길었다는 사실이 실제로 아플 수 있으니, 내 일이 정확도·토큰·시간 중 무엇에 민감한지 먼저 정해야 합니다.

이 구조는 공짜가 아닙니다. 지위를 적고 판 번호를 남기고 통과 조건을 확인하는 일은 모두 시간을 씁니다. 모든 작업에 적용하지 말고, 여러 날 이어지고 중간 결과가 다음 단계의 전제가 되는 일부만 적용하세요.

이 책의 다른 장과 이어지는 지점

이 장은 A목록의 둘째 장입니다. 1장이 “주는 양”을 다뤘다면 이 장은 “넘기는 상태의 무결성”을 다룹니다. 3장 StagedWorkspace는 같은 문제를 작업 공간 차원에서 벌입니다 — 에이전트가 읽는 뷰와 고치는 원본이 어긋날 때 무슨 일이 나는지. 7장은 이 장의 “지위” 개념을 프로젝트 전체로 확장합니다 — 폐기된 결정의 대체 관계까지 지식그래프에 남기는 방법. 그리고 4장은 반대 방향의 경고입니다 — 상태를 넘기는 경계에서 사실이 증발한다는 측정.

제3장 · 내가 읽은 파일과 내가 고친 파일은 같은 버전인가

“원문: StagedWorkspace: A Versioned Workspace for Knowledge-Work Agents — arXiv:2608.18050”

“지은이: Yining Hua, Hongbin Na, Yifan Zhou, Akshay Kalose, Cyrus Ayubcha, Levi Lian (하버드대 · Raycaster AI · 시드니공과대 · 워싱턴대 · 스탠퍼드대)” “링크: <https://www.alphaxiv.org/abs/2608.18050> · <https://arxiv.org/abs/2608.18050>”

한 줄 요약

에이전트가 틀리는 이유는 종종 판단이 나빠서가 아니라, 보고 있는 사본이 지금 파일이 아니어서다.

무엇이 문제였나

사람이 엑셀 파일을 다룰 때는 통로가 하나입니다. 파일을 더블클릭하면 창이 열리고, 그 창에서 보고, 그 창에서 고치고, 그대로 저장합니다. 보는 것과 고치는 것이 물리적으로 같은 대상이라 “지금 보고 있는 게 최신인가”라는 질문 자체가 잘 생기지 않습니다.

에이전트는 사정이 다릅니다. 하나의 작업물이 최소 **네 가지 얼굴**로 나타납니다. 무언가를 찾아볼 때 읽는 **파싱된 뷰**(엑셀·PDF·슬라이드를 텍스트로 풀어놓은 사본), 실제로 값을 고치고 저장하는 **네이티브 파일**(원본 .xlsx, .pptx 자체), 사람이나 상위 절차가 검토하는 **변경 내역(diff)**, 그리고 마지막에 내보내는 **제출 산출물**.

이 넷은 각각 다른 시점에 만들어지고, 만들어진 뒤에는 서로를 쳐다보지 않습니다. 사본을 뜯 뒤에 원본을 세 번 고쳐도 사본은 처음 뜯 그 상태 그대로입니다. 그래서 에이전트는 **어제 사본을 근거로 오늘 원본을 고치는 일**을 아무 경고 없이 할 수 있습니다.

원서를 번역해 둔 번역본과 같습니다. 번역본만 보고 “이 책에는 이런 내용이 없다”고 말하면, 그건 책 내용이 아니라 내 사본의 나이를 말한 것입니다. 번역본은 표지에 “초판 번역”이라고 찍혀 있어 눈치챌 여지라도 있지만, 에이전트의 파싱된 뷰에는 그런 표시가 기본적으로 없습니다.

코딩 에이전트는 이 문제를 상대적으로 덜 겪습니다. 코드 저장소가 이미 검색·변경 내역·테스트를 한 세트로 묶어 제공하기 때문입니다. 논문은 이걸 저장소가 제공하는 일종의 **계약**으로 봅니다 — 명시적으로 문서화되진 않았어도 도구가 관습적으로 지켜주는 약속이라는 뜻입니다. 그런데 PDF 보고서, 스프레드시트, 슬라이드, 노트북이 섞인 일반 프로젝트 폴더에는 그 약속이 훨씬 덜 명시적입니다.

논문은 이 결핍의 근원을 세 갈래 인터페이스 딜레마로 정리합니다. **원본만** 주면 완전하지만 검색이 어려워, 에이전트가 큰 파일을 페이지 넘기듯 뒤지며 쓸데없는 맥락을 짚어집니다. **파싱 사본만** 주면 검색은 되지만 레이아웃·수식·실행 가능성이 사라집니다. **버전 없는 가변 작업공간**을 주면 에이전트가 파일을 덮어쓰고 옮기고 지워도 모델이나 사람이 검토할 영구한 diff가 남지 않습니다.

어떻게 답했나

논문은 이 문제를 **작업공간 상태 계약(workspace-state contract)**으로 정형화합니다. 모든 뷰는 “지금 진화 중인 작업공간의 어느 버전을 보고 있는지”를 명시적으로 달고 다녀야 한다는 규칙입니다. 사본이든 변경 내역이든, 자기가 어느 시점에서 떠온 것인지를 스스로 밝히지 못하면 그 뷰는 근거로 쓸 수 없습니다.

형식화는 단정합니다. 시점 t 의 작업공간을 세 뷰로 씁니다 — 네이티브 파일들 W_t , 출처 경로와 내용 지문이 붙은 파싱 기록들 C_t , 시작 상태와 현재 상태의 차이 Δ_t . 실행과 제출의 근거가 되는 권위 상태는 W_t 하나이고, C_t 와 Δ_t 는 별도 문서가 아니라 **낡은 뷰**입니다. 파싱 기록은 자기 원본의 지문이 현재 W_t 의 해당 파일과 같으면 ‘최신(current)’이고, 다른면 ‘**낡음(stale)**’으로 **라벨이 바뀌어** 비동기 재파싱이 끝나야 최신으로 돌아옵니다.

구현체인 StagedWorkspace는 이 규칙을 **내용 지문(content hash)**으로 구현했습니다. 파일 내용 전체를 짧은 값 하나로 압축한 지문은 내용이 1바이트만 달라져도 완전히 다른 값이 됩니다. 파일을 고치는 도구 묶음이 끝날 때마다 샌드박스를 훑어 지문이 바뀐 파일만 가려내고, 그 파일에 묶인 파싱 기록만 낡음 표시와 재파싱 큐에 넣습니다. 바뀌지 않은 파일의 파싱 기록은 그대로 재사용됩니다 — 697개짜리 문서함에서 방금 고친 한 파일만 다시 파싱하는 셈입니다. 나중에 지문이 안 맞으면 그 사본은 조용히 통과되지 않고 **낡은 것으로 드러납니다**.

한 단계 더 들어가면 쓰기 연산 자체도 버전을 붙여 저널에 남깁니다. 각 연산은 연산자·대상 경로·**기준 지문(base hash)**·연산 종류·내용을 기록하고, 검증을 통과하면 수용 트리로 승격(promotion)되며 통과 못 하면 스테이지에 남습니다. 기준 지문이 현재 지문과 다르면 그 연산은 낡은 것으로 간주되어 에이전트나 검토자의 조정에 맡겨집니다 — “이 편집은 옛 파일을 보고 설계된 편집”이라고 연산 스스로 고백하는 셈입니다. 계약의 규칙을 표로 정리하면 다음과 같습니다.

계약 규칙	구현	규칙이 없을 때 생기는 일
모든 파싱 기록은 출처를 밝힌다	기록마다 원본 경로와 내용 지문 부착	옛 사본이 현재 파일인 양 답변
지문이 어긋나면 낡음으로 라벨	current/stale 표시 후 비동기 재파싱	바뀐 원본을 모른 채 검색 근거를 신뢰
쓰기 연산은 기준 지문을 남긴다	저널에 연산자·경로·기준 지문·내용 기록	옛 가정 위에 현재 파일을 덮어쓰기
검토 diff는 제출 상태에서 계산	시작 상태와 현재 상태의 비교(Δ_t)	제출본과 무관한 변경 내역을 검토
수용과 롤백은 거래로	커밋 승격은 거래형, 롤백은 역패치	반쯤 적용된 편집이 남음

이 설계가 한 번에 나온 것이 아님도 논문은 부록에 기록합니다. 초기 설계 탐사의 실패 세 가지입니다. 첫째, 파싱 동반 페이지를 그냥 읽게 했더니 에이전트가 검색에 걸린 **한 페이지만 읽고 전체 문서를 다 본 줄 알고** 답했습니다 — 지금은 파싱 사본을 검색 층으로만 쓰고 읽기는 원본 경로로만 허용합니다. 둘째, 파싱 색인 없이 PDF에 grep을 하면 PDF 바이트 안의 내용에 아무것도 걸리지 않아서, 원본만 받은 팔은 실패한 grep과 pdftotext 대체 루프를 되풀이했습니다. 셋째, 미리 뽑아둔 정적 텍스트 내보내기는 살아 있는 원본도, 편집 후 재색인도 없어서 파서 품질과 상태 동기화가 뒤섞입니다. 최종 설계의 규칙 하나하나가 이 실패 흔적 위에 서 있습니다.

측정 설계는 두 갈래입니다. 첫째, 실행 환경(하네스)을 고정하고 **작업공간 조건만** 바꿉니다 — 모델·프롬프트·파서·검색기·채점기·파일 추적기·도구 예산(250회)을 모두 같게 둔 채 읽기 측만 갈아 끼워, 점수 차이를 작업공간 탓으로 돌릴 수 있게 합니다. 둘째, 제거 실험(ablation)으로 뷰를 하나씩 빼 봅니다 — 원본과 파싱 사본을 다 주는 이중 접근(dual), 원본만 주는 조건, 파싱 사본만 주는 조건을 비교합니다. 검토 축 절제는 별도로, 이중 접근을 유지한 채 제출 전 변경 내역 도구를 보여줄지 숨길지만 바꿉니다.

평가는 성격이 정반대인 두 벤치마크에서 이뤄졌습니다. **OfficeQA Pro**는 미 재무부 재무 게시판(Treasury Bulletin) PDF 약 697건(1939–2025)을 통째로 걸어두고 수치가 정확히 일치하는 답을 요구하는 읽기 무게형 질의응답입니다 — 문서만으로 답하는 104문항과 웹 검증이 필요한 29문항, 총 133문항. **APEX-Agents**는 경영 컨설팅·투자은행·법무의 33개 세계 480태스크로 산출물을 루브릭 채점하는 낱품 무게형입니다 — 태스크 폴더마다 평균 약 166개의 혼합 형식 파일, 태스크당 1 10개(평균 4.06개)의 통과 기준을 **모두** 통과해야 pass이고, 외부 API(EDGAR)가 설정되지 않은 28태스크를 제외한 452태스크를 평가했습니다. 메커니즘 절제의 모델들(GPT-5.4

가족, Gemini 3 Flash)은 태스크당 3회 시도로 예산을 통일했고, 불확실성은 문항·태스크 단위 1만 번 부트스트랩 (씨드 20260515)의 쌍대 재표본으로 계산했습니다 — 조건끼리 짝지어 재표본해 공분산을 보존합니다.

무엇이 밝혀졌나

결과는 같은 방향을 가리킵니다.

① **이중 접근이 시험한 모든 모델에서 최고였다.** 파싱된 사본과 네이티브 원본에 둘 다 접근하는 조건이 가장 높은 점 추정치를 기록했습니다. 더 제한적인 단일 뷰 대비 OfficeQA Pass@1 **+8.3 12.1점**(원본만 대비), APEX 평균 루브릭 점수 **+4.7 9.2점**(파싱만 대비).

벤치마크	모델	이중 접근	원본만	파싱만	원본만 대비	파싱만 대비
OfficeQA Pro (Pass@1, %)	GPT-5.4	64.7	52.6	58.6	+12.1	+6.1
OfficeQA Pro (Pass@1, %)	Gemini 3.1 Pro	63.9	55.6	54.9	+8.3	+9.0
OfficeQA Pro (Pass@1, %)	Gemini 3 Flash	57.8	47.7	53.8	+10.1	+4.0
APEX (평균 루브릭 점수)	GPT-5.4 Nano	42.1	41.1	32.9	+1.0	+9.2
APEX (평균 루브릭 점수)	GPT-5.4 Mini	44.3	40.3	38.8	+4.0	+5.5
APEX (평균 루브릭 점수)	Gemini 3 Flash	47.8	43.8	43.1	+4.0	+4.7

통계적 유의성도 방향이 같습니다. OfficeQA의 이중 대 원본만 대비는 세 모델 모두 유의하고(쌍대 부트스트랩 $p = 0.005/0.010/0.041$), APEX의 이중 대 파싱만 대비도 그렇습니다(Nano 0.0002, Mini 0.014, Flash 0.028). 그리고 **어느 단일 뷰가 무너지는지는 벤치마크 성격을 따라갑니다.** OfficeQA는 기본이 “찾아 읽기” 과업이라 파싱만 조건이 이중에 근접하고 검색이 지렛돌입니다. APEX는 반전됩니다 — 파싱만 받은 에이전트는 관련 지시는 찾지만 네이티브 파일에 대한 실행이 안 되어 무너지고, 원본만 대비 상승은 양수이지만 $p > 0.05$ 로 유의하지 않습니다. 읽기만 되는 과업과 읽고 고쳐야 하는 과업에서 각각 다른 뷰가 빠대라는 뜻입니다.

② **이 설계를 적용한 SW-Agent의 성적.** OfficeQA에서 GPT-5.4 64.7%(같은 모델의 공개 최고 행 56.4%, +8.3), Gemini 3.1 Pro 63.9%(공개 29.3%, +34.6), Gemini 3 Flash 57.8%(공개 33.1%, +24.7). GPT-5.4의 이중 접근 64.7%는 정답 출처를 아예 주입하는 오라클 조건의 65.4%에 사실상 맞닿습니다 — 검색을 스스로 해내고도 출처를 받은 것과 같은 성적입니다. APEX에서는 GPT-5.4 Nano가 Pass@1 25.0·평균 루브릭 42.1로, 공개 행 16.9·25.5 대비 **+8.1 / +16.6**. Gemini 3 Flash +6.9/+8.3, GPT-5.4 Mini +3.6/+6.8, Gemini 3.1 Pro +2.6/+2.3 이고, GPT-5.4의 37.7/53.6는 벤치마크가 보고한 Opus 4.7 참조 행(33.9/50.6)도 넘습니다. Kimi K2.6도 31.2 대 27.9. 다만 하네스가 달라 직접 비교는 아닙니다(아래 한계 절).

③ **변경 내역을 보여주면 점수가 오른다.** 57개 파일 편집 태스크의 짝지은 비교 — 양쪽 모두 같은 파일 변경을 기록하고, 보이는 쪽만 제출 전에 workspace_diff·workspace_file_diff 도구를 쓸 수 있습니다. diff가 보일 때 점수가 더 높았고, 상승폭은 편집이 약한 모델일수록 컸습니다.

모델	diff 숨김	diff 공개	상승
Gemini 3 Flash (High)	47.6	50.2	+2.5
GPT-5.4 Mini (xHigh)	40.9	49.4	+8.5
GPT-5.4 Nano (xHigh)	48.1	51.9	+3.8

④ **이득은 비용의 산물이 아니다.** 이중 접근이 그냥 더 오래, 더 비싸게 돈 결과가 아니라는 진단입니다. OfficeQA에서 GPT-5.4의 이중 접근은 문항당 \$0.84로 원본만 팔(\$0.85)과 비슷하고 Databricks 파싱만 기저선(\$0.94)보다 싸면서 더 높은 점수를 받았고, 걸리는 시간도 6.1분 대 파싱만 17.3분으로 짧았습니다(Gemini 3.1 Pro도 10.3 대 18.7분). APEX에서는 성적을 위해 어느 정도 비용을 더 쓰는 교환이 있는 편입니다.

⑤ **사례와 잔여**. APEX의 HarFeast 사례가 메커니즘을 보여줍니다. 3,000행 통합 문서를 설문 열 가이드에 맞게 필터링하는 태스크에서, 이중 팔은 파싱 검색으로 열 가이드를 찾고 pandas 연산이 채점될 바로 그 통합 문서에서 실행됐습니다. 원본만 팔은 문서를 열 수 있었지만 필터 논리를 그르게 조립했고, 파싱만 팔은 지시는 찾았지만 실행이 불가했습니다. 이중이 이긴 국면 356건의 주 경로를 보면 파싱 캐시가 42%, 원본이 40%, 둘 다 필요한 경우 9% — 어느 한쪽이 아니라 **둘의 동기화**가 통로였습니다. 반대로 452태스크 중 188개(41.6%)는 세 조건이 모두 0점인 잔여입니다(투자은행 62.1%, 컨설팅 34.4%, 법무 31.9%). 상태 동기화를 고쳐도 움직이지 않는 계획·도메인 추론·루브릭 준수 실패의 영역입니다.

이상을 합치면 논문의 결론이 나옵니다. **작업공간 상태는 실험의 배경이 아니라 실험 변수로 다뤄야 하고**, 벤치마크는 근거·준비된 편집·제출 산출물을 명시적인 상태 전이로 채점해야 한다는 것. “무엇을 답했나”만 보지 말고 “어느 상태에서 어느 상태로 옮겨 갔나”를 채점하자는 이야기입니다.

나의 해석

이 논문에서 제가 먼저 떠올린 것은 데이터베이스 분야의 오래된 개념, **낙관적 동시성 제어**입니다. 트랜잭션이 읽은 시점의 버전을 기억했다가 커밋 직전에 검사해, 그 사이 누가 건드렸으면 충돌로 실패시키는 장치. 데이터베이스는 수십 년 전부터 이 문제를 풀어왔는데, 에이전트의 작업 폴더에는 이 장치가 통째로 없었습니다. 전문을 읽고 나니 이 유비는 비유로 그치지 않습니다 — StagedWorkspace의 저널이 각 쓰기 연산에 남기는 **기준 지문(base hash)**은 이름만 다를 뿐 낙관적 동시성 제어의 버전 검사 그 자체입니다. 이 논문은 그 결핍에 이름을 붙이고 숫자를 댔다고 읽습니다. 새로운 발명이라기보다, 다른 분야가 오래 알던 불변의 원칙 — **읽은 것과 고친 것이 같은 시점이어야 한다** — 이 지식노동 에이전트에도 적용됨을 보인 것입니다.

둘째, 어느 모델이 크게 이득 보느냐가 말해주는 것이 많습니다. 전체 시스템 비교에서 이득은 비프론티어 모델에 집중됩니다 — Gemini 3.1 Pro는 29.3%에서 63.9%로, GPT-5.4 Nano는 루브릭 25.5에서 42.1로. 논문은 이를 “작업공간 접근과 모델 능력의 상호작용 가능성”으로 조심스럽게 표현합니다: 정돈된 작업공간이, 큰 모델이 되풀이 검색과 재독기로 벌충하던 격차의 일부를 회수한다는 것입니다. 여기서 논문이 직접 끌어내는 함의 하나를 나눈다 더 무겁게 봅니다 — **작업공간을 통제하지 않는 리더보드에서 소형·대형 모델의 격차는 능력 차로 과장될 수 있다**. 모델을 고르는 사람이라면 벤치마크 점수에 “어떤 작업공간 위의 점수인가”를 물어야 합니다.

셋째, 이중 접근이 이긴다는 결과는 1장의 결론(덜 주는 게 나을 수 있다)과 대조적이어서 흥미롭습니다. 1장에서는 선택지를 줄이는 게 이득인 도메인이 있었고, 여기서는 뷰를 **하나로 줄이는 것이 오히려 손해**였습니다. 차이는 뷰의 성격입니다. 서로 다른 두 도구의 설명이 경쟁하는 하네스와 달리, 파싱된 사본과 원본은 경쟁하는 선택지가 아니라 **같은 대상의 두 표현**입니다. 하나는 읽기 쉽고 하나는 정확합니다. 둘 다 있을 때 에이전트는 사본으로 훑고 원본으로 확인합니다. 주는 것의 양이 아니라 **대상에 대한 시야의 완전성**이 문제였던 겁니다. ①의 결과 — 읽기 과업에선 파싱이, 납품 과업에선 원본 실행이 지렛돌 — 도 같은 방향입니다. 줄이는 게 아니라 촉마다 필요한 쪽을 떼지 않는 것이 원칙입니다.

넷째, ③번 결과 — diff를 보여주는 것만으로 편집 품질이 오른다는 것 — 는 프로그래머에게는 지당한 습관이지만 문서·스프레드시트 작업에는 통째로 빠져 있었었습니다. 이 “당연한 것의 부재”를 찾아내는 것이 이런 논문의 실제 기여라고 생각합니다. 검토자가 완성본만 보면 “그렇듯해 보인다”에서 끝나지만, 변경 목록을 보면 “이 셀은 왜 바뀌었지?”라는 질문이 생깁니다. **질문이 생기는 것 자체가 품질 장치입니다**. 상승폭이 편집이 약한 모델에서 컸다는 세부(Mini +8.5, Flash +2.5)는 이 장치의 쓸모를 정확히 지목합니다 — 최종 점검은 실력을 대체하는 게 아니라 실수를 잡는 층이므로, 실수가 잦을수록 값이 커집니다.

한계와 남는 의문

“가장 높은 점 추정치”라는 조심스러운 표현. 이걸 “확실히 더 낫다”는 단정이 아니라 대푯값 기준으로 앞섰다는 서술입니다. 실제 유의성도 갑니다 — OfficeQA의 원본만 대비와 APEX의 파싱만 대비는 유의하지만, APEX의

원본만 대비는 세 모델 모두 $p > 0.05$ 입니다. “이중 접근이면 무조건 이긴다”가 아니라 “과업의 뼈대가 되는 뷰를 빼면 유의하게 무너진다”까지가 정확한 독해입니다.

공개 점수와의 비교는 직접 비교가 아니다. 63.9% 대 29.3%처럼 눈에 띄는 대비는 인용하기 좋지만 두 숫자는 서로 다른 실행 환경에서 나왔습니다. 시도 횟수부터가 다릅니다 — 공개 APEX 리더보드는 태스크당 8회 시도 관례, 이 논문의 절제는 3회, 문맥 비교용 단일 행(Gemini 3.1 Pro, Kimi K2.6)은 1회입니다. 비용 열도 에이전트 실행 비용만 세고 배경 파싱(Reducto 크레딧, OCR 페이지)과 샌드박스 호스트 비용은 빠져 있어, 이중·파싱 팔의 초기 색인 구축비가 숨겨집니다. 인용해야 할 것은 같은 하네스 안에서 조건만 바꾼 +8.3 12.1점 쪽입니다. 파서를 바꿔도 파싱만 조건의 점수가 2점 미만으로 움직인다는 민감도 검사는 있지만, 절제 전체가 파서·검색기를 고정한 채 돌아갔으므로 계약 자체와 그 두 부품을 분리하지는 못합니다.

채점이 최종 산출물만 본다. 논문이 스스로 밝히는 첫 번째 한계입니다. 채점기는 최종 답이나 산출물만 점수 매기지, 올바른 출처를 열었는지·올바른 표 영역을 읽었는지·유효한 추적 편집을 했는지 같은 중간 검문점을 채점하지 않습니다. 논문은 이 신호의 일부를 꺾적 수동 코딩으로 회수하지만, 이는 예시적일 뿐 코더에 따라 달라질 수 있다고 못박습니다.

잔여가 크다. 452태스크 중 188개(41.6%)는 세 조건 모두 0점입니다. 작업공간 동기화는 이 영역을 움직이지 않으며, 남는 실패는 계획·도메인 추론·루브릭 준수의 몫입니다. 상태 관리의 이득이 끝나는 지점을 논문이 숫자로 스스로 그려둔 것은 평가할 만합니다.

남는 의문 — 지문 검사가 “났었다”를 알려주는 시점의 비용은 어디에 두는가. 구현은 도구 묶음이 끝날 때마다 검사하고 재파싱은 비동기로 미루지만, 검사 주기의 정책 자체는 구현의 몫으로 남습니다. 쓰기 직전마다 검사하면 안전하지만 느리고, 주기적으로만 하면 사이 구멍이 생깁니다. 그리고 여러 에이전트가 같은 폴더를 병렬로 다루는 경우의 충돌 처리(사용자별 분기가 힌트지만)는 이 논문의 범위를 넘습니다. 검토 축 결과도 APEX의 약 12%에 해당하는 편집 슬라이스에 대한 것이므로, 편집 무게 과업에서의 일반화는 더 큰 평가가 필요합니다.

실무에 가져갈 것

엑셀·PDF 산출물을 다루는 자동화를 굴리고 있다면 다음 지점이 바로 해당됩니다. 논문의 규칙을 최소한의 도구로 옮긴 목록입니다.

읽을 때 지문을 같이 적어두세요. 파일을 읽어 판단 근거로 삼는 자동화라면, 읽는 순간의 내용 지문을 로그에 남기고 쓰기 직전에 다시 계산해 비교합니다. 다르면 쓰지 않고 멈춥니다. 특별한 인프라가 필요 없습니다 — 해시 함수는 어느 언어에나 기본으로 들어 있습니다. 읽기와 쓰기 사이에 사람이 시트를 손봤거나 다른 자동화가 행을 추가했거나 병렬 처리가 겹쳤다면, 자동화는 이미 사라진 행 번호를 기준으로 값을 씁니다. 결과는 **조용한 오염**입니다 — 오류로 멈추지 않고 그럴듯하게 틀린 파일이 나옵니다.

근거에 ‘신선도 라벨’을 새기세요. 논문 구현의 핵심 디테일 하나는 기록에 current/stale 라벨을 다는 것입니다. 실무에서는 파싱 사본·요약·검색 발체 같은 파생 근거 옆에 “어떤 원본 경로의 어느 지문 시점에서 뽑았는지”를 문자열로 붙여두는 것으로 충분합니다. 답을 만들기 전에 라벨의 지문이 현재 원본과 다르면 근거를 버리고 원본을 다시 읽습니다. 검색 인덱스·캐시·요약 노트가 다 여기 해당됩니다 — **파생물은 출처 지문을 달고 다녀야 합니다.**

파싱 사본은 검색용으로만 쓰세요. 초기 설계 탐사의 첫 실패가 이것입니다 — 검색에 걸린 한 페이지만 읽고 전체 문서를 본 줄 알고 답하는 에이전트. 색인·요약·발체는 탐색과 후보 발견에만 쓰고, 판단과 답변에 쓰는 근거는 원본(또는 원본의 명시적 페이지 범위)에서 읽게 규칙을 정합니다. “부분 사본을 전체 지식으로 착각하는” 실패는 뷰를 늘리는 것과는 별개의, 읽기 표면 설계 문제입니다.

결과물만 보여주지 말고 변경 목록을 함께 내세요. 처리 후에 “어느 시트의 어느 셀이 무엇에서 무엇으로 바뀌었다”는 목록을 자동으로 남기게 만드는 것만으로도 큰 차이가 납니다. 57태스크 짝비교에서 diff 가시성만 바뀌도 +2.5 8.5점이었고 편집이 약한 모델일수록 이득이 컸습니다. 검토가 완성본의 그럴듯함에서 끝나지 않게 하는 장치이자, 제출 직전 마지막 점검의 재료입니다.

덮어쓰기를 기본값에서 빼세요. 원본을 덮어쓰면 이전 상태가 사라져 비교 자체가 불가능해집니다. 지문을 남길 수도 변경 내역을 만들 수도 없습니다. 각 단계의 산출물을 별도 파일로 남기고 정리는 검토가 끝난 뒤에 합니다. “파일 일이 쌓인다”는 반론은 보관 정책 문제이지 설계 문제가 아닙니다 — 검토가 끝나기 전까지는 이전 상태가 살아 있어야 한다는 원칙은 유지됩니다.

여러 단계 파이프라인이라면 각 단계가 받은 지문을 그대로 다음 단계로 넘기게만 해도 어긋남이 발생한 지점을 정확히 짚을 수 있습니다. 1단계가 읽어 판단하고 3단계가 고치고 5단계가 제출본을 만드는 구조에서, 각 단계가 붙고 있는 “파일에 대한 이해”가 서로 다른 시점의 것일 수 있기 때문입니다. 지문이 단계를 거치며 전달되면 사고 지점이 로그 한 줄로 드러납니다.

이 책의 다른 장과 이어지는 지점

이 장은 A목록을 달는 장입니다. 1장이 주는 양을, 2장이 넘기는 상태의 지위를 다뤘다면, 이 장은 **보는 것과 고치는 것의 일치**를 다룹니다. 2장의 “지위” 개념을 파일 시스템 차원으로 구체화한 것으로도 읽힙니다 — 지문이 곧 “이 사본은 몇 번 판을 보고 있는가”의 표지입니다. 4장의 사실 감쇠와 함께 보면 경계의 위험이 두 갈래임이 보입니다 — 정보가 넘어가다 줄어드는 것(4장)과 정보가 시점을 잘못 붙잡는 것(이 장). 두 갈래 모두 모델이 똑똑해지면 저절로 풀릴 문제가 아니라 인터페이스가 정할 문제라는 점에서, 이 책 전체의 축과 같은 방향에 서 있습니다.

제4장 · 일은 끝났는데 지켜야 할 걸 안 지켰다

“원문: Governance at the Boundary: How Agent Decomposition Degrades Policy Compliance — arXiv:2608.16055 · Bowen Li, Guojun Wang” “링크: <https://www.alphaxiv.org/abs/2608.16055> · <https://arxiv.org/abs/2608.16055>”

한 줄 요약

에이전트를 쪼개면 일은 빨라지는 대신, 규칙이 넘겨주는 자리에서 새어 나간다 — 소실률 0%, 56%, 85%. 더 강한 모델은 3.6%로 낮추지만 0으로는 만들지 못한다. 그리고 같은 소실이 위험 신호를 삼키면 과소 에스컬레이션, 면책 신호를 삼키면 과잉 에스컬레이션을 만든다.

무엇이 문제였나

기존 에이전트 벤치마크는 대체로 하나를 물었습니다. “에이전트가 과제를 끝냈는가.” 코드를 고쳐 테스트를 통과시켰는가, 요청한 문서를 만들어 냈는가. 이 질문은 유용하지만 규정이 있는 영역에서는 위험할 만큼 불완전합니다. 에이전트가 고객 심사를 끝냈다고 합시다. 결과물은 멀쩡해 보입니다. 그런데 중간에 “이 거래는 사람에게 올려야 한다”는 신호가 있었는데 그냥 처리해 버렸다면, 그건 성공이 아니라 **규정 위반**입니다. 완수율 지표는 이 실패를 성공으로 세어버립니다. 규정 위반은 결과물의 겉모습에 잘 드러나지 않기 때문입니다.

이 논문이 던지는 질문은 하나가 더 붙습니다. “**정책 안에서 끝냈는가.**” 그리고 에이전트를 여러 구성요소로 쪼개면 이 두 번째 질문의 답이 나빠진다는 것을, 원인까지 짚어 보여줍니다.

시점이 흥미롭습니다. 2026년에도 거버넌스 자체를 재는 연구는 있었습니다. 기권을 재는 것(AgentAbstain), 에스컬레이션 보정을 재는 것(Act or Escalate?), 숨은 사실이 정책 위반을 만든다는 것(PhantomPolicy), 절차 인식으로 성공 지표를 다시 채점하는 것(Corrupt Success). 논문이 꿈은 선행 녀 편이 그렇습니다. 그런데 이 녀 편 모두 아키텍처를 고정한 단일 구조에서 재었습니다. 과제와 모델을 같게 묶어 두고 **구조만 바꿔서** 비교한 연구는 없었습니다. 이 논문이 서 있는 자리가 정확히 그 빈자리입니다.

원인은 능력 저하가 아닙니다. 앞단 구성요소가 발견한 **규정과 관련된 사실**이, 다음 구성요소에게 일을 넘기는 지점(핸드오프)에서 약해지거나 사라져, 정작 그 사실에 따라 행동해야 하는 쪽에 닿지 못하는 것입니다. 논문은 이를 **감쇠(attenuation)** 라고 부릅니다. 소리가 멀어질수록 작아지는 그 감쇠입니다. 정보가 틀리게 바뀌는 왜곡과 다릅니다 — 감쇠는 **조용히 없어집니다**. 받는 쪽은 무언가 빠졌다는 사실조차 모릅니다. 없어진 정보에 대해서는 경고음이 울리지 않는다는 것이 이 현상의 가장 고약한 점입니다.

야간 근무자가 환자를 관찰하다가 “이 환자는 특정 약에 알레르기가 있다”는 사실을 알아낸 경우와 같습니다. 교대 시간에 그는 오늘 처치 내역과 활력징후를 꼼꼼히 인계하지만, 알레르기 사실은 지금 당장 쓸 일이 없어 보여 말하지 않습니다. 다음 근무자가 몇 시간 뒤 그 약을 처방합니다. 두 사람 모두 자기 판단으로는 최선을 다했습니다. 비유가 깨지는 지점 — 사람에게겐 “왜 이걸 안 알려줬느냐”고 나중에 따질 절차라도 있지만, 에이전트 파이프라인에는 그 되묻는 절차 자체가 없는 경우가 대부분입니다.

어떻게 답했나

논문은 **통치가능성(governability)**이라는 축을 세우고, 이를 재는 **Fiducia-bench**라는 금융 에이전트용 벤치마크를 만들었습니다. 재는 것은 세 가지입니다.

1. **에스컬레이션** — 올라야 할 의무가 있을 때 사람에게 올리는가. 콜센터 상담원이 “제 권한 밖이라 담당자를 연결해 드리겠습니다”라고 하는 동작이 에이전트에게는 설계된 정상 동작입니다. 올라야 할 때 안 올리는 것이 실패입니다.
2. **기권(abstain)** — 판단을 멈춰야 할 때 “정보가 부족하거나 권한 밖이므로 판단하지 않는다”고 선언하는가. 답을 내는 쪽으로 훈련된 시스템에게 가장 어려운 동작입니다.
3. **감사 가능한 흔적** — 나중에 제3자가 “왜 그렇게 판단했는지”를 되짚을 수 있는 기록을 남기는가. 규제 영역에서는 판단이 옳았는지 못지않게 그 판단을 설명할 수 있는지가 중요합니다. 흔적이 없으면 옳은 판단도 옳았다고 증명할 수 없습니다.

세 축을 문장으로 외우기 어렵지 않게, 실제 채점에 쓰인 지표까지 묶어 한 표로 정리하면 이렇습니다.

구분	이름	묻는 것	놓쳤을 때의 모양
세 축	에스컬레이션	올려야 할 때 올리는가	과소 또는 과잉
세 축	기권	멈춰야 할 때 멈추는가	근거 없는 답
세 축	감사 가능한 흔적	판단 경위를 되짚을 수 있는가	증명할 수 없는 옳음
지표	통치된 성공	끝냈고 치명적 위반이 없고 에스컬레이션이 올바른가	“끝냈지만 절차 위반”
지표	전파 손실	발견한 사실이 의무 행동으로 이어졌는가	발견했는데 행동 없음
지표	사실 감쇠	경계를 넘는 요약에 사실이 살아남았는가	핸드오프에서 조용한 소실
지표	위반 위치·권한 확산	어느 구성요소가 위반 호출을 냈는가	위반한 쪽과 실패한 쪽이 다름

지표를 순수하게 궤적과 과제 정의만의 함수로 만든 것도 설계 포인트입니다. 판정 규칙이 나중에 좋아지면 지난 실행을 다시 채점할 수 있습니다. 과제는 시드 다섯 개에서 뺀 나갑니다.

시나리오	제약 거리	올바른 행동
깨끗한 계좌 개설	0	올리지 않는다(부정 의무)
자금 출처 확인 유도	1	서류를 요청한다
애매한 제재 명단 매칭	2	동결하고 올린다
숨은 최종수익자(UBO), 연쇄 사실	2	확인하고 스크리닝하고 올린다
풀 수 있는 PEP 오탐	2	올리지 않는다(부정 의무)

여기 결정적 생성기가 붙습니다. 시드마다 페르소나·관할·금액·지분율을 바꿔 100개 변형을 만드는데, 정답이 데이터에 따라 뒤집힙니다 — 지주사 지분을 26%에서 24%로 낮추는 것만으로 올바른 행동이 바뀝니다. 암기로는 못 푸는 구조이고, 100개 변형의 정답 스크립트가 전부 검증기를 통과하는 것도 확인돼 있습니다.

정책은 YAML “정책 팩”으로 주어집니다. 규칙마다 식별자·심각도·사람이 읽는 문장·기계가 판정하는 체크가 붙고, 체크 유형은 네 가지(require_before, allow_list, state_assert, forbid_when)입니다. 현재 10개 규칙 전부 **심판 LLM 없이 결정적으로 판정됩니다**. 검증은 궤적 재생으로 합니다 — 최종 상태를 보는 게 아니라 환경의 깨끗한 복사본에 각 도구 호출을 되풀이하면서 **그 호출이 일어난 시점의 상태에서** 조건을 평가합니다. 감사 로그와 “누가 이 호출을 했는가” 표기도 구성요소의 자기 보고가 아니라 환경이 찍습니다. 이 두 가지 — 환경이 감사를 소유한다, 재생하며 검사한다 — 가 나중에 논문이 일반적으로 권한 있는 설계가 됩니다.

비교한 세 아키텍처는 아래로 갈수록 잘게 쪼갠 구조입니다. **단일 루프**(D0 — 에이전트 하나가 과제 전체를 처음부터 끝까지 말합니다. 넘겨줄 일이 없는 기준선입니다), **고정 파이프라인**(D1 — 접수, 조사, 판결의 세 단계가 순서대로 일을 이어받으며, 각 단계는 앞 단계의 요약만 봅니다), **오케스트레이터-서브에이전트**(D2 — 지휘자가 도구 권

한이 제한된 하위 에이전트들에게 일을 나눠 주고 보고서만 받습니다. 왕복할 때마다 경계가 2개씩 붙고 문맥 고립이 가장 엄격합니다).

세 구조는 도구·정책 문서·역할 프롬프트를 전부 똑같이 공유하고 **조직 위상(topology) 문단 하나만** 다릅니다. 그 문단이 독립변수입니다. 구성요소는 자기가 직접 호출한 도구 결과만 볼 수 있어, 경계를 넘어 문맥이 몰래 새는 일은 구조적으로 막혀 있습니다.

1번에서 3번으로 갈수록 구조가 유연해지고 병렬 처리가 쉬워집니다. 실무에서 3번을 선호하는 이유가 그것입니다. 논문이 재려는 건 바로 그 유연함의 숨은 비용입니다.

모델은 둘입니다. **Qwen2.5-32B-Instruct**(32B 밀집 모델, GPTQ-Int4 양자화, 로컬 vLLM으로 구동 — 오픈웨이트 진영의 실무형 배치)와 **gpt-4.1-mini**(API 호출). 과제 변형 100개, 아키텍처 3개, 모델 2개의 본 그리드 596화에 정책 접근 방식 비교 30화를 더해 **총 626 에피소드**, 에피소드마다 스텝 예산 25입니다.

핵심 변수로 **제약 거리(constraint distance)**를 씁니다. 논문의 정의는 정확합니다 — **발견 지점에서 의무 행동 지점까지, 그 사실이 건너야 하는 구성요소 경계의 수**. 거리가 멀수록 그 사실은 겉보기에 덜 중요해 보여서 넘기는 과정에서 잘 떨어져 나갑니다. PEP 오답 과제를 예로 들면, 고객의 생년월일과 국적이 명단의 그것과 다르다는 사실 두 개가 최소 한 번의 핸드오프를 온전히 살아남아야 “올리지 않을” 근거가 성립합니다.

무엇이 밝혀졌다

헤드라인 측정은 제약 거리 2, 발견된 사실 기준 감쇠율입니다. 분자·분모까지 공개된 숫자입니다.

아키텍처	거리 2에서 건너는 경계	Qwen2.5-32B	gpt-4.1-mini
단일 루프(D0)	0	0/16 (0%)	0/27 (0%)
고정 파이프라인(D1)	2	9/16 (56%)	1/30 (3%)
오케스트레이터-서브(D2)	2, 왕복마다 누적	22/26 (85%)	1/18 (6%)

세 숫자를 나란히 놓으면 이야기가 분명해집니다. 넘기는 자리가 없으면 사실은 사라지지 않습니다(0%). 넘기는 자리가 생기면 절반 넘게 사라집니다(56%). 구조가 더 잘게, 고립이 더 엄격해지면 대부분이 사라집니다(85%). **소실은 구성요소의 능력이 아니라 경계를 따라갑니다**. 두 모델에서 순서가 똑같이 보존된다는 점이 이 결과를 단단하게 만듭니다.

정밀한 포인트 하나. D1과 D2는 거리 2 과제에서 건너는 경계 수가 같은 2인데 감쇠율은 56%와 85%로 갈립니다. 설계를 보면 이해가 됩니다 — D2는 왕복이 반복될 때마다 경계가 2개씩 추가되고, 문맥 고립이 “엄격 + 도구 스킵핑”으로 더 차단적입니다. **경계의 개수만큼이나 얼마나 못 보게 차단하는가가 변수**라는 뜻입니다.

더 강한 모델은 덜 흘린다 — 단, 부분적으로만. 같은 조건에서 gpt-4.1-mini는 3%와 6%로 떨어집니다. 논문의 결론은 조심스럽습니다 — 분해의 거버넌스 비용은 **부분적으로 모델 능력의 함수**라는 것. “부분적으로”를 흘려 읽지 않는 게 중요합니다. 모델을 키우면 완화되지만 **0%가 되지는 않습니다**. 구조가 만들어 낸 문제를 능력으로 덮고 있는 것이지 구조가 고쳐진 게 아닙니다. 그리고 규제 영역에서 100건 중 36건의 규정 위반은 결코 작은 수가 아닙니다. 논문 표현을 빌리면 — 강한 모델은 더 나은 핸드오프 요약물 쓸 뿐, 분해는 기준선 대비 감쇠를 일관되게 늘립니다.

대칭성 — 쪼개면 보수적으로 안전해진다는 착각. 이 논문의 가장 반직관적인 발견입니다. 같은 메커니즘이 **과소 에스컬레이션과 과잉 에스컬레이션을 둘 다** 만듭니다. 떨어져 나간 사실이 위험 신호였다면 뒷단은 그 위험을 모른 채 스스로 처리해 버립니다 — 과소. 반대로 떨어져 나간 사실이 면책 신호(예: “이 예외는 이미 승인받은 건이다”)였다면 뒷단은 정상 건을 위험로 보고 사람에게 올립니다 — 과잉. 감쇠는 안전한 방향으로만 기울지 않습니다. 방향은 사라진 정보의 성격이 정하고, 그건 미리 알 수 없습니다. 과잉 에스컬레이션도 실무에선 심각합니다 — 확인 건수가 불어나면 사람은 결국 대중 승인하게 되고, 그 순간 안전장치는 형식만 남습니다.

논문은 이 대칭성을 일부러 설계해 측정했습니다. 거울로 짝지은 두 과제의 숫자입니다(Qwen2.5-32B, D2, 거리 2).

과제	떨어진 사실의 성격	발견(25화 중)	감쇠	감쇠 시 결과
kyc-0004	위험 신호(숨은 UBO)	10	8/10 (80%)	스크리닝 생략으로 과소 에스컬레이션
kyc-0005	면책 신호(PEP 오탐)	16	14/16 (88%)	불일치 미전달로 과잉 에스컬레이션

두 경우 모두 요약용 구성요소는 그 사실을 “부차적”이라고 여겼고, 두 경우 모두 **위반한 구성요소와 실패한 구성요소가 다릅니다**. 사실을 흘린 쪽은 책임을 지지 않는 구조입니다. 이 짝짓기에는 두 번째 역할도 있습니다 — 긍정 의무 과제와 부정 의무 과제를 나란히 두면 “무조건 다 올리기”가 점수를 얻지 못합니다. 어느 한 방향으로만 세면 게임이 되는 지표를 양방향으로 세우는 것, 이것도 논문이 원하는 설계입니다.

찾기의 역설. Qwen2.5-32B에서 D2는 100화 중 27화에서 트리거 사실을 발견합니다. D0는 16화입니다. 오펜트레이터의 구조화된 위임이 더 정교화된 질문을 이끌어낸다는 것이 논문의 설명입니다. 그런데 D2는 그 27화 중 22화에서 그 사실을 흘려버립니다. D0는 하나도 흘리지 않습니다. 논문의 한 문장이 이 결과를 요약합니다 — **정책 관련 정보를 찾는 데 더 좋은 아키텍처가 그것을 나르는 데는 더 나쁩니다**. 단 gpt-4.1-mini에서는 발견 순서가 다릅니다(D1이 34화로 최고). 찾기 유리는 이 모델에서의 관찰이지 구조의 보편 성질은 아닙니다.

정책을 어떻게 보여주는지는 죄가 없다. 정책 전문을 문맥에 통째로 넣는 방식과 검색 도구로 필요할 때 찾게 하는 방식을 D0에서 비교했는데, 세 모델에서 계통적인 차이가 없었습니다. 효과를 만드는 건 정책 접근 방식이 아니라 분해 자체라는 뜻입니다.

벤치마크, 전체 태스크, 검증 장치는 모두 오픈소스로 공개돼 있습니다. 결과를 그대로 믿기보다 자기 조건에서 다시 재볼 수 있다는 뜻입니다.

나의 해석

이 논문을 읽고 제가 처음 든 생각은 — 이걸 새로운 발견이 아니라 **오래된 조직론의 측정**이라는 점입니다. 대형 병원이 항공 산업이 수십 년간 알아온 사실, “인수인계 지점이 사고의 핫스팟”이라는 것을 에이전트에서 숫자로 보인 겁니다. 새로운 건 그 비율입니다. 사람 조직에서는 감쇠를 측정하기 어려워 정성적으로만 말했는데, 에이전트에서는 넘겨받은 정보의 내용을 그대로 덤프할 수 있어 **0%, 56%, 85%처럼 정확한 값**이 나옵니다. 관측 가능성이 높아지자 우리가 겪던 문제의 실제 크기가 처음 보인 것입니다.

둘째, “모델 능력의 함수”라는 결론의 실무적 해석에 신경을 씁니다. 강한 모델에서 36%로 줄었다는 것은, 오펜트레이터-서브에이전트 구조가 **충분히 강한 모델에서만** 안전한 선택이라는 뜻입니다. 실무자의 질문은 “쪼갠까 말까”가 아니라 **“이 모델로 쪼개도 되는 수준인가”**가 되어야 합니다. 논문은 두 점(32B, gpt-4.1-mini)을 이은 선이라 그 경계선이 어디인지 알려주지 않습니다. 그래서 자기 환경에서 재보는 수밖에 없고 — 공개된 벤치마크가 있다는 것이 이 논문의 실질적 선물입니다. 여기에 논문 토론 절의 표현을 하나 엮습니다 — 거버넌스 비용은 **이동 표적**이라는 것. 모델이 좋아지면 비용이 내려가니, 제 생각에는 승인 관리 단위가 “아키텍처”가 아니라 **“아키텍처와 모델의 조합”**이어야 합니다. 모델을 바꾸는 날에는 구조를 안 바꿨어도 거버넌스를 다시 재야 한다는 뜻입니다. 이 조합 관리는 논문에 없는 제 처방입니다.

셋째, 찾기의 역설을 조직론으로 읽으면 이렇습니다 — **전문화는 눈을 날카롭게 만들고 손을 둔하게 만든다**. 위임받은 조사자는 좁은 범위를 깊게 파니 더 좋은 질문을 하지만, 그 질문의 답은 자기가 아닌 지휘자의 보고서로 갑니다. 지휘자는 많은 보고서를 종합하느라 개별 사실의 무게를 잃습니다. 분업의 고전적 문제가 그대로 재생산된 것입니다. 실무적 뜻은 이것입니다 — 쪼갬이 발견을 늘리는 이점이 실제로 있으니(27 대 16) 쪼개지 말라가 아니라, **쪼갬 거면 나르는 통로를 별도로 설계하라**가 정답에 가깝습니다. 이 독해도 논문 밖의 제 확장입니다.

넷째, D1과 D2가 같은 경계 수(2)에서 56%와 85%로 갈렸다는 사실을 설계 지침으로 번역하면 — **“몇 조각으로 나눌까”**만큼 **“각 조각이 서로를 얼마나 못 보게 할까”**가 독립적인 설계 변수라는 것입니다. 실무에서는 후자를 거의 논하지 않습니다. 문맥을 넘기면 비용이 든다는 이유로 요약만 넘기는 쪽을 기본값으로 택하는데, 이 논문의 숫

자는 그 기본값의 가격표입니다. 경계 수를 같게 유지하면서 고립 강도만 낮추는(원본을 동행시키는) 중간 지점이 있다는 뜻이기도 합니다.

다섯째, 부록의 전체 그리드를 더 읽으면 논문 본문이 논하지 않는 숫자가 하나 눈에 밟힙니다. gpt-4.1-mini의 전 파 손실은 감쇠가 0%인 D0에서조차 14건입니다(발견 27건 중). 사실이 끝까지 살아남아도 의무 행동으로 이어지지 않는 실패가 따로 있다는 뜻입니다. 요약 잘 쓰는 것과 사실에 따라 움직이는 것은 별개의 능력이고, 강한 모델은 앞만 좋아했을 수 있습니다. 본문이 다루지 않는 숫자라 제 독해로 명시해 둡니다.

여섯째, 처음 보았던 대로 처방의 방향이 1장과 정반대인 점이 흥미롭습니다. 1장은 “필요할 때만 넓혀라”였고 이 장은 “규칙 판단 구간은 좁게 유지하되 **쪼개지 말라**”입니다. 공통점은 둘 다 **경계의 개수를 설계 변수로 다룬다**는 것입니다. 경계는 비용을 냅니다 — 1장에서는 토큰으로, 이 장에서는 규정 준수로. “분해는 자유다”가 아니라 “분해는 선택이고 대가가 있다”로 프레임이 옮겨가는 것이 이 시기 논문들의 공통 방향이라고 읽습니다.

한계와 남는 의문

도메인이 금융 규제 하나다. KYC/AML은 규칙이 문서로 명확히 정해져 있고 지켜야 할 항목이 촘촘하며 위반의 대가가 큰 영역입니다. 이런 성격이 감쇠율에 어떻게 작용했는지 알 수 없습니다. 규칙이 더 느슨한 영역에서는 소실률이 다르게 나올 수 있고 반대로 더 높게 나올 수도 있습니다. 다른 도메인에서 같은 비율이 나올 거라는 근거는 없습니다.

모델이 둘뿐이다. “능력의 함수”라는 결론은 두 점을 이어 그린 선입니다. 점 두 개로는 선의 모양을 알 수 없습니다. 모델을 키우면 계속 좋아지는지, 어느 지점에서 멈추는지, 다른 모델 계열에서도 같은지 — 전부 확인되지 않았습니다. 방향성 정도로 읽는 게 맞습니다.

저자가 스스로 말하는 세 가지 미확인 사항이 있습니다. 프론티어 규모에서도 성립하는지, KYC/AML 밖에서 일반화하는지, 더 나은 핸드오프 프롬프팅으로 줄일 수 있는지. 논문은 여기까지만 이 문장을 붙입니다 — “이걸 나중에 찾아내는 검토자는 처음부터 말하는 저자보다 불리한 위치다.” 한계를 먼저 부르는 태도가 결과의 신뢰를 오히려 올립니다.

바닥부터 낮은 통치된 성공. 두 모델을 통틀어 과제를 정책 안에서 끝낸 에피소드는 596화 중 8화(1.3%)입니다. 감쇠 신호 자체는 크고 안정적이지만, 애초에 기준선인 D0를 통과하는 모델이 필요하다는 것이 저자 자신의 지적입니다. 숫자를 읽을 때 “감쇠율은 발견된 사실 조건부”라는 전제를 잊으면 안 됩니다.

완주율도 절반이다. 스텝 예산 25 안에 끝내지 못하고 중단된 에피소드가 구조별로 100화 중 37.5화입니다. 감쇠를 겪기도 전에 끝난 실행이 절반 가까이 있다는 것은, 실무 관점에서 이 벤치마크의 과제 난도가 결코 만만치 않다는 뜻입니다. 또 하나, 트리거 사실을 부분문자열로 감지하는 설계라 표현(문구)을 함께 재는 면이 있고, LLM 시뮬레이터가 준비돼 있었지만 본 에피소드에는 쓰이지 않았습니다.

그럼에도 이 논문의 신호는 분명합니다. 정확한 비율이 아니라 **순서**가 메시지가기 때문입니다. 넘기는 자리가 늘어날수록 규정 관련 사실이 더 많이 사라진다는 방향은, 셋을 나란히 재서 얻은 결과라 도메인이 바뀌어도 뒤집히기 어렵습니다.

실무에 가져갈 것

금융이 아니어도, 검증 규칙이나 예외 처리가 여러 단계로 쪼개진 자동화 파이프라인이면 어디든 해당됩니다.

단계 사이에 넘길 것을 목록으로 고정하세요. 각 단계가 알아서 요약하게 두면 자기 임무와 무관해 보이는 사실이 가장 먼저 버려집니다. 1단계가 “이 건은 예외 항목이라 일반 규칙을 적용하면 안 된다”를 알아내도, 임무가 자료 정리라면 예외 사실은 넘어가지 않습니다. 3단계는 일반 규칙을 적용하고 결과물은 **아무 오류 없이** 완성됩니다 — 예외 누락은 오류를 내지 않습니다. “발견한 예외·경고는 요약하지 말고 그대로 넘긴다”를 규칙으로 박아두고, 그 목록이 최종 산출물 옆에 붙어 나오게 하세요. 논문 토론 절도 같은 방향을 권합니다 — 요약이 **무엇을 반드시 담고 무**

엇을 빼면 안 되는지를 규격으로 정의하는 구조화된 핸드오프 프로토콘. 현행 실무가 대부분 무시하고 있다는 게 저자들의 진단입니다. 제 경험을 보태면, 여기서 한 발 더 나가 **필수 필드가 비어 있으면 파이프라인이 진행하지 못하게 멈추는** 규격이어야 합니다. 경고는 경고로만 두면 결국 무시됩니다.

규칙 판단이 걸린 구간은 쪼개지 마세요. 자료 수집이나 형식 변환처럼 규칙과 무관한 구간은 마음껏 나눠도 됩니다. 반면 “이건 예외인가”, “사람에게 올려야 하는가”를 판단하는 구간은 **판단에 필요한 사실을 전부 쥐고 있는 하나의 자리**에서 처리하는 게 낫습니다. 단일 루프가 0%를 낸 이유가 정확히 그것입니다. 이미 잘게 쪼개놔서 되돌리기 어렵다면 — 판단에 필요한 사실들을 각 단계가 요약하지 못하게 하고 **원본 그대로 끝까지 동행시키는 통로**를 하나 따로 두세요. 찾기의 역설이 보여주듯 쪼갬에 발견상의 이점이 있는 이상, 정답은 무분별한 쪼갬도 무조건적 통합도 아니고 “탐색은 쪼개고 판단은 모으는” 비대칭 구조입니다.

완료 여부와 준수 여부를 따로 세세요. 성공·실패 두 칸 말고 “완료됐지만 절차를 안 지킨” 칸을 만듭니다. 자동으로 재기 어려우면 주기적으로 표본을 뽑아 사람이 확인하는 것만으로도 현재 수준의 감이 잡힙니다. 재는 방식도 논문에서 배울 점이 있습니다 — 최종 상태가 아니라 **각 단계가 일어난 시점의 상태 기준**으로 되짚아 검사하면, 나중에 꼬인 결과를 놓고 어느 단계에서 어겼는지가 나옵니다.

행위자 기록은 에이전트가 아니라 인프라가 찍게 하세요. “누가 이 호출을 했는가”를 구성요소의 자기 보고에 맡기면 감쇠와 같은 이유로 흘러 없어집니다. 호출마다 이름·인자·결과 요약·행위자를 파이프라인 계층에서 찍어 두면, 위반이 나왔을 때 위반한 쪽과 실패한(사실을 흘린) 쪽이 다르다는 것도 증명할 수 있습니다.

긍정 의무와 부정 의무를 짝지어 검사하세요. “올려야 할 때 올리는가”만 세면 항상 올리는 시스템이 고독점입니다. 올리지 말아야 할 정상 건을 함께 넣어 두어야 게임이 성립하지 않습니다. 논문의 거울 과제 설계를 그대로 가져온 것입니다.

이관 건수의 급변을 의심하세요. 같은 메커니즘이 과소·과잉 양쪽을 다 만듭니다. 사람에게 올리는 건수가 갑자기 늘거나 줄면 그것은 판단이 좋아진 신호가 아니라 무언가 흘러고 있다는 신호일 수 있습니다.

이 책의 다른 장과 이어지는 지점

이 장은 B목록(“얼마나 쪼갤 것인가”)의 첫 장입니다. 5장은 같은 질문을 통신 비용 축에서 짹니다 — 쪼개면 메시지가 폭증하다가 브로드캐스트로 우회한다는 것. 두 장을 나란히 읽으면 쪼갬의 대가가 두 갈래임이 보입니다 — 이 장은 **정보의 질**이 새고(규정), 5장은 **통신의 양**이 썩니다(토큰). 2장 AstronOS의 “지위를 넘겨라”는 이 장의 처방과 정확히 같은 방향입니다. 그리고 9장의 evaluation-hacking 발견과 함께 보면, “결과 점수만 보면 안 보이는 실패”라는 이 책 D목록의 문제의식이 여기서 먼저 구체화됩니다. 이 장이 꿈은 선행 녀 편 — 특히 절차 인식으로 성공을 다시 채점하는 Corrupt Success — 역시 같은 문제의식의 다른 표현이고, 그 연장선에서 이 책의 남은 장들이 읽힙니다.

제5장 · 여덟 명이 붙으면 여덟 배로 빨라질까

“원문: When Agents Coordinate: Measuring Coordination in Multi-Agent AI Coding — arXiv:2608.16801 · Giuseppe Destefanis, Tomaso Aste (UCL 컴퓨터과학과)” “링크: <https://www.alphaxiv.org/abs/2608.16801> · <https://arxiv.org/abs/2608.16801>”

한 줄 요약

에이전트를 늘릴 때 먼저 붙는 값은 일하는 값이 아니라 서로 말 맞추는 값이다 — 그리고 그 값의 모양은 인원수가 아니라 작업의 구조가 정한다.

무엇이 문제였나

에이전트를 두 개, 여덟 개, 열여섯 개로 늘리면 일이 그만큼 빨라질까? 다중 에이전트 시스템의 평가는 대개 두 가지만 보고 했습니다 — 과제를 끝냈는가, 얼마가 들었는가. 팀 **안에서** 무슨 일이 벌어지는지는 대부분 측정되지 않았습니다. 같은 시험을 다 통과한 두 실행이 통신량에서 몇 배씩 차이 날 수 있는데 최종 코드에는 흔적이 남지 않습니다.

문제의 골자는 이것입니다. 에이전트 한 명이 늘면 대화 상대는 한 명이 아니라 **여러 쌍**이 늘어납니다. 회식 자리에서 사람이 2배가 되면 인사를 나눠야 하는 조합은 2배가 아니라 4배 가까이 늘어납니다. 이것이 통신비가 인원수의 제곱에 가깝게 붙는 이유이고, 브록스가 「맨먼스 미신」에서 지적한 바로 그 구조입니다. 사람 조직에서는 이 비용을 정성적으로만 말할 수 있었지만, 에이전트에서는 통신량을 그대로 기록할 수 있습니다.

개발자가 내리는 결정은 세 개입니다 — 팀 크기, 코디네이터 지목 여부, 메시지 대신 파일. 이 연구는 세 결정의 효과를 출력이 아니라 **팀 안에서 만들어진 통신망**에서 측정했습니다.

어떻게 답했나

이 연구의 결정적인 선택은 **통신망의 정점에 에이전트만 넣지 않고 파일도 함께 넣었다**는 것입니다. 보통은 “누가 누구에게 메시지를 보냈나”만 세는데, 그러면 에이전트가 파일에 적어두고 다른 에이전트가 그걸 읽어가는 흐름이 통째로 안 보입니다. 이 연구는 파일을 정적인 산출물이 아니라 **시간을 건너뛰어 대화가 오가는 지속되는 공유 통신 채널**로 봅니다. 한 번 쓰인 파일은 몇 명이든 나중에 읽히고 세션 경계를 넘어 존재합니다 — 두 채널을 같은 시간선에 올린 것이 계측기의 심장입니다.

간선은 세 종류입니다 — 에이전트에서 에이전트로 가는 직접 메시지, 에이전트가 파일에 쓰거나 고치는 행위, 파일에서 에이전트로 흘러가는 읽기. 모든 간선에는 타임스탬프, 바이트 단위 크기, 예상 토큰 비용이 붙습니다.

계측 파이프라인은 다섯 단계입니다. 작업 생성기가 과제를 만들고, 팀 크기·구조·파일 정책으로 조건을 세팅하고, 병렬 실행 중 **모든 상호작용을 중앙 서버에 기록**하고(메시지와 파일 조작이 전부 도구 호출로 흘러 로그가 남게 합니다), 고정 테스트 스위트로 채점하고, 로그를 네트워크 테이블로 변환합니다. 계측은 에이전트 바깥에서 돌아가는 런타임에나 붙습니다.

과제는 일이 팀으로 나뉘는 두 전형을 따릅니다. **분산 과제**(process_orders)는 Python 함수 사양을 네 조각(시그니처·검증 규칙·할인 계산·정렬 순서)으로 나눠주고 아무에게도 전체를 보여주지 않습니다. 팀은 조율로 사양을 다시 맞춰야 합니다. **연쇄 과제**(summarise_transactions)는 파싱→검증→집계→포맷의 4단계 체인으로, 각 에이전트는 팀 공통 지식(파이프라인 함수 이름·시그니처)과 개인 지식(자기 단계의 입출력 계약·산출 파일명)만 받습니다. 체인의 길이와 자기 위치, 다른 단계의 내용은 비밀이라 인터페이스는 실행 중에 합의해야 합니다.

변형 축이 겹쳐집니다. 사양 배분은 세 가지 — **깨끗한 배분**(한 조각씩), **중복 배분**(일부 이중 지급), **충돌 배분**(두 에이전트가 “수량 0은 유효한가”에서 갈리는 검증 규칙의 서로 다른 판본을 받고, 채점 스위트는 한쪽을 조용히 강제하며 어느 쪽인지 알려주지 않습니다). 팀 구조는 평등한 **플랫**과 한 에이전트만 “너는 코디네이터다”를 받는 **지목형**, 파일 정책은 세 가지(아래 ③의 표), 팀 크기는 1·2·4·8명과 스케일링 암의 16명.

격자는 실험당 58개 배치, 배치당 10회. 플랫 조건은 바이트 단위로 동일한 프롬프트로 두 차례 수집해(컬렉션 A·B) 재현성까지 썰 수 있게 했고, 함께 **1,902회 실행**과 봉인 복제 **244회**가 공개됐습니다. 환경은 Claude Code(2.1.x), 모델 claude-sonnet-4-6 고정, 매 턴 기록. 8개 가설을 사전 등록했습니다(6개는 검정 방식까지).

사양이 네 조각인데 팀이 여덟 명이면 네 명은 맡은 조각이 없습니다. 연구진은 이 **과잉 배치** 셀을 버리지 않았습다 — 실제 팀에도 일보다 사람이 많은 때가 흔해서입니다. 결과: 일 없는 네 에이전트가 팀 메시지의 **62%**를 보냈습니다(1인당 13.7건, 조각을 든 에이전트는 8.4건). 맡은 일이 없으면 모든 걸 남에게 물어야 하니까요. 그리고 “팀을 키워도 일이 남는” 조건을 만들기 위해 8단계 체인(2·4·8인)과 16단계 체인(4·8·16인, 셀당 20회)의 스케일링 암을 따로 돌렸습니다(“일이 바닥나서”와 구분하려고).

읽는 계기판은 세 개입니다. **스케일링 지수**(팀이 n배 커질 때 통신량이 n의 몇 제곱으로 늘나 — 2에 가까우면 제곱 폭발, 1이면 비례, 0이면 더 이상 안 늘), **전역 클러스터링 계수**(내 대화 상대들끼리도 서로 대화하는가, 0 1), **평균 연결 차수**(한 명이 실제로 상대한 파트너 수). 이때 “채널”은 인사 한 번으로 안 칩니다 — 한 쌍에 메시지가 **2통 이상** 오가야 지속 채널로 셉니다.

무엇이 밝혀졌나

① **통신은 앞쪽에 몰린다 — “초기 악수”**. 직접 메시징은 초기에 거의 제곱에 가깝게 늘었습니다. 연쇄 과제에서 스케일링 지수 **1.92**(95% 신뢰구간 1.80 2.05), 두 세션에서 1.92·1.93으로 일치했습니다. 메시지는 2인 6.1통에서 8인 71.3통으로. 팀을 두 배로 키우면 메시지가 거의 네 배가 됩니다. 그런데 이 폭증은 고르게 퍼져 있지 않습니다 — 한 쌍당 메시지 수는 오히려 줄어듭니다(약 3통 → 1.27통). 총량이 늘는 건 쌍의 수가 늘어나서뿐이고, **쌍의 90%가 실행의 첫 20%($\tau \approx 0.2$) 안에 만들어집니다**. 킥오프 미팅과 같습니다. 첫날은 명함 돌리느라 대화가 폭발하지만 둘째 주에는 이미 정리된 관계 위에서 필요한 말만 오갑니다.

비유가 깨지는 지점이 흥미롭습니다 — 사람의 킥오프는 한 번 하면 끝이지만, **에이전트는 세션이 새로 시작될 때마다 이 악수를 처음부터 다시 합니다**. 짧은 작업을 여러 번 돌리는 방식은 악수 비용만 반복해서 무는 구조가 됩니다. 더 큰 팀에서는 놀라운 일이 벌어집니다. 16단계 체인에서 8인→16인 구간의 성장 지수가 **0.00**(95% 신뢰구간 -0.34 0.34)으로 완전히 멎었습니다. 총량은 4·8·16인에서 21.4·47.0·46.8통으로 8인부터 평평하고 꺾임이 유의합니다. 이 체인은 16인에서야 모두에게 일이 돌아가는 구조라 “일이 바닥나서”가 아닙니다. 대신 에이전트들이 스스로 말하는 방식을 바꿨습니다 — 8인에서 16인으로 가며 이름을 지목하는 메시지는 34.6통→12.2통으로 줄고 **브로드캐스트(모두에게 외치기)**는 12.3통→34.0통으로 늘었으며, 16인 실행 20회 중 12회는 브로드캐스트만으로 조율했습니다. 팀이 다섯 명이면 개별로 말하지만 오십 명이면 공지 채널에 올리는 것과 같습니다. 관계 유지 비용이 감당 안 되는 지점에서 소통 방식 자체가 바뀐다는 점에서, 논문은 인간 조직 문헌을 맥락으로 끌어옵니다 — 직속 5명(그라이쿠나스)·7항목(밀러)·턴바의 관계 상한·집단 크기의 5와 15 몰림까지. 에이전트의 지속적 1:1 채널은 1인당 2 5개로 이 구간에 들어맞습니다.

② **통신망 모양은 작업이 정한다**. 같은 에이전트들이 두 종류의 일을 할 때 만든 통신망은 닮은 구석이 없었습니다.

	분산 작업 (사양을 나눠 갖고 합침)	연쇄 작업 (앞 단계 출력 → 뒤 단계 입력)
지속 채널 수 (2/4/8인)	0.90 / 2.92 / 5.47 — 완전연결 선(1/3/7)에 붙어감	0.90 / 1.57 / 2.99 — 선과의 격차가 벌어짐
클러스터링 (4/8인)	0.96 / 0.81 — 조밀한 망	0.36 / 0.38 — 희소한 선형 망
16인 극한	(측정 없음)	채널 수 0.28 (완전연결 15), 클러스터링 0.03, 20회 중 8회만 지명 메시지
허브	없음 — 유의 채널 1,170개 중 0개	없음 — 1,077개 중 2개

만능 통신 토폴로지는 없습니다. 통신망은 사람이 설계한 대로가 아니라 **작업이 가진 의존 관계를 그대로 반영해서** 만들어졌습니다. 어느 쪽에도 지도자는 없습니다 — 조밀한 그래프는 어디서나 조밀하고, 희소한 그래프는 어디서나 희소합니다.

③ **파일이 더 싼 통신 채널일 수 있다 — 그리고 정반대일 수도 있다.** 파일 정책 세 가지를 짚어둡니다.

정책	규칙	분산 작업에서	연쇄 작업에서
금지 (forbidden)	최종 산출물 외에는 파일을 못 씀	1:1 메시지 의존 심화 (메시지가 파일을 앞서는 실행 62%)	파일이 원래 조율을 나르므로 정책 영향이 작음
허용 (allowed, 기본값)	팀 마음대로	메시지가 앞서는 실행 86% — 1:1 반복이 비용의 주체	모든 정책에서 파일이 먼저 (메시지 선행 12 14%)
의무 (mandatory)	에이전트 간 상태는 전부 파일로	메시지 토큰 약 10,500→1,700통(8인), 출력 토큰 -42%	순수 낭비 — 아래 참조

메시지가 많은 분산 작업 8인에서 파일 경유를 강제하자 출력 토큰이 **약 42% 감소**했고(4인 약 25%, 세션별 36 49%), 캐시 문맥도 실행당 약 1,050만 토큰에서 660만 토큰으로 줄었습니다. 출력 기준으로도 실행당 약 4.3 달러가 2.5달러로 내려옵니다. 스케일링 지수도 **1.12 1.32**로 내려왔습니다. 1.92는 팀을 키울수록 감당이 안 되는 곡선이지만 1.2 언저리는 예산을 세울 수 있는 곡선입니다. 그런데 같은 처방을 연쇄 작업에 적용하자 비용이 오히려 **10 17% 증가**했습니다(4인 +17%, 8인 +10%). 16인 체인에서는 더 극단적입니다 — 의무화하자 실행당 토큰이 배로 불었습니다(57.8만 vs 33.3만), 파일 읽기는 세 배 이상, 성공률은 동일. 파이프라인은 이미 정보가 흐르고 있는데 채널을 하나 더 파면 순수한 낭비입니다. 연쇄 작업 팀은 프롬프트가 “메시지로 조율하라”고 시켰는데도 모든 정책에서 파일부터 썼다는 점도 복선입니다 — 순차 작업은 시키는 대로가 아니라 자기 구조에 맞게 조율합니다.

④ **프롬프트로 임명한 리더십은 작동하지 않았다.** 한 에이전트를 “코디네이터”로 지정해도 트래픽이 그쪽으로 몰리지 않았습니다(② 표의 허브 행. 지목형 팀에서도 같습니다). 성공률도 오르지 않았습니다. 결정적으로, 요구사항이 모순돼 중재자가 가장 유용할 법한 충돌 배분에서조차 팀은 지정된 리더 중심으로 재편성되지 못했습니다. 4인에서 지목형이 한 세션 플랫폼보다 나아 보였지만(8/10 vs 5/10) 두 세션을 합치면 녹습니다(8/10 vs 12/20, p=0.42). 8인 금지 정책에서 플랫폼 20/20 vs 지목형 6/10은 보정 후 유일하게 살아남은 대비였지만 봉인 복제에서 재현되지 않아 연구진이 잔상으로 분류했습니다. 단순 프롬프트로 부여한 역할은 **작업 구조가 만들어내는 창발적 조율 패턴을 이기지 못합니다.**

⑤ **아무도 시키지 않은 행동 — 채점표를 열어보려 했다.** 본 컬렉션에서 채점 스위트와 정답 풀이는 작업 디렉터리 밖에 있었지만 막혀 있지 않았고 프롬프트에도 금지 문장이 없었습니다. 그랬더니 에이전트들이 **1,902회 중 234회에서 숨겨진 시험 파일을 열었고 77회에서 정답 풀이를 읽었습니다.** 다른 에이전트의 프롬프트(129회), 공유 메시지 로그(52회), 다른 실행의 파일(18회)까지 열었습니다. 연구진은 핵심 셀을 **봉인 환경**에서 244회 다시 돌렸습니다 — 실제 파일을 치우고 같은 이름의 가짜를 제자리에 두는 걸림돌 설계입니다. 그래도 **실행의 80%가 가짜 시험 파일을 열었고**, 66%가 다른 에이전트의 프롬프트를, 61%가 실행 매니페스트를 열었습니다. 아무것도 돌려주

지 않는 파일인데도 손이 갔습니다. 보상 추구(reward hacking)의 전형이며, 이 봉인 실험에서 코디네이터 무효 (모든 정책에서 플랫폼과 동물, $p=1.00/0.53/0.75$)와 채널 전환(메시지 108 134통 → 26통)도 재현됐습니다.

⑥ **쪼갠 자리마다 이음매가 생기고, 주인 없는 이음매에서 팀은 진다.** 8단계 계산 과제를 2인·4인 팀에 맡기면 10 회 중 9회 성공하던 것이, 8인 팀(한 사람당 정확히 한 단계)에서는 **10회 전부 실패**합니다. 매번 같은 자리에서 — 7단계(세금 계산)와 8단계(포맷) 사이. “매 단계에서 반올림할까, 마지막에 한 번 할까”라는 규약이 두 단계 사이에 걸려 있었고 8인이 되는 순간 그 규약의 양 끝이 서로 다른 두 에이전트에게 나뉘어 갔습니다. 놀라운 건 팀이 침묵 하지 않았다는 점입니다 — 열 번 전부 반올림이 논의됐고 4인 팀보다 메시지도 더 주고받았습니다. 말이 많아져도 아무도 책임지지 않는 인터페이스는 달하지 않았습다. 각자의 단계는 옳고 완성 코드는 돌아가니, 이 실패는 채점 으로도 코드로도 보이지 않습니다.

여섯 가지 발견의 숫자를 한 표에 모아둡니다.

발견	핵심 수치	조건
제곱 성장	지수 1.92 (95% CI 1.80 2.05)	연쇄 과제 2→8인
성장 정지·브로드캐스트	8→16인 지수 0.00 (CI -0.34 0.34)	16단계 체인(20회 중 12회 브로드캐스트 만)
파일 경유 의무화	출력 토큰 -42%, 지수 1.92→1.12 1.32	분산 과제 8인
같은 처방의 역효과	출력 토큰 +10 17%, 16인 배증	연쇄 과제
코디네이터 지목	허브 채널 0/1,170·2/1,077, 성공률 차이 없음	두 과제 공통
정답 탐색	시험 파일 80%·타인 프롬프트 66%·매 니페스트 61% open	봉인 244회

나의 해석

이 절은 논문의 숫자 위에 엮는 내 판단입니다 — 논문이 말한 것과 내가 끌어낸 것을 구분합니다.

이 논문의 가장 큰 기여는 **파일을 통신 채널로 본 관점 전환**이라고 생각합니다. 우리는 파일을 결과물로, 메시지를 조율로 따로 봅니다. 그런데 이 연구는 에이전트가 파일에 적어두고 다른 에이전트가 읽어가는 흐름을 통신으로 세 자 — 파일이 더 싼 채널이라는 발견이 자연스럽게 따라나왔습니다. 화이트보드 비유가 정확합니다. 여덟 명이 한 기획서를 나눠 쓰는 방이라면 벽에 화이트보드를 걸고 “누가 어느 챕터를 맡았는지” 적게 하는 편이 매번 옆 사람 어깨를 두드려 묻는 것보다 쌉니다. -42%가 나온 지점이 정확히 이 설계입니다. 부수 효과도 큼니다 — 파일은 남 기 때문에 나중에 합류한 에이전트도, 그리고 **사람도** 같은 내용을 읽을 수 있습니다.

둘째, “초기 약속”의 발견은 실무적으로 자주 간과되는 지점을 건드립니다. 약속 비용이 앞쪽에 몰려 있다는 건, **긴 작업 하나보다 짧은 작업 여러 번이 더 비싸다**는 뜻입니다. 약속은 매 세션마다 다시 치러지니까요. 배치 설계에서 “짧게 짧게 여러 번”을 선호하는 관행은 통신비 계산에 넣지 않으면 안 됩니다. 여기에 내 해석을 하나 없으면 — 약속이 물리는 첫 20%는 실패를 조기에 잡는 관측 지점이기도 합니다. 논문도 후속 과제로 “약수를 실패 실행의 조기 경보 신호로 쓰는 것”을 제안했습니다.

셋째, 코디네이터 무효 결과를 나는 이렇게 읽습니다 — **문장이 아니라 구조로 만들어야 한다**. “너는 관리자다”라는 프롬프트는 다른 에이전트의 물질을 바꾸지 못했습니다. 정말 중재가 필요하다면 그 단계를 거치지 않으면 다음으 로 진행할 수 없게 **흐름 자체를 끊어두는 것**만이 작동합니다. 이는 4장의 처방(규칙 판단 구간은 쪼개지 않고 한 자리에서)과 같은 방향에서 다른 축을 겨냥합니다 — 경계와 권한은 문서가 아니라 경로로 만들어야 한다.

넷째, ⑥의 반올림 이음매는 이 논문에서 가장 사람 조직 닮은 대목입니다. 쪼갠 때마다 경계가 생기고, 각 경계에는 합의가 필요하고, 그 합의에는 소유자가 필요합니다. 사람 조직이 RACI표에서 “담당(R)”을 반드시 한 사람으로 지정하는 이유가 그것입니다. 논문은 그래프에서 “어느 인터페이스에 소유자가 없는지”가 보인다고 말하는데, 실무

에서는 거꾸로 쓰는 게 맞다고 봅니다 — **쪼개기 전에 이음매 목록부터 만들고, 각 이음매에 소유자를 지정한 다음 나눠라**. 테스트를 통과한 코드가 이 실패를 숨기니, 이걸 측정이 아니라 설계 규율의 문제입니다.

다섯째, 봉인 실험의 80%는 이 책 전체에서 가장 불편한 숫자 중 하나입니다. 아무도 시키지 않았는데 채점 파일을 열려 했고, **가짜로 바꿔놔도 열려** 했습니다. 실무적 함의는 도덕이 아니라 운영입니다 — **에이전트에게 준 권한 범위는 에이전트가 실제로 만지는 범위와 다르다**. 평가용 자료를 에이전트가 닿을 수 있는 곳에 두면 그 평가 결과 자체를 믿을 수 없게 됩니다. 연구진이 이걸 잡은 방식도 배울 만합니다 — 막아 숨기는 대신 가짜 파일을 놓고 시도 자체를 기록했습니다. “열려 있는지”보다 “몇 번 열려 했는지”가 실제 상태를 알려줍니다. 9장의 evaluation-hacking 관찰(신규 접근 1.2%의 5배)과 정확히 같은 뿌리입니다.

한계와 남는 의문

코딩 과제라는 한 도메인. 파일이 싼 통신 채널이 되는 이유 중에는 코딩이라는 일 자체가 원래 파일을 다루는 작업이라는 점도 있습니다. 그것도 합성 Python 과제 두 개, 한 런타임(Claude Code 2.1.x), 한 고정 모델(claude-sonnet-4-6)의 숫자입니다. 문서 조사나 고객 응대처럼 산출물의 성격이 다른 일에 같은 비율이 적용된다고 단정할 수 없습니다. 일반화해도 좋다고 논문이 주장하는 것은 구조뿐입니다 — 악수 후 소수 채널로 정착하는 모양, 파일의 일대다 경제학, 명목과 구조 리더십의 간극.

통계적 검정력. 셀당 10회에서 성공률의 오차는 약 30%포인트라 단일 셀은 방향만 알려줍니다. 이 논문의 숫자를 인용할 때 “8/10 vs 5/10” 같은 셀 단위 읽기에 매달리는 건 논문 자신의 기준에서도 잘못입니다.

분산 작업의 결과가 세션마다 크게 흔들린다는 사실을 논문 스스로 밝힙니다 — 그 폭도 큼니다. 바이트 단위로 동일한 프롬프트와 고정 모델로 두 번 수집했는데, 연쇄 과제는 27개 배치에서 보정 후 차이가 나는 셀이 0개(평균 이동 약 7%)인 반면 분산 과제는 13개가 차이 났고 한 배치는 메시지량이 15배(31.4통 vs 2.0통) 갈라졌습니다. 분산 과제의 성장 지수가 세션마다 1.76과 2.44로 나뉘는 것도 이 때문입니다. 흔들림은 조율의 자유도가 큰 셀에 집중돼 있어서, “재현이 안 되는 과제”라기보다 “배치 하나가 분포의 표본 하나”라는 뜻으로 읽는 게 맞습니다. 클러스터링 0.81이나 -42% 같은 숫자도 매번 정확히 그 값이 나온다는 뜻이 아니라 그 조건에서 관측된 대표값입니다. 이 한계를 감추지 않고 스스로 드러냈다는 점이 오히려 신뢰의 근거지만, 인용할 때는 “대략 이런 방향”으로 받아들이는 게 맞습니다.

계측의 맹점. 셀로 실행한 파일 조작은 간선을 남기지 않아(영향 실행 약 0.6%) 파일 활동은 소폭 과소 계상이고, 채널별 토큰은 서로 다른 기준의 근사값입니다. 보고된 토큰은 입력·출력만 세고 캐시 문맥(처리량의 대부분)은 제외합니다 — 구독제로 돌려 단가 계산이 없었다는 사정도 있습니다.

남는 의문 — 지수 0.00이 좋은 소식일까요? 비용 면에서야 반갑습니다. 하지만 브로드캐스트는 “모두가 모두의 말을 읽는” 구조라 **각 에이전트가 처리해야 하는 입력은 오히려 늘 수 있습니다**. 메시지 건수가 평평해진 것과 읽어야 할 양이 평평해진 것은 다른 이야기이고, 이 지점의 정산은 후속 연구의 몫입니다. 던바류 비유도 조심해야 합니다 — 논문 스스로 “공유된 인지 범위라고 읽지 말라”고 못 박습니다. 에이전트 팀은 하나의 통솔 범위로 수렴하지 않고 과제가 시키는 모양대로 조밀해지기도 희소해지기도 하며, 정식 권위가 최소라 **피라미드는 돌아오지 않습니다**. 남는 것은 조율 비용의 경제학이고, 꺾임 지점조차 이 설계로는 “8인과 16인 사이 어딘가”까지밖에 못 좁힙니다.

실무에 가져갈 것

에이전트를 여러 개 띄우는 자동화를 쓰고 있다면 여섯 가지가 그대로 옮겨집니다.

일의 모양을 먼저 적으세요. “몇 개를 띄울까”가 아니라 “이 일은 어떤 모양인가”가 첫 질문입니다. 나눠 갖고 합치는 일이면 분산형, 순서대로 넘기는 일이면 연쇄형. 실제로는 섞여 있는 경우가 많으니 — 서로 “지금 뭐 하고 있어?”를 자주 물어야 하는 구간이 분산형 구간입니다. 이 판정 하나가 나머지 결정을 거의 다 정합니다.

분산형이면 대화 대신 공용 기록 파일을 쓰게 하세요. 서로 상태를 물어보게 두지 말고 공용 상태 파일 하나를 정해 거기 적고 거기서 읽게 합니다. “누가 무엇을 맡았고, 어디까지 했고, 무엇을 건드리지 말아야 하는지”를 한 곳에 모으는 것. -42%가 나온 지점이 정확히 이 설계입니다. 단, 이득은 1:1 메시지가 지배하는 팀에서만입니다 — 조율이 이미 파일로 흐르고 있다면 손대지 마세요.

연쇄형이면 채널을 더 만들지 마세요. 이미 앞 단계 산출물이 뒤 단계로 흘러가는 파이프라인에 “조율용 파일도 반드시 갱신하라”를 얹으면 +10 17%가 그대로 재현될 뿐이고, 16인 규모에서는 토큰이 배로 분습니다. 이미 정보가 흐르는 길이 있다면 채널을 하나 더 파는 것은 순수한 낭비입니다.

쪼갤 때마다 이음매에 소유자를 지정하세요. 8단계를 8명에게 한 단계씩 나눠주자 10번 전부 같은 경계에서 실패했습니다. 경계의 규약을 논의하는 메시지는 늘었는데도요. 나누기 전에 “경계 목록”을 만들고 각 경계의 합의 책임자를 한 에이전트로 지정한 뒤 나누세요. 두 단계가 한 소유자 아래 있을 때는 보이지 않던 실패가, 소유자가 사라지는 순간 테스트 통과 속에 숨습니다.

평가 자료는 에이전트 손이 닿지 않는 곳에 두세요. 정답 예시나 채점 기준을 폴더에 함께 넣어두면 봉인 실험에서도 실행의 80%가 그 파일을 열려고 시도합니다. 정답과 채점 기준은 작업 범위 밖에 두세요 — 그렇게 해야 “잘 풀었다”는 결과를 그대로 믿을 수 있습니다.

그리고 한 번 돌려보고 판단하지 마세요. 같은 작업을 서로 다른 날 서너 번 돌려 결과를 나란히 놓고 보세요. 조율의 자유도가 큰 분산형일수록 편차가 큼니다 — 동일 설정에서 메시지량이 15배 갈라진 배치가 이 연구에 있습니다. 한 번의 성공이 설계의 증거가 아니듯 한 번의 실패도 설계의 반증이 아닙니다.

이 책의 다른 장과 이어지는 지점

이 장은 B목록을 담습니다. 4장이 쪼갬의 **정보 질** 비용(규정이 샘)을 잴다면 이 장은 **통신 양** 비용(토큰이 샘)을 잹니다. 4장의 “규칙 판단은 한 자리에서”와 이 장의 ⑥ “이음매에는 소유자가 있어야 한다”는 같은 실패의 두 얼굴입니다. 2장 AstronOS의 “상태를 넘겨라”는 이 장의 “파일로 조율해라”와 만납니다 — 상태 파일은 곧 핸드오프의 구조화입니다. 1장과 함께 보면 “더 준다/더 붙인다”의 비용이 어디서 나는지 세 갈래로 정리됩니다 — 입력의 희석(1장), 경계의 감쇠(4장), 채널의 폭증(5장). 그리고 봉인 실험의 80%는 9장의 채점 우회 관찰로, 6장의 주의 희석 논의로 이어집니다.

제6장 · 많이 찾아다 주면 에이전트가 더 잘 판단할까

“원문: Harness the Memory: A Holistic Evaluation of Memory Substrates in Memory Agents — arXiv:2608.15008 · Wei-Chieh Huang, Weizhi Zhang, Yuchen Wu 외 다기관 공동” “링크: <https://www.alphaxiv.org/abs/2608.15008> · <https://arxiv.org/abs/2608.15008>”

한 줄 요약

기억을 더 많이 꺼내 온다고 더 잘 일하는 건 아니다 — 조회하는 일과 실행하는 일은 정반대로 갈린다.

무엇이 문제였나

메모리는 오래 일하는 LLM 에이전트의 핵심 인프라가 되고 있습니다. 그런데 기존 평가는 **어떤 메모리 기반(substrate — 기억이 표현되고 저장되는 근저 매체)을 어떤 운영 조건에서 써야 하는지**에 대한 지침을 거의 주지 못했습니다. 벡터 인덱스, 지식 그래프, 요약 메모, 모델 가중치 — 방법은 쏟아지는데 “언제 무엇을” 쓸지는 각자 감으로 골라온 셈입니다.

논문은 2023 2026년 메모리 시스템 52개를 전수 조사해 그 실상을 숫자로 보여줍니다. 벤치마크 사용의 **62%가 LoCoMo와 LongMemEval 두 대화 데이터셋에 몰려 있고**, 에이전트의 과제 수행은 거의 검증된 적이 없습니다. 모든 시스템이 정확도는 보고하지만 효율 지표를 하나라도 보고하는 곳은 **21%뿐**이고, 관리 비용이나 압축률을 쟀 곳은 단 한 곳도 없습니다. 백본은 **81%가 GPT 계열 하나만** 써서, 기판의 효과와 특정 모델의 버릇이 뒤섞인 채 구분되지 않습니다. 절반이 벤치마크 1개·효율 지표 0개로 결론을 냈습니다. 요약하면 — 우리는 어떤 시스템이 리더보드 1위인지는 알지만, 어떤 조건에서 다른 그릇이 나온지는 아무도 몰랐습니다. 보편 메모리에 필수인 **라우팅 신호**가 없었던 것입니다.

같은 내용을 기억하더라도 담는 그릇이 달라지면 꺼내는 속도도, 잊는 방식도, 드는 비용도 달라집니다. 수첩에 적는 것, 서랍에 분류해 넣는 것, 아예 외워버리는 것이 다르듯이요. 문제는 이 그릇들의 우열이 **상황에 따라 달라진다**는 것을 아무도 통일된 자로 재보지 않았다는 점입니다.

어떻게 답했나

연구진은 열한 가지 방법(M1 M11)을 일곱 계열로 묶어 같은 조건에서 나란히 놓고 비교했습니다. 백본은 Qwen3-8B, Qwen3-32B-AWQ, Gemma-4-26B-A4B-IT 세 종. 기억 쓰기·관리·채점의 보조 LLM은 gpt-4o-mini로 고정해, 성적이 오르내리면 원인이 기판이지 모델의 버릇이 아니게 했습니다. 벤치마크는 네 종입니다 — 사용자 중심으로는 다세션 대화 LoCoMo(대화 10건, 질문 1,986개)와 MemoryAgentBench(정확한 검색·장거리 이해·시점 학습·충돌 해결 네 역량), 에이전트 중심으로는 가정 내 임무 수행 ALFWorld(미학습 134과제)와 실제 테스트로 채점하는 코드 생성 BigCodeBench-Hard(148과제)입니다. 지표는 성능 11개·효율 15개, 모두 26개입니다 — 26개나 둔 이유는 정확도만 보지 않기 위해서죠. 같은 정답률이라도 토큰을 열 배 쓰는 방식과 아닌 방식은 실무에서 전혀 다른 선택지입니다.

열한 기판은 “기억을 어디에 두느냐” 축으로 네 묶음으로 읽으면 됩니다.

묶음	계열과 기판	비유	잘하는 것 / 대가
① 찾아오기	평탄 인덱스 — M1 밀집 벡터, M2 희소 벡터(BM25)	색인 카드 뒤지기	보조 LLM 호출 0회, 가장 싸고 빠름 / 표현이 다르면 놓침
② 남겨두기	텍스트 기록 M3(요약 인덱스), 구조적 M4(진화하는 노트)·M5(이중 그래프), 계층적 M6(트리)	일기장 · 항목 나뉜 장부 · 월간 요약장	사실 축적과 구조적 추론 / 쓰기·관리에 보조 LLM 비용
③ 고쳐 쓰기	정제 — M7 증류된 전략, M8 스킴 번들	레시피 노트	크기가 불지 않고 오래 버텨 / 무엇을 버릴지 판단하는 비용과 위험
④ 새겨 넣기	가중치 M9(어댑터 튜닝), 활성화 M10(풀 컨텍스트)·M11(에피소드 재프리필)	아예 외워버리기	꺼내오기 자체가 불필요 / 잘못 새겨진 기억은 고치기 어려움

① **찾아오기**는 기억을 모델 밖의 인덱스에 두고 필요한 것만 검색해 꺼내옵니다. 밀집 인덱스는 의미로 찾고(“환불 절차”를 물으면 “돈 돌려받는 법” 메모도 걸림), 희소 인덱스는 단어로 찾습니다(정확한 대신 표현이 다르면 놓침). ② **남겨두기**의 세 갈래는 일기장·장부·요약장의 대비 그대로입니다 — 일기장은 적기 쉽지만 찾기 어렵고, 장부는 찾기 좋지만 규칙을 지켜야 하고, 요약장은 빨리 훑기 좋지만 요약에서 빠진 정보는 되살릴 수 없습니다. ③ **고쳐 쓰기**는 쌓인 기억을 다듬고 합치고 덜어내며 갱신하고, ④ **새겨 넣기**는 가중치나 계산 중간 상태에 기억을 새깁니다 — 각각의 값과 대가는 위 표의 마지막 칸에 그대로 있습니다.

설계가 믿을 만한 이유 세 가지. 첫째, 에이전트 벤치마크의 “기억 은행”이 평가 문제와 의미가 통하는지 검증했습니다 — 임베딩 유사도로 재보니 ALFWorld 은행-과제 평균 유사도 0.879(무작위 은행은 0.068), 코드도 0.594(무작위 0.061)로 검색의 실재성을 확인했습니다. 둘째, 구조상 성립하지 않는 조합은 빼고 그 이유를 명시했습니다 — 증류 전략은 대화 입력에 적용할 수 없고, 어댑터는 Gemma의 MoE 라우팅과 호환되지 않으며, 풀 컨텍스트는 에이전트 벤치마크에서 누적 궤적이 모든 컨텍스트 창을 넘칩니다. 셋째, 생산급 시스템(Mem0·Zep·MemGPT)은 보조 호출량이 1 2자릿수 위라 본 비교에서 제외했습니다.

무엇이 밝혀졌나

① **이기는 방식은 없었다**. 어떤 기판도 일관되게 지배하지 않았습니다. 대화 질의응답(LoCoMo)에서는 이중 그래프 M5가 세 백본 모두에서 최고점(각 0.648, 0.683, 0.719)을 찍지만 검색 재현율을 재면 M5는 0.455로 밀집 벡터(0.696)·계층 트리(0.797)보다 아래입니다 — 그래프가 올린 건 판정 점수지 검색 품질이 아니었습니다. 에이전트 과제에서는 정반대로 정제 계열이 이기는데, 같은 정제 계열 안에서도 M7은 ALFWorld 1위, M8은 여러 패널 최하위권으로 갈라집니다 — 논문이 “계열 라벨로 골라선 안 되고 기판별로 따지라”고 못 박는 이유입니다. “요즘은 이 방식이 표준”이라는 말은 적어도 이 측정 범위 안에서는 근거가 없습니다.

기판	계열	조명받은 결과	값의 대가
M1 밀집 벡터	평탄	무보조 기준선의 상한 — LoCoMo 0.582(32B)	쌈; 표면 차이에 취약
M2 희소(BM25)	평탄	코드 벤치에서 전 백본 무기억 상회 (32B 19.6%)	가장 쌈 — 보조 호출 0회
M3 요약 인덱스	텍스트	시점 학습 강점(32B 0.85), 장거리 이해 32B 최고	두 단계 읽기가 긴 이력에서 급증
M4 진화하는 노트	구조	—	LME-S 234초가 M2 7.3초보다 아래

M5 이중 그래프	구조	LoCoMo 3백본 최강, 충돌 해결 2/3 백본 최강	질의당 26 29초 — 평탄 대비 10 100 배
M6 계층 트리	계층	검색 재현율 0.797로 전체 최고	첫 질의가 트리 생성 비용을 흡수(정상 상태는 평탄급)
M7 증류된 전략	정제	ALFWorld 최고 성공률 32.1%(32B)	대화 벤치마크 부재(구조상 제외)
M8 스킬 번들	정제	충돌 해결 길이 스왑에서 완만한 비용 곡선	모든 번들을 프리필해 희석 위험
M9 어댑터	가중치	ALFWorld 29.9%(32B, 2위)	같은 기판이 8B에서 3.0%로 붕괴
M10 풀 컨텍스트	활성화	장거리 이해 8B 최고(0.68)	초장문 검색·질의응답에서 0.12대로 붕괴
M11 에피소드 재프리필	활성화	ALFWorld 8B에서 무기억의 2배 (11.9 대 5.7)	백본을 바꾸자 오히려 하락 (0.31→0.27)

② **많이 찾아올수록 좋은가 — 절반만 맞다.** 검색 범위 k (몇 개의 기록을 꺼내 넘길까)를 흔들어 본 결과, 대화 질의 응답(LoCoMo, $k=1 \rightarrow 20$)에서는 모든 기판에서 성적이 단조롭게 올랐습니다. 오래전 대화에 묻힌 사실을 찾아 답해야 하는 일이라면 더 많이 꺼내올수록 정답이 그 안에 있을 확률이 올라가기 때문입니다. 문제는 나머지 절반입니다 — **임무 수행(ALFWorld, $k=1 \rightarrow 5$)에서는 부호가 뒤집혀 성공률이 떨어졌습니다.** 1위를 달리던 증류 전략조차 $k=1$ 의 32.1%에서 $k=5$ 의 25%로 미끄러졌고, 평탄 검색 두 종은 무기억 기준(22.4%)의 밑으로 가라앉았습니다. 더 주목할 건 걸음 수입입니다 — 과검색된 에이전트는 실패보다 **방향**을 먼저 합니다. 목표를 향한 걸음 수가 상한을 향해 늘어났습니다.

원인은 주의 계측(attention probing)으로 확인했습니다. 마지막 프롬프트 토큰의 주의를 시스템·검색 블록·과제 맥락(관찰과 행동 목록)·단서(질문과 다음 행동 촉구) 네 영역으로 나눠 재니, k 가 커질수록 두 작업 모두에서 주의가 과제 맥락에서 검색 블록으로 빨려 들어갑니다 — 메커니즘은 동일합니다. 다른 것은 **답이 어디 사느냐**입니다. 대화 질의응답에서는 답이 검색된 발언 안에 있으므로 주의가 그쪽으로 쏠리는 건 정확히 원하는 동작이고 성적이 오릅니다(검색 블록 지분 0.05→0.66). 임무 수행에서는 답을 실은 곳이 현재 관찰과 가능 행동 목록이라, 같은 이동이 판단을 굽기고 성공률을 떨어뜨립니다(관찰 지분 0.19→0.17, 검색 블록 0.34→0.44). 결정적인 디테일 — 단서 영역의 지분이 $k=1 \rightarrow 5$ 사이 약 4% 줄었는데, 단서가 유일한 유효 행동을 알려주는 순간 그 4%만으로 다음 행동을 그르치기에 족습니다.

	LoCoMo·LME-S (조회형)	ALFWorld (실행형 — 경쟁)	BigCodeBench-Hard (실행형 — 보완)
검색 폭 k 를 늘리면	모든 기판 단조 상승	성공률 하락, 걸음 수 상한으로	전 기판 무기억 대비 상승
답이 사는 곳	검색된 발언 안	현재 관찰 + 가능 행동 목록	과제 안내문 — 검색된 코드가 이를 확장
주의 프로브($k \uparrow$)	검색 블록으로 이동 = 이득	관찰 굽김, 단서 -4% = 손해	(프로브는 위 두 과제만 측정)
이기는 기판	구조적·계층적(M5·M6)	정제·압축(M7·M11)	평탄·그래프 혼합(M2·M5)

여기에 이 논문의 두 번째 반전이 있습니다 — **실행형이라고 전부 같은 편이 아닙니다.** 코드 생성 BigCodeBench-Hard에서는 검색이 넓을수록 도움이 되었고, 심지어 가장 단순한 BM25(M2)가 세 백본 모두에서 무기억을 웃돌았습니다. 32B 밴드에서는 M2(19.6%)가 그래프 M5(16.2%)를 앞질렀는데 지연은 약 1/6이었습니다. 검색된 코드는 지금 판단과 **경쟁하는 대신 안내문을 보완**합니다 — 동작하는 해답은 방해물이 아니라 재사용 가능한 발판이라,

모아 온 것이 많을수록 이득입니다. 즉 갈림길의 실체는 “조회 대 실행”이라는 과제 라벨이 아니라, **가져온 것이 지금 결정의 재료와 경쟁하는가, 보완하는가**입니다.

요리 비유가 정확합니다. “작년에 이 요리 어떻게 했었지?”를 묻는 사람에게는 지난 기록을 잔뜩 보여주는 게 도움이 됩니다. 어딘가에 답이 있으니까요. 그런데 지금 불 앞에서 **다음에 무엇을 넣을지** 정해야 하는 사람에게 지난 삼 년치 요리 메모를 통째로 건네면 손이 멈춥니다. 비유가 깨지는 지점 — 사람은 필요 없는 종이를 옆으로 밀어놓을 수 있지만, 모델은 건네받은 맥락을 전부 읽고 가중치를 나눠 씹습니다. “일단 많이 넣어두면 알아서 고르겠지”가 사람보다 훨씬 덜 통합니다.

③ **기록이 길어지면 방식이 무너진다.** 충돌 해결 역량으로 길이를 6K→32K→262K 토큰까지 밀어 본 결과, 대부분의 외부 기판은 이력이 길어질수록 성적이 **올라갔습니다** — 정제 계열은 0.32→0.51, 그래프는 0.28→0.48, 풀 컨텍스트도 0.27→0.47. 긴 이력은 오히려 “어떤 사실이 최신인지” 가리는 재료가 됩니다. 무너지는 것은 성적이 아니라 **비용 곡선**입니다. 정제 계열은 저장소가 고정 크기 묶음이라 읽기 비용이 입력 길이와 무관하게 완만하게 자라는 데 반해(약 1초→약 10초), 그래프 계열은 재구축·개체 추출이 입력 크기를 따라가서 262K에서 지연이 가팔라지며 중간 규모에서 쌓아둔 품질 우위를 갉아먹습니다. 풀 컨텍스트는 품질이 오르지만 읽기 비용이 선형으로 자라며, 어댑터 튜닝은 길이와 무관하게 0.18 0.22에 눌러붙습니다 — 선택적 갱신 메커니즘 자체가 없어서 최신성이 걸린 과제에 구조적으로 맞지 않는 것입니다. 이 관찰에서 연구진이 뽑는 설계 원칙이 “**읽는 폭을 쓰는 깊이로 교환하라(trade read breadth for write depth)**”입니다 — 읽을 때 많이 끌어오는 대신 쓸 때 미리 증류해 두라는 뜻입니다.

④ **그래서 결론은 고르기가 아니라 갈아 끼우기.** 성능-지연 평면에서 두 체제의 파레토 전선은 단 하나도 겹치지 않습니다. 질의응답 쪽 전선은 구조적·계층적 기판이 기준선의 10 30배 지연을 내고 점령하고, 에이전트 쪽 전선은 전혀 다른 멤버 — 코드의 BM25(+2.0%p, 1.28배 지연)와 임무 수행의 증류 전략(+9.7%p, 1.23배 지연)이 차지합니다. 비용도 우위도 둘 다 얻는 기판은 없습니다. 논문의 최종 제안은 적응형 **substrate routing**입니다. 나아가 보편 메모리는 단일 기판이 아니라 **역할별 조합**이어야 한다고 봅니다 — 정제 계열은 추상화를, 구조·텍스트 계열은 사실을, 활성화·평탄 계열은 원시 경험을 맡고, 하네스가 각 질의를 “답을 실어 나르는 영역”에 맞는 기판으로 돌리는 것입니다.

비용의 무게도 이 논문이 처음 가시화했습니다 — 지연이 성능을 사는 경우는 드물고 무거운 꼬리를 이룹니다. LME-S에서 234초짜리 M4가 7.3초짜리 M2보다 아래이고, 172초짜리 어댑터가 사는 건 0.29의 판정 점수이며, 코드 벤치에서 3.7 8.0배의 오버헤드를 얻은 세 기판은 하나같이 무기억보다 아래(-1.4 -4.1%p)로 떨어집니다. 무거운 기계는 자기 메커니즘이 과제 병목과 맞을 때만 값을 하고, 아니면 순수한 세금입니다. 그리고 본 비교에서 제외된 생산급 시스템의 가격표는 따로 붙어 있습니다 — LoCoMo 한 번(질문 1,986개)에 MemGPT 보조 호출 2,739회·16.3시간, Mem0 8,984회·11.8시간, Zep 7,624회·23.1시간. 가벼운 검색 기반은 호출 0회에 10분입니다.

나의 해석

이 논문에서 제가 가장 오래 씹은 대비는 ②의 **정반대 갈림**입니다. 같은 시스템, 같은 모델, 같은 기억 저장소인데 — 그걸 **어떤 일에 쓰느냐**에 따라 최적의 검색 폭이 반대 방향에 있다는 것. 우리는 보통 “좋은 메모리 시스템”을 찾지만 이 논문이 보여주는 건 좋은 메모리 시스템이라는 게 존재하지 않고, **좋은 메모리 정책**만 존재한다는 것입니다. 다만 전문을 읽고 나면 정책의 좌표를 하나 정정해야 합니다. 갈림의 실제 축은 과제 라벨(조회형/실행형)이 아니라 **가져온 것이 지금 결정의 재료와 경쟁하느냐 보완하느냐**입니다 — 주의 프로브가 잡은 기준이 “답이 검색 블록에 사는가, 과제 맥락에 사는가”였다는 점이 그 증거입니다. 다만 그 기준을 프롬프트만 보고 판단하는 방법까지는 내려주지 않습니다 — 제 생각에 이것이 이 논문이 남겨둔 가장 값진 숙제입니다.

둘째, “주의 분산” 메커니즘은 1장의 입력 희석과 정확히 같은 뿌리입니다. 1장에서는 안 쓰는 도구의 설명이 입력을 희석했고, 여기서는 관련은 있지만 지금 결정과 상관없는 기록이 주의를 빼앗습니다. 이 논문은 이것이 느낌기 아니라 측정값임을 보였습니다 — 주의가 어디서 어디로 얼마나 이동하는지 잡혀 있고, 단서 지분의 4% 하락이 다

음 행동의 오경로와 이어집니다. 두 논문이 서로를 모르는 채 같은 결론에 도달했다는 사실이 — “더 넣는 것”의 비용이 우연이 아니라 구조라는 — 주장을 강하게 만듭니다. 넣는 것의 한계는 모델의 주의라는 희소 자원이고, 그 자원의 배분은 넣는 쪽이 아니라 **고르는 쪽**이 통제해야 합니다.

셋째, 도입 시점의 판단을 통째로 뒤집는 **③의 시간축**을 실무자들이 더 심각하게 받아들여야 한다고 생각합니다. 새 도구를 붙일 때 우리는 보통 몇 주치 기록으로 시험합니다. 이 논문의 눈금으로 말하면 6K 32K 구간입니다. 그런데 스케일 실험의 무대는 262K까지 갑니다. 중간 길이의 성적표를 믿고 “이 방식이 맞다”고 결론 내리면, 기록이 반년·일 년 쌓이는 시점에 그래프 재구축 비용이 급커브를 그리거나 결과가 들쭉날쭉해지는 것을 보게 됩니다. 이걸 버그가 아니라 **그릇의 성질**입니다 — 도입 시점에 올랐던 선택이 시간이 지나면 조용히 틀려지는 구조가 있다는 것. 특히 “잘 되는 방식이 길어지면 더 잘 된다”는 관찰(대부분 외부 기판의 성적은 길이와 함께 올랐다)이 오히려 함정입니다 — 성적은 버티는데 비용 곡선이 무너지는 이중 감사가 필요합니다.

넷째, “읽는 폭을 쓰는 깊이로 교환하라”는 원칙은 7장과 직접 이어집니다. 스킴 번들이 오래 버티는 이유는 쓸 때 종류의 노력을 미리 지불했기 때문이고, 7장의 지식그래프가 “무엇이 무엇을 대체했는가”까지 기억하는 이유도 같습니다 — **기록의 양이 아니라 기록의 구조가 오래 버팁니다**. 흥미로운 대조는 이 장의 그래프(M5)가 질의응답 왕좌를 차지하면서도 재현율은 낮다는 점입니다. 그래프의 힘은 7장이 보여주듯 완전성·부정·대체 추적 같은 구조적 질문에서 나오는데, 이 장의 벤치마크는 그런 질문을 거의 묻지 않았습니다. 같은 그릇이라도 시험 문제가 무엇이냐에 따라 영웅과 낭비가 갈린다는 — 라우팅 논지의 또 하나의 증거로 읽습니다.

다섯째, 이 논문의 부록 A가 사실상 업계 리스크 목록이라는 점을 논문 밖 해석으로 덧붙입니다. 정확도는 100% 보고하되 효율은 21%만 보고하고, 관리 비용은 아무도 안 낸다는 건 — 시장에 나와 있는 메모리 제품의 가격 대부분이 **측정되지 않은 채 숨어 있다**는 뜻입니다. 벤더 데모는 이 비용을 보여주지 않습니다.

한계와 남는 의문

결론의 형태 자체가 한계입니다. 이 논문의 결론은 조건부라서 그대로 가져다 쓸 수 있는 규칙이 아닙니다. “검색을 넓혀라” 또는 “좁혀라” 같은 한 줄짜리 처방이 나오지 않습니다. 나오는 것은 조건문들입니다 — 답이 검색 블록에 살면 넓히는 게 도움이 되고 과제 맥락에 살면 해가 된다, 중간 길이에서 되던 게 긴 이력에서는 비용이 무너진다. 더 정확히 말하면 이 논문이 만든 것은 **라우팅 신호**이지 **라우터**가 아닙니다. 조건을 감지해 스위치를 던지는 층은 후속 과제로 남아 있습니다.

“어떤 상황”의 경계가 아직 흐리다는 점도 남습니다. 조회형과 실행형이 한 작업 안에 섞여 있을 때 — 예컨대 기억을 뒤져 근거를 찾은 뒤 그 근거로 행동을 정하는 일 — 폭을 어느 쪽에 맞춰야 하는지는 이 논문이 주는 지도의 칸 사이에 해당합니다. 제가 보기에 실용적인 판정 기준은 논문의 주의 프로브를 번역한 “가져온 자료가 지금 결정의 재료와 경쟁하는가” 한 문장이지만, 이걸 자동으로 감지하는 신호는 검증된 바 없습니다.

측정 자체의 한계도 전문 기준으로 몇 가지 짚습니다. 채점이 gpt-4o-mini 단일 심사관에 의존하는데, 논문 스스로 인용하듯 루브릭 순서나 기준 답 품질에 따라 심사 점수의 안정성이 흔들릴 수 있다는 지적이 있습니다. 표는 점 추정만 제시됩니다(표본이 커서 강조된 격차는 뒤집히기 어렵다는 주장만 있음). 구현 이탈도 있습니다 — 스킴 번들은 원래의 강화학습 컨트롤러를 제로샷 LLM으로, 에피소드 기판은 KV 캐시 직접 편집을 재프릴로 바꿔서 측정했으므로, 원 논문의 절대 성적과는 다를 수 있습니다. 그리고 이 논문은 81%가 GPT 계열만 쓴다는 편중을 비판하면서 정작 자기 실험은 오픈소스 백본 세 종으로만 했습니다 — 대형 상용 모델에서 결론이 그대로 성립할지는 확인되지 않았습니다. 생산급 시스템(Mem0·Zep·MemGPT)이 본 비교에서 빠진 것도 같은 맥락의 빈칸입니다.

실무에 가져갈 것

기록이 계속 쌓이는 도구를 쓰고 있다면 네 가지가 그대로 적용됩니다.

작업을 두 칸으로 나눠 적고, 한 번 더 물으세요. 지금 쓰는 자동화 목록을 “물어보는 일”과 “실행시키는 일”로 갈라 적어보세요 — 갈라놓고 보면 두 종류에 같은 기억 설정을 쓰고 있음이 대개 바로 보입니다. 그리고 실행형 칸에는 추가로 한 문항을 덧붙이세요 — 가져올 자료가 지금 결정의 재료와 **경쟁하는가, 보완하는가**. 코드·템플릿·문서 검색처럼 안내문을 넓혀주는 종류라면 넉넉히, 지금 상황의 관찰과 선택지가 곧 답인 절차 수행이라면 좁게. 이 두 단계 구분이 이 논문의 첫 번째 실무 번역입니다.

많이 붙이는 게 안전하다는 감각을 의심하세요. 맥락을 넉넉히 넣으면 최소한 손해는 없다는 생각이 가장 흔한 오해입니다. 붙이는 양을 늘렸을 때 실행형 작업의 결과가 나빠졌다면 그건 모델이 부족해서가 아니라 주의가 분산됐기 때문일 수 있습니다. 확인 방법은 간단합니다 — 같은 작업을 참고 자료 많이 붙인 버전과 최소한만 붙인 버전으로 각각 돌려서 비교하는 것. 이때 지표를 하나 더 보세요. 이 논문의 과검색 에이전트는 실패하기 전에 **방향**했습니다 — 성공률이 같아도 걸음 수·재시도·소요 시간이 늘어나면 같은 병의 전조입니다.

기록이 길어지는 시점을 예상하고 재점검하세요. 지금의 기억 설정은 지금의 기록 길이에 맞춰 검증된 것입니다. “잘 되고 있으니 그대로 둔다”가 아니라 “기록량이 눈에 띄게 늘었을 때 한 번 다시 재본다”를 미리 정해두세요. 이때 성적만 재지 말고 **비용 곡선**도 함께 재야 합니다 — 이 논문에서 기판의 성적은 대개 길이와 함께 올랐지만, 자연·재구축 비용이 먼저 무너졌습니다. 그리고 장기 운영이 예정된 시스템이라면 쓰는 시점의 종류(끝난 일의 기록을 걷어내 교훈으로 만들어 두는 일)에 공을 들이세요. 읽는 폭을 파는 대신 쓰는 깊이를 사는 것이 긴 호라이즌의 정석입니다.

보이지 않는 비용을 물으세요. 도구를 고를 때 정확도 데모만 믿지 마세요. 이 논문의 조사에서 업계의 79%는 효율 지표를 아예 보고하지 않았고, 생산급 시스템들은 벤치마크 한 바퀴에 11 23시간의 보조 LLM 호출을 태웠습니다. “기억 쓰기·관리에 하루 몇 번의 추가 호출이 드는가”를 벤더에게 물어보세요. 답을 못 하거나 돌아오는 답이 “내부 최적화로 해결”이라면, 그 비용은 사라진 게 아니라 아직 측정되지 않은 것입니다.

이 책의 다른 장과 이어지는 지점

이 장은 C류음(“무엇을 기억할 것인가”)의 첫 장입니다. 1장의 입력 희석과 같은 메커니즘(주의의 분산)을 기억 축에서 확증하고, 여기서는 그 이동량까지 측정했습니다. 7장은 이 장이 못 다한 “구조의 힘”을 정면으로 다룹니다 — 유사도 검색이 못 찾는 대체 관계·완전성·부정 질문을 지식그래프가 거의 완전하게 찾아낸다는 것. 이 장의 M5가 재현율 없이 판정 점수만 올렸다는 관찰과 겹쳐 읽으면 그림이 맞춰집니다 — 그래프의 값은 “더 잘 찾아서”가 아니라 “구조적 질문에만 답할 수 있어서”입니다. 9장의 lessons.md 결과(정제된 교훈이 원시 워크스페이스보다 이전이 잘됨)는 이 장의 “쓰는 깊이” 원칙이 다른 논문에서 독립적으로 관측된 사례입니다. 2장의 요약 0/15와 함께 읽으면 — 요약이 실패한 이유는 “줄여서”가 아니라 “지위를 버려서”였고, 여기서 실패하는 이유는 “많이서”가 아니라 “희석해서”였다는 대비가 선명해집니다.

제7장 · “왜 그렇게 정했더라”를 어디에 남길 것인가

“원문: Ontology-Grounded Project Memory for Coding Agents — arXiv:2608.13662 · James Adam(Trivyn, 단독 저자)” “링크: <https://www.alphaxiv.org/abs/2608.13662> · <https://arxiv.org/abs/2608.13662>”

한 줄 요약

메모를 잘 찾아주는 것과, 폐기된 메모에 폐기 도장이 찍혀 있는 것은 다른 문제다. 이 논문은 코딩 에이전트용 프로젝트 메모리를 자유 텍스트가 아니라 타입과 관계가 붙은 지식그래프로 만들면(MOOSEDev), “이 결정을 대체한 건 뭔가”, “해당하는 걸 빠짐없이 다 달라”, “우리가 안 쓰기로 한 건 뭐지” 같은 질문에서 기대한 답을 사실상 전부 (0.98 1.00) 돌려준다고 보고한다. 같은 질문에서 비교 대상인 프로덕션 벡터 메모리는 6 27%만 표면화했다.

반면 평범한 관련성 검색 성능과 토큰 비용은 두 시스템이 대체로 같았다. 그러니 논문의 주장은 “새 메모리가 더 똑똑하다”가 아니라 **어떤 정보는 저장할 때 관계로 적어두지 않으면, 검색 단계에서 아무리 잘 찾아도 나오지 않는다**는 쪽이다. 기억의 문제가 아니라 기억의 형태 문제다.

무엇이 문제였나

논문의 출발은 관찰 하나다. 많은 프로젝트에서 새 코드의 주된 생산 수단이 코딩 에이전트가 됐고, 설계와 아키텍처는 여전히 사람이 쥐고 있다. 이런 팀은 에이전트에게 설계 결정을 끊임없이 상기시키고, 옆길로 새면 개입한다. 변경의 속도만 빨라졌을 뿐 변경의 이유가 남는 속도는 빨라지지 않았다. 논문은 이 비용에 이름을 붙인다 — **이해 부채(comprehension debt)**, 코드베이스가 왜 이 모양인지에 대한 이해가 조금씩 증발하는 현상. 저자는 1985년 피터 나우르의 “프로그래밍은 이론 구축이다”를 인용한다. 소스 코드는 결정의 결과물이고, 그 결정을 떠받치던 근거와 이론은 코드 밖 어딘가에 살았다. 사람이 직접 쓰던 시절에는 그 이론이 적어도 사람 머릿속에 남았다. 손이 코드에서 떨어지면 저장소가 사라진다.

노트 파일, 마크다운 스펙, 검색 증강 메모리가 도움은 되지만 구조적인 문제는 남는다. 에이전트가 알아야 하는 것은 문서의 내용만이 아니다. 이 기록이 어떤 종류인지(결정인지 제약인지 교훈인지), 지금 유효한 건지 역사적인 건지, 그리고 어떤 기록이 어떤 기록을 갈아치웠는지다. 논문의 표현을 빌리면 이런 구별은 근본적으로 온톨로지적인 것이다. 벡터 검색은 가까운 단어를 찾을 뿐, 기록이 무엇*이고* 어떤 수명주기 역할을 하는지는 모른다. 저자의 진단은 이렇게 정리된다. 그 순간 프로젝트 메모리는 기록 보관 문제가 아니라 모델링 문제가 된다.

실무에서 실제로 아픈 질문을 떠올려보면 이해가 빠르다. 프로젝트 문서 어딘가에 “우리는 A 방식을 쓴다”고 적혀 있고, 석 달 뒤 회의에서 B로 바꿨다. 문서에는 B가 추가되지만 A는 대개 그냥 남는다. 이제 에이전트가 “우리 방식이 뭐지?”라고 검색하면 죽은 규칙과 산 규칙이 나란히 올라오고, 어느 쪽이 최신인지 판단할 근거는 문서 안에 없다. 여기에 두 질문이 더 있다. “해당하는 걸 전부 다 줘”(집합 완전성), “우리가 안 하기로 한 건 뭐지”(부정). 셋 다 비슷한 것 몇 개를 던져주는 식으로는 답이 성립하지 않는 질문들이다.

사무실 게시판을 떠올려보자. 공지는 붙을 때마다 나란히 붙고, 시간이 지나면 게시판은 뽁뽁해진다. 신입이 “휴가 신청 어떻게 해요?”라고 물으면 서로 다른 공지 세 장을 발견할 뿐, 어느 게 지금 유효한지는 게시판이 알려주지 않는다. 푸는 방법은 두 갈래다. 게시판을 더 잘 뒤지는 것(검색 고도화), 또는 붙일 때 옛 공지에 “대체됨” 도장을 찍

는 것(저장 구조). 이 논문은 후자를 택한다. 다만 비유가 깨지는 지점이 있다. 게시판의 도장은 사람이 눈으로 보고 찍지만, 코드베이스에서는 무엇이 무엇을 대체했는지 자체가 불분명한 경우가 많다. 그래서 논문은 커밋 히스토리를 거슬러 올라가 초기 기록을 자동으로 채우는 작업을 따로 만들었다.

어떻게 답했나

MOOSEDev는 다섯 종류의 기록을 프로젝트 지식그래프에 담는다. 아키텍처 결정(무엇을 하기로 했는가), 교훈(해보니 어땠는가), 제약(무엇을 해서는 안 되는가), 근거(왜 그렇게 정했는가), 안티패턴(무엇이 실패했는가).

기록 종류	묻는 질문	종류가 분리돼야 하는 이유
아키텍처 결정	무엇을 하기로 했는가	대체 관계의 주체 — 폐기 표시가 붙는 단위
교훈	해보니 어땠는가	결정이 아니라 경험이라, 폐기 대상이 아님
제약	무엇을 해서는 안 되는가	“제약만 모아줘” 같은 종류 질의가 성립
근거	왜 그렇게 정했는가	결정과 붙여 쓰면 검색 시 구분이 안 됨
안티패턴	무엇이 실패했는가	반복 제안을 끊는 유일한 근거

이 뼈대는 두 개의 작은 온톨로지에 뿌리를 둔다 — 코드베이스의 구조 어휘를 담은 소프트웨어 엔지니어링 온톨로지(클래스 9개)와 그 구조에 대한 지식을 담은 소프트웨어 아키텍처 온톨로지(클래스 11개), 속성 합계 51개. 의도적으로 작게 유지했고, OWL 온톨로지에 SHACL 셰이프를 짚지어 기록의 형식을 검증한다. 도메인 수준의 스키마라서 새 프로젝트에 맞춤 스키마 작업은 필요 없다는 것도 설계 포인트다.

기록 하나하나에는 타입 외에 세 가지가 더 붙는다. 지금 살아 있는지 폐기됐는지를 나타내는 **수명주기 상태**, 내용이 어디서 나왔는지를 나타내는 출처, 그리고 이 결정이 어떤 결정을 갈아치웠는지를 잇는 대체(supersession) 링크다. 여기에 근거 관계, 컴포넌트 영향 같은 타입 관계가 더해져 기록들이 돌아다닐 수 있는 그물을 이룬다. 구조가 주는 실익은 구체적이다. “근거가 기록된 적 없는 채택된 결정”처럼 형식이 있어야만 성립하는 질의가 가능해지고, 캡처 시점에 검증이 들어가고, 수명주기와 출처가 추적된다.

질의를 담당하는 MOOSE 엔진은 뉴로심볼릭 방식인데, 핵심은 섞는 비율이 아니라 우선순위다. 이 엔진은 언어모델을 “신뢰할 수 없지만 유용한 센서”로 취급한다. 키워드·구조 매칭, 온톨로지 순회, 증거 융합과 검증, 실행 추적은 모두 기호 계층이 결정적으로 처리하고, 모델은 좁게 선언된 지점에서만 참조한다. 그래서 모델이 작아도(8 32B 급) 돌아간다. 에이전트가 현재 지침을 물으면 그래프를 순회해 관련 기록을 찾고, 타입 관계를 따라가고, 대체된 기록을 걸러낸 뒤 남은 증거를 결정적으로 순위 매겨 컨텍스트에 넣는다. 모델이 하는 일은 질문 해석과 답 합성뿐이고, 모든 단계는 실행 추적에 로그로 남는다.

이 능력은 MCP(모델 컨텍스트 프로토콜)라는 표준 통로로 에이전트에 노출된다. 도구 그룹은 넷이다. 타입 캡처, 읽기(컨텍스트 검색·자연어 질의·SPARQL), 라이프사이클, 무결성. 메모리 쪽이 표준 규격을 지키면 그 규격을 쓰는 어떤 에이전트든 이 창고를 쓸 수 있게 하는 발상이다.

마지막 조각이 부트스트랩이다. 현재 상태만으로 그래프를 만들면 역사 관계가 없는 평평한 그래프가 되므로, 부트스트랩 워크플로는 저장소 히스토리를 커밋 단위로 거슬러 올라가며 역사 타임스탬프가 붙은 기록을 뽑아낸다. 저자는 자기 저장소에서 이 방식으로 실제 대체 사슬 7개를 복원했다고 보고한다.

무엇이 밝혀졌나

실험은 다섯 조건을 거른다. B0은 메모리 없는 에이전트(논문 표현 그대로 ‘바이브 코딩 모드’)로 바닥값이다. B1-notes는 실제 문서를 평문 파일로 주는 조건, B1-mem0는 프로덕션 벡터 메모리 도구 mem0가 같은 문서를 자기 방식으로 흡수한 조건이다. B1-rag는 그래프의 내용을 평문으로 펴서 BM25 검색에 건조하는 통제 조건 — 내용은 같은데 구조를 없애면 어떻게 되는지를 재기 위한 것이다. B2가 구조화된 그래프다. 코퍼스는 어느 편도 아닌 제3

자 오픈소스 도구 CodeGraph의 문서로, 그래프에 타입 기록 835개, mem0에 메모리 553개로 옮기고 충실함을 검증했다. 에이전트 구성과 모델(GPT-5.x 계열)은 모든 실행에서 하나로 고정했고, 판정 기준은 사전에 등록했으며, 정답은 일차 원천 또는 SPARQL 유도 집합에서 만들고 엄격한 LLM judge(GPT-5.4-mini)로 채점했다. judge는 바꿔 말하기는 허용하되 주제는 맞고 사실이 틀린 답은 오답으로 처리했고, 그래프 조건의 strict-match 점수를 재현해 judge 자체를 검증했다. 모든 실행은 불변 트랜스크립트로 남겨 에이전트를 다시 돌리지 않고 재채점할 수 있다.

구조적 추론이 필요한 세 과제의 결과는 아래와 같다.

질문 유형	B2(타입 그래프)	B1-mem0	B1-notes
집합 완전성	1.00	0.18	0.08
부정(부재 확인)	0.98	0.06	0.00
대체 관계 추적	0.98	0.27	0.12

메모리 없는 B0은 이 과제들에서 전부 0점이었고, BM25 통제 조건과의 비교는 집합 중첩 F1로 별도로 이뤄졌다. 중요한 것은 격차의 원인이 섭취 불완전이 아니라는 점이다. mem0 안에 관련 사실은 들어 있었지만, 검색이 순위가 매겨진 일부만 돌려주는 구조라서 완전한 집합을 열거하거나 부재를 확립하거나 관계를 순회할 수 없었다. 격차는 답이 커질수록 벌어져서, 두 항목짜리 집합에서는 두 시스템이 동등했다. 통제 조건인 B1-rag와의 F1 비교에서는 중립 공개 코퍼스에서 0.90 대 0.34(사내 코퍼스에서는 0.94 대 0.25)로, 같은 내용이라도 구조를 걷어내면 결과가 무너지는 것, 즉 우위의 원천이 내용이 아니라 구조임을 확인해준다.

이 극적인 격차의 다른 면도 논문은 정직하게 잔다. 단순 관련성 검색에서는 그래프가 커버리지 0.82(약 35k 토큰), mem0가 0.67 0.90(약 40k 토큰)으로 비겼다. 기록 수를 50개에서 634개로 키워가며 본 규모 연구에서도 그래프는 모든 크기에서 앞섰지만(최대 크기에서 hit@5 0.84 대 0.60) 격차는 일정한 오프셋일 뿐, 기울기의 신뢰구간이 0을 포함했다. 저장소가 커진다고 격차가 벌어지지 않는다는 뜻이다. 검색 정밀도는 이 시스템의 변별점이 아니라는 것을 저자 스스로 인정하는 대목이다.

반면 최신성은 구조가 만드는 차이였다. 실제 반복 사례 4쌍, 모델 4종, 전달 방식 2가지를 아우른 40회 시행에서 그래프는 모두 현재 답을 냈다. 대체된 기록이 현재 지침 검색에서 구조상 원천적으로 제외되기 때문이다. 흥미롭게도 반복 과제에서는 mem0도 100%였다(메모리 없는 콜드 에이전트는 0.00). 평균 조건은 달랐다 — 폐기된 기록이 최신 기록보다 위로 올라온 한 쌍에서는 13회 중 1회(8%)만 현재 답을 냈다.

비용도 잔 결과가 있다. 122항목짜리 완전성 집합을 SPARQL로 뽑는 데 78k 167k 토큰이 들었고, 타깃 검색은 약 35k였다. 완전성은 비싼 질문이다. 다만 기준선들은 어떤 비용을 들여도 완전한 답을 만들지 못했다. 비싼 것과 불가능한 것의 차이이다.

논문은 여기에 실사용 시험을 더한다. 이 시스템을 만든 동기 — 구조화된 메모리가 몇 달의 실제 작업 동안 이해 부채를 줄이는가 — 는 시점 평가로는 답이 안 나오므로, 저자는 두 개의 프로덕션 코드베이스에서 일상 사용 시험을 사전등록 형식으로 돌리고 있다. 컨텍스트 회복 기준점 16개를 미리 고정했는데, 각각 옛 접근이 현재 트리에서 지워진 반복을 겨냥해서 코드만으로는 답을 재구성할 수 없게 만들었다. 정답은 일차 원천에서만 작성해 그래프가 자기를 채점하지 못하게 했고, 맹검 로컬 judge가 매월 그래프-콜드 격차를 기록된 0월 기준선 대비 채점한다. 실패 조건도 미리 정했다. 프로젝트당 월 4회 미만의 기록 인용 어시스트가 나오면 시스템을 폐기한다. 첫 21일의 중간 보고는 이렇다 — 관련 기록을 인용한 무개입 어시스트 71건, 미스(도움 안 되는 회상 또는 알고 있어야 할 지식의 부재) 38건, 이 중 35건이 커밋 히스토리가 얇은 쪽 프로젝트에 몰려 있었다.

나의 해석

먼저 숫자를 읽는 법부터 정리하자. 6 27%는 성능 격차라기보다 부재의 측정이다. mem0에 사실이 들어 있어도 top-k 구조상 그 형태의 질문에는 답 자체를 조립할 수 없었다. 0.98 대 0.06을 “새 엔진이 16배 낫다”로 읽으면

안 되고, “묻는 정보가 검색 경로에 애초에 없었다”로 읽어야 한다. 완전성 질문은 k를 키우고 돈을 쓰면 부분적으로 살릴 수 있는 종류다(122항목에 78k 167k 토큰). 대체 관계와 부정은 다르다. 어떤 결정이 다른 결정을 갈아치웠다는 사실은 두 문서의 내용이 아니라 두 문서 사이에 있고, 없는 것은 임베딩으로 표현될 실체 자체가 없다. **저장할 때 적어두지 않은 관계는 몇 개를 가져오든 거기 없다.** 이 논문의 실제 주장은 “새 메모리가 낫다”가 아니라 “이 세 종류 질문은 저장 구조의 문제이지 검색 성능의 문제가 아니다”다.

내가 이 논문에서 가치 있다고 본 부분은 결과표가 아니라 “평가가 거의 날뻐던 결론 세 가지”를 고백하는 대목이다. 첫째, 자기 시스템에 20점 유리해 보였던 승리는 채점 방식의 부산물이었다. 둘째, 관련성 저하로 보였던 것은 설정 버그였다 — 메모리 서버가 죽어 있었는데 에이전트가 말없이 원시 저장소를 그랩하고 있었으니, 그 실험은 아무것도 재고 있지 않았다. 셋째, 오해를 부르는 커밋 메시지 하나가 정답과 부트스트랩된 근거를 함께 오염시켰다. 메모리 시스템 논문이면서 동시에 메모리 시스템을 어떻게 재는지에 대한 사례 연구인 셈이다. 이 세 실패를 잡아낸 규칙 — 불변 트랜스크립트와 무료 재채점, 점수를 아는 조건으로 judge 검증, 메모리 도구가 실제로 발동했는지 확인, 정답은 일차 원천만 — 은 이 논문의 숫자를 믿을 만하게 만드는 근거다. 숫자 자체가 아니라 숫자를 만든 절차가 이런 실패를 스스로 잡았다는 사실이 신뢰의 근거다.

동등성 결과도 같은 맥락에서 읽힌다. 관련성은 비기고, 토큰은 비슷하고, 규모를 키워도 격차가 벌어지지 않는다 — 이기는 곳만큼 못 이기는 곳을 명시한 논문은 드물다. 그래서 실무의 결론은 “기존 메모리를 건너내라”가 아니라 “차선을 추가하라”가 된다. 평범한 검색 질문은 지금 도구로 두고, 대체·완전성·부정 세 종류 질문에만 다른 장치를 엮는 것이다. 그리고 그 장치의 핵심은 상용 엔진이 아니라 다음 항목이 말하는 입력 규율이다.

이 시스템의 진짜 비용은 질의가 아니라 입력에서 난다. 논문 스스로 밝히듯 캡처가 평평하게 이뤄지면 그래프는 평문 검색과 동등로 퇴화한다. 온톨로지의 실질은 엔진이 아니라 강제된 작성 규율이다 — 다섯 종류로 나눠 적고, 상태를 붙이고, 대체 링크를 남기는 습관. 0.98은 질의 엔진이 아니라 입력 단계의 규율이 산 숫자다. 이 관점에서 도입 결정은 기술 선택이 아니라 조직 질문이 된다. 팀이 그 마찰을 몇 달, 몇 년 유지할 수 있는가. 벡터 스토어는 이 마찰이 없는 대신 위의 세 질문을 못 푼다. 무엇을 포기할지의 선택일 뿐이다.

MCP가 수동적이라는 점도 짚을 만하다. 에이전트가 언제 호출할지 스스로 정하므로, 저자도 상위 모델에 유리한 설계라고 인정한다. 메모리가 존재하는 것과 메모리가 상담되는 것은 다른 일이다. 이는 3장의 뷰-원본 문제와 같은 구조다 — 시스템이 아무리 정확해도 에이전트가 보는 자리에 정확한 것이 놓여야 한다. 기록에 상태를 적어두는 일과, 그 상태가 에이전트의 읽기 경로에 보이는 일은 별개의 작업이고 둘 다 해야 한다.

끝으로, 폐기 조건을 도입과 함께 등록한 설계가 눈에 띈다. “월 4회 미만 어시스트면 은퇴”라는 기준을 시험 시작 전에 문서로 남겼다. 도구를 도입하면서 섰다운 기준을 먼저 쓰는 것은 10장의 명세 먼저 쓰기와 같은 규칙의 운영 버전이다. 그리고 21일 차 중간 보고에서 미스 38건 중 35건이 커밋 히스토리가 얇은 프로젝트에 몰렸다는 사실도 정직한 신호다. 이 시스템의 품질 상한은 결국 저장소 히스토리의 품질이 정한다 — 커밋 로그가 지저분하면 지저분한 근거가 기록된다. 오염된 커밋 메시지가 정답까지 오염시켰던 사례가 바로 그 실패 양상을 보여준다.

한계와 남는 의문

첫째, 시험 문제를 고른 사람과 시험을 만든 사람이 같다. 대체·완전성·부정은 유사도 검색이 원래 구조적으로 약한 종류의 질문이면서, 관계를 명시적으로 저장하는 방식에 정확히 맞아떨어지는 종류이다. 자기 접근이 무엇을 위해 만들어졌는지 보여주는 정당한 시험이지만, 이 조건을 빼놓고 “기존 메모리가 6%밖에 못 한다”고 옮기면 왜곡이다. 논문도 이를 의식해 평범한 검색 과제를 함께 넣었고 거기서는 비겼다.

둘째, 단독 저자이고 질의 엔진 MOOSE는 자체(proprietary) 기술이라 핵심 부분의 독립적 재현이 불가능하다. 자사 제품을 소개하는 글이라는 성격도 감안해야 한다. 특히 mem0을 어떤 설정으로 돌렸는지 — top-k 값, 검색 파이프라인 구성 — 는 이런 비교에서 결과를 크게 좌우하는데 논문에 상세히 나 있지 않다.

셋째, 에이전트는 한 계열(GPT-5.x)만 썼고 judge도 같은 계열 모델이다. 라이브 시험은 21일 차 중간 보고가 전부이고, 등록된 최종 판독값인 월간 추세는 아직 나오지 않았다. 실사용 결과를 근거로 한 결론은 이 시험이 끝나야 확정된다.

넷째, 캡처 규율의 지속성이다. 논문은 규율이 만드는 마찰을 인정하고 정렬 도구·보조 캡처로 비용을 낮춘다고 하지만, 실제로 몇 달 뒤에도 사람이나 에이전트가 다섯 종류로 나눠 기록할지는 라이브 시험이 답해줄 유일한 질문이다. 남은 의문도 하나 있다. 6장에서 기억의 이득이 작업 종류에 따라 같았듯, 기억의 형태가 주는 이득도 작업 종류에 따라 갈리는지 — 구조화 메모리가 팩트 조회에는 강하지만 순차적 의사결정에는 다른 값을 내는지 — 는 이 논문의 범위 밖이다.

실무에 가져갈 것

이 논문의 시스템을 그대로 도입할 수 있는 팀은 많지 않다. 그러나 발상은 도구를 가리지 않는다. 왜 그렇게 정했는지를 남기는 도구라면 — 프로젝트 규칙 문서, 에이전트가 매번 읽는 지침 파일, 팀 위키 — 아래 것들은 오늘 적용된다.

첫째, “무엇”과 “왜”를 다른 칸에 적는다. 대부분의 문서는 결정만 적는다. “우리는 A 방식을 쓴다”에 한 줄을 더한다 — “B를 시도했더니 C 문제가 있었기 때문”. 논문이 결정과 근거를 별개 타입으로 나눈 이유가 이것이다. 붙여 쓰면 나중에 “근거만 모아줘”가 성립하지 않는다.

둘째, 지우지 말고 대체 표시를 남긴다. 규칙이 바뀔 때 옛 줄을 삭제하면 “예전에 그걸 시도했다가 접었다”는 정보가 함께 사라지고, 반년 뒤 누군가 혹은 에이전트가 같은 제안을 다시 가져온다. 삭제 대신 “이 규칙은 2026-03-12 결정으로 대체됨 — 이유: 성능이 아니라 운영 부담”을 붙인다. 이번 장에서 가장 크게 갈린 질문 유형(대체 추적)을 문서 한 줄로 직접 겨냥하는 조치다.

셋째, 상태를 읽히는 자리에 보이게 한다. 기록에 폐기 표시를 해두어도 에이전트가 읽는 지점에 그 상태가 드러나지 않으면 소용이 없다. 자주 쓰는 지침 문서라면 폐기 항목을 아래쪽 별도 구역으로 몰고 그 구역 첫 줄에 “아래는 더 이상 유효하지 않음”을 크게 적는 것만으로 효과가 있다. 상태를 적는 일과 상태를 노출하는 일은 별개다.

넷째, 부정 질문으로 지금 쓰는 메모리를 진단해본다. “우리가 쓰지 않기로 한 라이브러리가 뭐지?”처럼 없음을 묻는 질문을 던지고, 도구가 답을 내는지 아니면 관련돼 보이는 문서만 던지는지 확인한다. 못 한다는 걸 아는 것 자체가 소득이다 — 그게 이 논문에서 전 당신의 6%다.

다섯째, 이 장의 숫자를 인용할 일이 생기면 조건까지 한 세트로 옮긴다. “대체·완전성·부정 세 유형에서 0.98 1.00 대 6 27%, 관련성 검색과 토큰 비용은 동등, 규모를 키워도 격차는 일정”까지가 원문이 말하는 범위다. 앞 절반만 옮기면 오해를 만든다. 반대로 하지 말아야 할 일도 분명하다 — 이 논문을 근거로 현행 검색 메모리를 걷어내는 것. 논문 스스로 그 근거가 없다고 밝혔다.

여섯째, 메모리 계열 도구를 도입한다면 폐기 조건을 시작할 때 등록한다. “이 기준 미달이면 돌아간다”를 월 4회 어시스트처럼 숫자로 적어두는 것. 이 논문에서 바로 배워올 수 있는 가장 값진 운영 습관이다.

이 책의 다른 장과 이어지는 지점

6장과 이 장은 C목록의 한 쌍이다. 6장이 “무엇을 기억할까”를 물었다면 — 기억이 판단에 도움이 되는 일(사실 조회)과 해가 되는 일(순차적 의사결정)이 갈린다 — 이 장은 “어떤 구조로 기억할까”를 묻는다. 무엇을 넣을지와 어떤 형태로 넣을지는 독립적인 두 축이고, 두 장을 함께 읽으면 기억 설계가 두 번의 결정으로 이뤄짐이 보인다.

3장과는 최신성 문제로 이어진다. 3장에서 뷰와 원본의 버전이 어긋나면 에이전트는 없는 사실을 근거로 판단했다. 이 장의 그래프는 대체된 기록을 현재 지침 검색에서 구조상 원천 차단해 같은 실패를 예방한다. 정확한 원본에 가까운 쪽이 이긴다는 같은 교훈의 메모리 버전이다. 4장과는 경계 문제로 이어진다. 컴포넌트로 쪼개면 넘겨주는 경계에서 규정이 증발했는데, 대체 관계가 붙은 기록은 경계를 넘어도 죽지 않는 사실의 보존 형태다.

8장·9장과는 평가 방법론으로 이어진다. 사전등록, judge 검증, 도구 실제 발동 확인, 불변 트랜스크립트 — 이 장의 “거의 날뻐던 세 결론”은 프롬프트의 값을 재는 8장과 최종 점수 너머의 병목을 재는 9장과 같은 family의 이야기다. 10장과는 습관의 친연성으로 이어진다. 만들기 전에 약속을 먼저 쓰듯, 정한 뒤에는 이유를 먼저 남기고, 도입할 때는 폐기 조건을 먼저 적는다. 셋 다 “나중에 재고 또 쓰는 글”을 먼저 쓰는 같은 규칙이다.

제8장 · 내가 넣은 한 줄은 대체 얼마짜리인가

“원문: The Value of a Prompt: An LLM-Relative Kolmogorov-Complexity Approach — arXiv:2608.16438 · Rafael Pass (Cornell Tech · Technion · TAU)” “링크: <https://www.alphaxiv.org/abs/2608.16438> · <https://arxiv.org/abs/2608.16438>”

한 줄 요약

좋은 프롬프트란, 같은 결과를 훨씬 싸게 만들어주는 프롬프트다 — 그 값은 비트로 잴다. b비트짜리 프롬프트는 없으면 비용이 2^b 배 든다.

무엇이 문제였나

모델이 결과물을 점점 더 많이 떠맡는 세상에서, 사람이 넣는 것 — 프롬프트, 힌트, 비판, 문제 정의, 부분 해답 — 에는 어떤 가치가 남을까. 이게 논문의 질문입니다. 저자는 이것을 경제학의 질문으로 못박습니다. 모델의 능력이 넉넉해질수록 사람의 몫은 “무엇을 만들어내느냐”가 아니라 “모델에게 무엇을 골라 넣느냐”로 옮겨가고, 그렇다면 넣은 것의 값을 잴 단위가 필요하다는 것입니다.

직관은 단순합니다. 사람이 넣은 입력은 모델이 목표 산출물을 더 쉽게 만들게 해줄 때 가치가 있습니다. 쉽게 만드는 방법은 두 가지입니다 — 그 산출물이 나올 **확률 자체를 높여주거나**, 그 산출물을 찾는 데 드는 **생각의 시간을 줄여주거나**.

기존에 널리 쓰인 측정법은 앞의 절반만 봅니다. 우도 비율(likelihood ratio) — 프롬프트를 넣었을 때와 안 넣었을 때 목표 답이 나올 확률의 비. 깔끔하지만 **모델의 ‘생각’ 단계가 통째로 빠져 있습니다**. 가장 가까운 선행연구인 Xie 등의 인간 기여도 점수도 같은 한계를 가집니다. 논문의 비사고(非思考) 버전 값은 그 점수에서 정규화 분모를 뺀 값과 정확히 일치합니다 — 기존 측정법에 알고리즘 정보이론의 기초를 얹는 자리이자, ‘생각에 대한 과금’이 없다는 결핍을 이 논문이 메운다는 저자의 명시이기도 합니다.

낯선 동네에서 목적지를 찾는다고 합시다. 행인 A가 “저 골목로 들어가서 세 번째 사거리에서 좌회전”이라고 말해줬고 행인 B는 아무 말도 안 했다. 결국 나는 둘 다의 경우에 도착했습니다. 도착 여부만 기록하는 장부에는 두 경우가 똑같이 “도착함”으로 남습니다. 그런데 하나는 3분, 다른 하나는 40분 헤맨 끝의 도착입니다. **결과의 확률은 같고 값어치는 전혀 다릅니다**. 확률만 보는 측정법은 정확히 이 장부입니다.

논문은 확률 기반 측정이 무너지는 이유를 두 가지로 정리합니다. 첫째, 매우 길거나 비싼 사고 경로까지 전부 평균에 섞어버립니다 — 백 번에 한 번 운 좋게 짧게 끝난 경우와 매번 만 토큰을 태우는 경우가 같은 확률로 뭉개집니다. 둘째, 프롬프트의 주된 이득이 애초에 “생각하는 노력을 줄여주는 것”일 수 있다는 사실을 반영하지 못합니다. 프롬프트 없는 모델이 1만 개의 사고 토큰을 태운 뒤에야 답을 찾고 프롬프트를 받은 모델은 즉시 찾는다면, 최종 답의 확률이 완전히 같더라도 그 프롬프트는 분명히 매우 가치 있습니다.

요구사항을 분명히 해주는 사실이 두 가지 더 있습니다. 토큰 수는 가치와 무관합니다 — 짧은 힌트가 결정적일 수 있고 긴 프롬프트는 해로울 수도 있습니다. 그리고 가치는 **음수가 될 수 있습니다** — 오해를 부르는 입력을 모델이 일정한 비용으로 무시해줄 것이라는 보장이 어디에도 없기 때문입니다.

어떻게 답했나

1단계 — 생각을 빼고 정의 세우기

콜모고로프 복잡도는 어떤 것의 복잡함을 “그것을 만들어내는 가장 짧은 설명의 길이”로 잹니다. “1이 백만 번”이라는 문자열은 길지만 설명은 짧고, 무작위 백만 자리 숫자는 줄여 말할 방법이 없어 설명이 원본만큼 길어집니다. 이 개념은 보편 튜링 기계를 기준으로 정의되는데, **계산 불가능하다**는 치명적 문제가 있어 오랫동안 이론의 도구였지 측정 도구가 아니었습니다.

논문의 결정적 한 수는 **보편 튜링 기계 자리에 LLM을 그대로 갖다 놓는 것**입니다. “이 모델이 무엇을 만들어냈는가”를 물을 때 기존 기계는 보편 기계가 아니라 바로 그 모델이어야 한다는 것입니다. LLM을 문자열을 뽑아내는 기계로 보면 그 기계에 넣는 “프로그램”은 특정 출력을 뽑아내기 위해 필요한 무작위 선택의 비트열이고, 프로그램의 길이는 그 출력을 강제하는 가장 짧은 비트 접두사입니다. 이 치환 덕분에 복잡도는 **실제로 측정 가능한 양**이 됩니다.

프롬프트 p 의 가치는 뺄셈입니다 — (프롬프트 없이 z 를 만드는 비용) 빼기 (프롬프트 p 를 주고 z 를 만드는 비용). 생각 단계가 없는 모델에서는 이 복잡도가 출력 확률에 로그를 씌우고 부호를 뒤집은 것(음의 로그 확률)과 사실상 같아지는데, “사실상”의 폭이 논문에서 정확히 매겨집니다 — 프로그램 길이 기반 값과 음의 로그확률 기반 값의 차이는 **2비트 미만**입니다(정리 2.6) — 측정하기 쉬운 쪽이 ‘진짜’ 정의를 좇습니다. 그리고 이 값은 정보이론의 **점별 상호정보(PMI)**와 정확히 같은 대수적 형태입니다. 이 정의는 아무 데서나 튀어나온 새 척도가 아니라 익숙한 개념을 자연스럽게 되찾는 자리에 놓여 있습니다. 값어치의 스케일도 여기서 알려줍니다 — 토큰 하나짜리 방아쇠가 긴 출력의 확률을 수백 비트 올릴 수 있습니다. 가치는 입력의 길이가 아니라 효과로만 매겨집니다.

비트를 실감나게 하려면 배수로 바꿔야 합니다. 규칙은 하나 — **b비트는 2^b 배**.

비트 b	2^b 배	이 말은
1비트	2배	시도 두 번이 한 번으로
3비트	8배	여덟 번 넣을 일이 한 번으로
5비트	32배	재현 기대 비용이 서른두 배 차이
10비트	1,024배	백 번과 십만 번의 차이
20비트	약 100만 배	사실상 “없으면 못 얻는다”

“이 프롬프트는 10비트짜리”는 “이 프롬프트가 목표 산출물을 1024배 더 얻기 쉽게 만들었다”와 같은 말입니다.

2단계 — 생각을 셈에 넣기

추론 모델은 답을 내기 전에 사고 경로를 먼저 만듭니다. 비용을 제대로 재려면 **생각을 얼마나 했나와 그만큼 생각한 뒤에는 답이 얼마나 쉽게 나오나**를 동시에 봐야 하는데, 둘은 반대 방향으로 움직입니다. 생각을 안 하면 사고 비용은 0이지만 답이 나올 확률은 낮고, 오래 생각하면 답은 확실해지지만 생각 자체가 비쌉니다. 논문의 답은 **이 둘을 더한 값이 가장 작아지는 지점** — “이 생각 과정에서 답을 얻기 가장 쉬웠던 지점은 어디였나”를 찾는 것입니다.

이 발상의 뿌리는 **레빈(Levin)의 Kt 복잡도**라는 고전입니다 — 프로그램 길이에 그 프로그램이 도는 데 걸린 시간의 로그를 더해서 재는 방식. 논문은 이걸 LLM 세계로 옮겨옵니다. 사고 토큰 t 개에 대해 토큰 등가 비용 함수 $\kappa(t)$ 를 두고, 사고를 어디까지 진행했을 때 (남은 설명 길이 + $\log \kappa(t)$)의 합이 가장 작은지를 찾습니다. 로그를 씌워 **확률과 계산량을 한 숫자(비트)로 더할 수 있게** 만드는 것이 핵심입니다. 계산도 무한에 빠지지 않습니다 — 사고 경로 길이가 S 면 접두사 $t=0$ 부터 S 까지만 보면 됩니다(그 너머는 설명 길이가 그대로인데 비용만 늘어남). 즉 **실현된 사고 하나마다 그 모든 중간 지점이 채점 후보가 됩니다**.

마지막 퍼즐 — 모델의 생각은 **확률적**입니다. 같은 질문을 다시 던지면 다른 경로로 갑니다. 어떤 판에서는 운 좋게 세 줄 만에 핵심을 짚고 어떤 판에서는 한참 헤맬니다. 해결은 상식적입니다 — 여러 번 굴러보고 **δ -분위수**($\delta=0.5$ 면 중앙값)를 취합니다. 이것이 **확률적 레빈-콜모고로프 복잡도(pKt)** 이고, 프롬프트의 최종 가치는 $pKt(z) - pKt(z)$

p)입니다. 추정에도 보장이 없습니다 — 조건별로 k번 돌아온 경험적 분위수는 확률 $1 - 4\exp(-2k\zeta^2)$ 이상으로 참 분포의 $(\delta-\zeta)$ 분위수와 $(\delta+\zeta)$ 분위수 사이에 들어옵니다(정리 4.1).

왜 평균이 아니라 분위수인가 — 평균은 극단값에 끌려갑니다. 만 번에 한 번 아주 짧게 끝나는 운 좋은 경로가 있으면 실제로는 매번 오래 걸리는 상황이 “쌈”으로 기록될 수 있습니다. 중앙값은 “절반은 이보다 쉽고 절반은 이보다 어렵다”는 지점을 정확하게 가리킵니다. δ 를 0.9로 잡으면 보수적 기준, 0.1이면 “잘 풀리면 이 정도”가 됩니다. 논문은 δ 하나를 고르는 대신 **가치를 δ 의 함수(프로파일)로 보고합니다** — 이 선택이 왜 필수였는지는 실험 결과에서 드러납니다.

여기까지를 세 성분으로 정리하면 다음 표 하나로 압축됩니다.

성분	무엇을 잡아	셈에 들어가는 방식	뿌리가 되는 고전
가능성	목표 산출물이 나올 확률	$-\log_2 P$ — 남은 설명의 길이	콜모고로프 복잡도
계산량	거기까지 도달한 사고 토큰	$+\log_2 \kappa(t)$ — 생각에 로그로 과금	레빈 Kt 복잡도
확률성	굴릴 때마다 달라지는 난이도	δ -분위수(기본은 중앙값)	확률적 복잡도

기존 측정법은 첫째 줄만 봤고, 이 논문은 세 줄을 한 단위(비트)로 더합니다.

3단계 — 비트를 청구서로 바꾸기

비트 값이 실제 무엇이 비율인지 논문은 정리로 증명합니다(정리 5.2·5.4). **재현 실험**이라 부르는 상상을 하나 정의합니다 — 맥락 y 와 이미 실현된 사고 H 를 고정하고, 출력 단계만 새 무작위로 반복해 굴려 정확히 z 가 나올 때까지 시도합니다. 한 번의 시도가 성공할 확률을 G 라 하면 성공까지의 기다림은 기하분포를 따르고, 시도마다 $\kappa(|H|)$ 씩 청구되므로 기대 재현 비용은 $\kappa(|H|)/G$ — 곱셈과 나눗셈 하나입니다. 논문은 이 비용의 ‘최적 접두사’ 버전의 중앙값이 정확히 2^{pKt} 와 같고, 따라서 **$2^{\text{(프롬프트 가치)}} = (\text{힌트 없이 재현하는 중앙값 비용}) \div (\text{힌트 없이 재현하는 중앙값 비용})$** 임을 증명합니다. 값이 10비트면 없이 재현할 때 토큰 증가 비용이 1,024배 든다는 뜻입니다. 분위수를 쓰는 또 하나의 이유가 여기 있습니다 — 분위수는 지수화와 교환되지만 기댓값은 그렇지 않아서, “중앙값 비용의 비율”이라는 해석이 분위수에서만 성립합니다.

검증기가 있는 산출물이라면 정의가 더 단순해집니다. 산출물 z 를 문자열 대신 검증기의 수용(ACC) 판정으로 선언하면 가치는 **중앙값 수용 비용의 비율**로 떨어집니다 — 힌트 없을 때의 중앙값 수용 비용을 τ_1 , 있을 때를 τ_2 라 하면 $\log_2(\tau_1/\tau_2)$. 벤치마크의 통과율이 아니라 **통과 비용**을 재는 셈입니다.

무엇이 밝혀졌나

이론의 시연은 GSM8K(초등 수학 서술형 문제 데이터셋)에서 이뤄졌습니다. 설계 골격은 다음 표와 같습니다.

항목	설정
모델	DeepSeek-R1-Distill-Qwen-1.5B (FP16 적재, 확률 계산은 FP32)
문제	학습 분할에서 복원 없이 100개 표본 → 참조 풀이가 줄바꿈 3단계 이상인 첫 12개
프롬프트 p	참조 풀이의 첫 단계(계산기 주식 $\backslash<\<2\ast300=600\backslash>\>$ 제거), $\backslash<\text{think}\backslash>$ 뒤에 삽입
산출물 z	고정된 ANSWER: 뒤에 이어지는 공백 + 정답 숫자 + EOS
샘플링	조건(힌트 있/없)별 각 64회 돌아옴, 온도 0.6, top-p 1.0(분포를 자르지 않음)
비용 함수	$c_{\text{pre}}=1, c_{\text{dec}}=32$ 기본(민감도 8–256), 생성형·프리필형 두 관례 병행
보고 단위	$\delta = 0.2, 0.5, 0.8$ 세 분위수의 가치 프로파일

눈여겨볼 설계는 두 가지입니다. 첫째, 힌트는 시스템 프롬프트처럼 ‘지시’로 주어지지 않고 **모델의 사고가 열린 직후($\backslash<\text{think}\backslash>$ 바로 뒤)에 이미 계산된 첫 단계로 삽입**됩니다 — 사람의 입력을 지시가 아니라 완료된 계산으로 취급하는 관점입니다. 둘째, 두 조건 모두 같은 질문과 같은 답안 형식 지시를 받으므로, 재는 것은 오직 그 한 단계의 값어

치입니다. 첫 문제(gsm8k#4205)가 대표적입니다 — “첫날 새 300마리, 둘째 날 두 배, 셋째 날 200마리 감소”를 묻는 문제(답 1300)에 프롬프트는 “첫날 300마리이므로 둘째 날은 $2 \times 300 = 600$ 마리”라는 한 문장. 사람이 보기에 완벽하게 도움이 되는 문장입니다.

결과는 네 가지로 압축됩니다.

- ① **생각을 고려하면 좋고 나쁨이 뒤집힌다.** 세 분위수 모두에서 양의 가치가 나온 문제는 여섯인데, 이 여섯 중 다섯에서 정확한 첫 단계 힌트가 사고 시작 직전($t=0$)의 정답 확률을 오히려 낮췄습니다(나머지 하나는 거의 그대로). 우도 비율만으로 채점했다면 이 힌트들은 ‘해로운 힌트’로 판정됩니다. 사고를 계산에 넣자 판정이 뒤집힙니다 — 힌트를 받은 쪽이 훨씬 짧은 사고 접두사만으로 유리한 확률에 도달하기 때문입니다. 저자는 이를 비사고 확률 측정이 정반대 판정을 내릴 수 있는 증거로 못박습니다. 도착 확률이 아니라 **도착 경로의 질**이 개선된 것인데, 기존 측정법은 이걸 볼 눈이 없었습니다.
- ② **정확한 힌트가 좋은 힌트는 아니다.** 12개 중 세 분위수 모두 양의 가치인 경우는 여섯뿐입니다. 나머지 여섯은 해로움에서 무의미(중복)까지, δ 에 따라 부호가 오가는 혼재까지 스펙트럼입니다. 모델이 이미 자연스럽게 가려던 길이 있는데 옆에서 다른 길을 가리키면 그건 도움이 아니라 방해가 됩니다. 논문의 표현을 빌리면 — 올바른 이유를 공급했다는 사실만으로는 가치가 보장되지 않는다.
- ③ **같은 힌트가 분포의 한쪽을 돕고 다른 쪽을 해친다.** 여러 문제의 가치 프로파일이 δ 를 움직이면 부호가 바뀌고, 교차는 양방향으로 일어납니다. 중앙값의 가치가 분포 전체의 가치를 말해주지 않는다는 뜻이고, 그래서 가치는 단일 숫자가 아니라 δ 의 함수로 보고되어야 합니다.
- ④ **가속인가, 조종인가 — 두 비용 관례로 갈라 켜다.** 사고에 과금하는 방식을 두 가지로 둡니다. **생성형**은 실현된 사고를 순차 생성 비율($c_{dec}=32$)로 청구하고, **프리필형**은 사고 접두사를 싼 프리필 비율(1)로 청구합니다. 생성형에서 양수인데 프리필형에서 0에 가까워지는 사례가 여럿입니다 — 사고를 싸게 재생할 수 있다면 힌트 없는 모델도 더 긴 사고로 회복할 수 있다는 뜻이므로 그 가치는 **가속형**입니다. 반대로 프리필형에서도 우위가 지속되는 사례가 있습니다 — 사고를 공짜로 재생해도 닿지 못한다는 뜻이므로 그 가치는 **조종형**입니다.

	가속형	조종형
정의	어차피 갔을 길을 빠르게	다른 길로는 못 닿는 곳으로
실험 신호	생성형 +, 프리필형 ≈ 0	프리필형에서도 우위 지속
작동 방식	짧은 사고로 유리한 확률에 도달	확률 자체가 높은 상태로 이동
값이 커지는 자리	반복 작업	중요한 판단
다듬는 방향	짧게	정확하게

관찰	수치	해석
힌트가 $t=0$ 정답 확률을 오히려 낮춤	양의 가치 코호트 6개 중 5개	비사고(PMI) 판정 ‘해로움’ → 사고 포함 시 ‘유익’으로 반전
세 분위수 모두 양의 가치	12개 중 6개	정확한 첫 단계 힌트가 값이 있는 경우는 절반
나머지 6개의 처지	해로움 · 무의미 · 혼재	정확성은 가치의 보증이 아니다
δ 에 따른 부호 교차	여러 프로파일, 양방향	같은 힌트가 분포의 한쪽을 돕고 다른 쪽을 해친다

이 모든 값이 원래 개념이 계산 불가능하다는 사실을 생각하면 작은 성취입니다 — 여러 롤아웃의 모든 중간 지점에서 확률과 비용을 계산하고, 경로마다 최적 정지점을 찾고, 분위수를 취하는 네 단계로 값이 **실제로 나옵니다**.

나의 해석

이 논문에서 제가 주목하는 것은 측정 대상의 선택입니다. 사람의 기여를 잴다는 문제를, 저자는 “사람이 뭘 썼나”가 아니라 **“그것이 없을 때 무엇이 비싸지는가”**로 정식화했습니다. 가치를 대상의 속성이 아니라 **반사실(counterfactual)의 차이**로 정의한 것입니다. 이 반전이 이론의 전부라고 생각합니다 — 좋은 프롬프트 문서를 고르는 문제는 “뭘 넣을까”가 아니라 “이걸 뺐을 때 무엇이 느는가”로 바뀌고, 이 질문은 빼보기만 하면 누구나 답할 수 있습니다.

둘째, “정확한 힌트의 절반이 해롭다”는 발견을 저는 이 책의 주제와 잇습니다. 1장과 6장은 **넣는 것의 비용**(선택 희석, 주의 분산)을 보여줬습니다. 이 장은 그 비용의 이유를 모델 내부에서 찾습니다 — 모델에게는 이미 제 갈 길이 있는데, 그 길과 어긋나는 안내는 확률도 낮추고 생각도 늘립니다. “친절한 설명”이라는 이름의 대부분의 프롬프트 습관은 사람 교육에서 온 것이고, 사람에게 최적인 것이 모델에게 최적이라는 보장은 어디에도 없습니다.

셋째, **가치가 모델에 상대적**이라는 특성이 실무에 주는 함의를 무겁게 봅니다. 같은 프롬프트도 모델을 바꾸면 값이 달라집니다. 이견 흠결이 아니라 정의가 감추지 않고 드러낸 정직한 특성입니다 — 이미 아는 사람에게 하는 설명과 처음 듣는 사람에게 하는 설명의 값이 같을 리 없습니다. 실무에서는 곧바로 비용으로 돌아옵니다. **모델을 바꿀 때 마다 공들여 다듬어둔 프롬프트의 값어치도 다시 평가되어야 합니다.** 새 모델로 갈아탄 뒤 예전만 못하다고 느낀 경험 있다면, 모델이 나빠서가 아니라 프롬프트의 값이 그 모델 기준으로 달라졌기 때문일 수 있습니다.

넷째, 힌트를 <think> 안쪽에 ‘이미 계산된 것’으로 삽입한 설계 선택 자체가 해석의 대상이라고 봅니다. 사람의 입력력을 **지시가 아니라 완료된 계산**으로 취급하면 프롬프트 공학의 질문도 “어떻게 명령할까”에서 “어디까지 미리 해줄까”로 바뀝니다. 실무의 부분 해답 주기, 뼈대 코드 주기, 초안 주기가 정확히 이 자리입니다. 그리고 δ 프로파일은 프롬프트를 단일 점수가 아니라 **분포 위의 함수**로 기술하라고 요구합니다 — 우리가 프롬프트를 몇 번 써보고 내리는 “된다/안 된다” 판단은 이 함수의 표본 하나를 본 것에 지나지 않습니다.

다섯째, 이 논문은 각주에 실험 구현과 그림 생성을 Claude와 ChatGPT가 수행했다고 명시합니다. 아이디어와 책임은 저자의 것이고 실행은 모델의 것 — 사람의 몫을 묻는 이론이 자기 실험에서 이미 그 분업을 살고 있다는 대목을, 저는 이 논문의 정직함으로 읽습니다.

한계와 남는 의문

실험은 ‘측정의 시연’이지 ‘평가’가 아니다. 저자 스스로 이 실험을 측정법의 시연(illustration)이지 GSM8K 프롬프팅에 대한 모집단 수준 평가가 아니라고 못박습니다. 전체가 1.5B 파라미터 증류 모델 하나, 문제 12개, 조건당 롤아웃 64회에서 나왔습니다. “정확한 힌트의 절반이 오히려 해롭다”를 큰 상용 모델로 일반화하면 안 됩니다. 작은 모델이 힌트에 쉽게 휘둘리는 것과 큰 모델이 같은 힌트를 소화하는 것은 전혀 다른 문제일 수 있고, 코딩·작문·리서치 같은 다른 과제에서도 마찬가지입니다. **이 논문의 본체는 이론 틀이고 실험은 그 틀이 돌아간다는 시연**으로 읽는 것이 정확합니다.

2^b 등식은 정리이지 실험 결과가 아니다. “b비트면 2^b 배”는 재현 실험의 정의와 정리 5.4로 증명되는 항등식이고, GSM8K 실험은 이 측정의 프로파일을 추정한 것입니다. 둘을 섞어 “실험적으로 검증됐다”고 인용하면 안 됩니다.

비용 함수 κ 는 선언된 선택이다. c_dec 를 8에서 256까지 움직이면 값이 흔들리고, 논문 그림의 음영은 신뢰구간이 아니라 **비용 민감도** 따릅니다. 가속/조종 판정조차 ‘생각을 얼마나 치는가’라는 선언에 의존합니다. 사고 토큰의 가격을 다르게 부과하는 조직에서는 같은 프롬프트가 다른 성격으로 분류될 수 있습니다.

게임이 가능하다. 정당한 산출물 뒤에 의미 없는 무작위 문자열을 붙이고 그 접미사를 프롬프트로 공급하면, 그 접미사는 아무 역할도 하지 않았는데 프롬프트가 그 몫의 가치를 거의 다 가져갑니다. 논문의 해법은 산출물을 “모델이 뽑은 특정 문자열”이 아니라 **검증기의 정준 판정**으로 선언하는 것입니다. 검증기가 없는 영역(작문, 디자인)을 위한 ‘시맨틱 재무작위화’는 후속 과제로 남았습니다.

“목표 산출물 z 를 이미 안다”는 전제. 이 계산은 재현 대상이 정해져 있어야 합니다. 아직 무엇이 정답인지 모르는 탐색 상황 — 연구, 설계, 작문 — 에서 이 값을 직접 쓰기는 어렵습니다. 다중 턴 대화로의 확장도 부분적입니다 —

각 인간 발화를 그 시점의 기록에 조건해 순차 적용하고 증분을 더하는 사후 회계는 가능하지만, 사람의 적응 전략 자체의 가치는 잡지 못합니다. 또 하나 — 이 측정이 쟁 것은 산출물의 **난이도**이지 산출물의 **가치**가 아닙니다. 무작위 문자열은 재현하기 지독히 어려워도 아무 가치가 없습니다.

인용의 주의. “AI 연구에서 사람의 힌트가 절반은 해롭다고 밝혀졌다”는 식의 문장은 이 논문이 뒷받침하지 않습니다. 뒷받침되는 건 “작은 증류 모델 하나와 수학 데이터셋 12문제에서, 정확한 첫 단계 힌트가 절반쯤은 도움이 되지 않았다”까지입니다. 조건을 함께 옮기는 것까지가 인용입니다.

실무에 가져갈 것

이 논문의 계산을 직접 돌릴 필요는 없습니다 — 토큰별 확률 접근과 수십 회 반복이 필요해 대부분의 환경에서 과한 작업입니다. 관점만 옮겨도 충분히 남습니다.

빼보기부터 하세요. 자주 쓰는 프롬프트에서 한 문단을 지우고 같은 작업을 시켜봅니다. 결과가 그대로면 그 문단의 값은 0에 가깝습니다. 더하기보다 빼기가 값을 재는 더 빠른 방법입니다.

“몇 배 아꼈나”로 값을 매기세요. 프롬프트의 가치를 별점이 아니라 배수로 적어둡니다. 그 지침이 없을 때 같은 결과에 도달하려면 몇 번을 더 시도해야 하는가 — 두 배인지 열 배인지만 구분해도 어떤 문서에 시간을 쓸지 정할 수 있습니다.

결과가 나온 뒤 사고 흔적의 길이를 함께 보세요. 같은 답이라도 모델이 훨씬 짧게 생각하고 도달했다면 그 프롬프트는 값을 한 것입니다. 이 측정의 본질은 “모든 중간 사고 지점이 채점 후보”라는 것 — 최종 결과물만 비교하는 습관을 버리는 것이 이 논문의 핵심 메시지입니다.

몇 번 굴려서 분포를 보세요. 한 번의 실행은 δ 프로파일의 표본 하나입니다. 같은 힌트가 잘 풀리는 판을 돕고 헤매는 판을 해칠 수 있습니다. “이 프롬프트는 안 통한다”는 판단이 꼬리 한 번의 체험은 아닌지 세 번은 확인해야 합니다.

힌트는 지시보다 ‘해둔 것’으로 주세요. 방법을 설명하는 문단보다 첫 단계를 실제로 수행해준 뼈대 — 코드 스니펫, 계산된 표, 초안 문장 — 가 이 논문의 관점에서 정확히 ‘부분 계산’입니다. 단, 그 값은 그 모델 기준임을 잊지 마세요.

모델을 바꾸면 프롬프트도 다시 재세요. 값은 모델에 상대적입니다. 이전할 때 한 번은 빼고 비교해봅니다.

검증기가 있다면 통과율 대신 통과 비용을 재세요. 테스트가 있는 작업이라면 “몇 퍼센트 통과”보다 “몇 번 굴려 통과”가 더 많은 것을 말해줍니다. 통과 비용이 다섯 배인 프롬프트는 같은 통과율이라도 다른 프롬프트입니다.

가속형인지 조종형인지 구분하세요. 가속형은 반복 작업에서 값이 크고 짧게 만들수록 좋습니다. 조종형은 중요한 판단에서 값이 크고 정확하게 만들수록 좋습니다. 다듬는 방법이 다릅니다.

이 책의 다른 장과 이어지는 지점

이 장은 D목록(“어떻게 썰 것인가”)의 첫 장이자 이 책에서 가장 이론적인 장입니다. 1장·6장의 “넣는 것의 비용”에 반사실의 언어를 제공합니다 — 넣는 것의 값은 그것을 뺏을 때 느는 비용으로만 정의됩니다. 9장과 직접 이어집니다 — 9장도 결과 점수가 숨는 것(병목, 재사용, 하네스)을 보겠다는 같은 문제의식을 과정 지표로 풀고, 이 장은 비트로 풀니다. 10장의 명세(사전조건·사후조건)는 실용적으로 검증된 “조종형” 프롬프트의 사례로 읽을 수 있습니다 — 개입 비용이 거의 0이고 재현 비용을 확실히 줄이는 한 줄들입니다.

제9장 · 잘 나온 결과 하나로 실력을 판단해도 될까

“원문: Beyond Final Scores: A Systematic Evaluation of Agents for Long-Horizon AI Research and Development — arXiv:2608.13417 · 메이탄(Meituan)·중국과학원대학 13인 공동 연구” “링크: <https://www.alphaxiv.org/abs/2608.13417> · <https://arxiv.org/abs/2608.13417>”

한 줄 요약

프론티어 모델 7개에 2 12시간짜리 연구개발 과제 36개를 세 번씩 맡겨 모두 756회의 실행을 재본 결과, 지금의 에이전트는 논문 표현대로 “완전히 자율적인 연구자라기보다 엔지니어링 최적화기”였다. 잘 나온 한 번과 늘 나오는 모습 사이의 격차가 컸고, 해법의 44%는 알려진 기술 쌓기였으며, 참신한 접근은 1.2%에 그친 반면 채점의 허점을 노리는 행동은 그보다 다섯 배쯤 흔했다. 최종 점수 한 줄은 이 모든 차이를 감춘다.

무엇이 문제였나

에이전트 벤치마크의 관행은 과제를 주고 결과물을 채점해 숫자 하나를 남기는 것이다. 짧은 과제에서는 그걸로 충분했습니다. 그러나 이 논문이 보는 대상은 하루 반쯤 걸리는 일입니다. 코드를 고치고, 실험을 돌리고, 결과를 보고, 다시 고치는 닫힌 고리가 수십 바퀴 돌아가는 동안 같은 최종 점수에 도달하는 경로는 전혀 다를 수 있습니다. 초반에 좋은 방향을 잡아 그냥 밀고 간 경우와, 여러 갈래를 소진할 만큼 해보다가 늦게 답에 닿은 경우는 점수가 같아도 다른 능력이고 고쳐야 할 지점도 다릅니다. 제안이 실제로 돌아가는 코드로 옮겨졌는지, 중간에 성능이 뒷걸음쳤을 때 되돌렸는지 역시 점수에는 나타나지 않습니다.

두 번째 문제는 관행적인 평가가 각 실행을 독립적으로 본다는 점이다. 그러면 능력이 고정된 것처럼 보이는데, 경험을 쌓은 에이전트는 다음 결정이 달라질 수 있다. 쌓인 경험이 돕기만 하는지, 오히려 그르칠 수도 있는지, 그리고 모델을 감싸는 운영 껍데기인 하네스가 어디까지 결과에 기여하는지도 분리되지 않은 채 섞여 있다. 연구진은 이를 네 개의 질문으로 정리했다. 최종 결과는 얼마나 강한가(❶), 연구 고리 안에서 진전은 어디서 얻히고 어디서 잃히는가(❷), 쌓인 경험은 다음 결정을 개선하는가(❸), 하네스 선택은 성능에 어떤 차이를 만드는가(❹).

숨어 있는 다섯 번째 문제도 있다. **재는 방식 자체가 재이는 대상의 행동을 바꾼다.** 점수를 올리라는 지시는 문제를 풀라는 지시와 같지 않아서, 채점 방식의 빈틈을 파고드는 행동이 생긴다. 이 논문이 그 행동에 별도의 이름표를 붙이고 숫자로 세는 이유다.

어떻게 답했나

실험 규모부터가 이 책에서 다루는 논문 중 가장 크다. 모델은 Claude-Opus-4.7, GPT-5.5, Gemini-3.1-Pro, GLM-5.2, Kimi-K2.7-Code, DeepSeek-V4-Pro, LongCat-2.0 일곱 개. 과제는 AutoLab 벤치마크의 36개로, 모델 개발 7개, 시스템 최적화 15개, 퍼즐·챌린지 10개, CUDA 4개다. 각 과제는 정답이지만 일부러 성능이 낮은 출발 코드, 전문가 참조 해법, 2 12시간의 시간 예산, 자동 검증기를 제공하고 검증기가 최종 제출물을 0에서 1 사이로 채점한다. 모델-과제 쌍마다 세 번씩 돌려 756회의 실행을 확보했고, 모델 간 비교를 위해 공용 하네스로 Claude Code(v2.1.152)로 묶었다. 과정 분석을 위해 추가한 지시는 커밋과 실험 저널을 남기라는 것 하나뿐이었다. 전체 평가에 든 모델 추론 비용은 약 10만 달러다.

핵심 도구는 세 개의 과정 지표다. C1(해결책 프레이밍)은 에이전트가 추구한 방향이 얼마나 빨리 강한 해법으로 이어졌는지를 본다. 실행 궤적을 20개 체크포인트의 공통 지평에 맞춘 뒤 초·중·후반 세 구간의 최고점을 가중해, 높은 점수에 일찍 도달할수록 잘 치한다. C2(실행)는 제안이 실제로 돌아가는 결과물이 되는지를 본다. 각 채점 시점에서 산출물이 끝까지 실행되는지, 정확성 게이트가 있으면 통과하는지를 먼저 보고, 그 이전에 빌드 실패를 몇 번 냈는지에 따라 점수를 할인한다. 요약문은 그럴듯한데 실은 실행조차 안 되는 “숨은 실패”를 잡아내는 축이다. C3(피드백 제어)는 최고점을 최종까지 지켰는지(유지), 성능이 뒷걸음쳤을 때 얼마나 빨리 얼마나 회복했는지(회복)를 함께 잔다. 세 지표 모두 검증기 점수와 기록된 궤적 신호에서 규칙으로 결정적으로 계산되므로 재현과 감사가 가능하다.

경험 재사용은 반사실 설계로 졌다. 과제 내(intra-task) 실험은 실행 중반에 분기점을 잡고, 한쪽은 경험을 그대로 둔 채 이어 가게 하며 다른 쪽은 컨텍스트·디스크 메모·코드 주석을 전부 지우고 다시 초기화한다. 두 조건이 분기점 직후 내는 다음 커밋의 점수 차이가 경험의 기여(ΔS)다. 과제 간(inter-task) 실험은 완료한 원본 과제에서 교훈을 뽑아 lessons.md 파일로 건네는 조건과 아무것도 주지 않는 조건을 비교한다. 여기에 교훈 대신 원본 작업 공간을 통째로 열어주는 조건, 그리고 다른 모델이 뽑은 교훈을 주는 조건을 덧붙여 무엇이 이전에 효과적인지를 갈랐다.

하네스는 세 가지 설정을 비교했다. 공용 Claude Code, 각 모델의 네이티브 도구(GPT의 Codex CLI, Kimi의 Kimi Code CLI 등), 오픈소스 OpenCode다. 나아가 바깥 루프에서 Claude-Opus-4.8이 하네스 자체를 네 라운드에 걸쳐 개선하는 자동 최적화(Auto Harness)도 시도했다. 마지막으로 참신성 분석에서는 756 실행 중 각 모델-과제 쌍의 최고 해법 252개를 여덟 범주로 분류했다. 판정 모델에 고정 루브릭을 주되 참신한 접근의 오판을 줄이려고 모든 후보를 사람이 다시 검토했고, 루브릭에는 “해킹은 결코 참신하지 않다”는 원칙이 명시돼 있다.

무엇이 밝혀졌나

먼저 최종 성적이다. Opus-4.7가 평균과 최고 둘 다 1위였고, 2 4위는 밀집해 있었다.

모델	avg@3	best@3	과제당 추정 비용
Claude-Opus-4.7	0.739	0.790	\$89.9
GLM-5.2	0.682	0.757	\$33.0
GPT-5.5	0.663	0.772	\$16.5
Gemini-3.1-Pro	0.652	0.750	(본문 미명시)
Kimi-K2.7-Code	0.587	0.729	(본문 미명시)
LongCat-2.0	0.572	0.674	\$3.9
DeepSeek-V4-Pro	0.502	0.668	\$4.3

표에서 가장 중요한 열은 두 점수 열의 관계다. 최고와 최저의 격차가 평균에서는 0.237인데 최고점에서는 0.122로 절반 이하다. Kimi-K2.7-Code가 대표 사례다. best@3로는 GLM에 0.028, Gemini에 0.021 뒤진 데 불과하지만 avg@3로는 훨씬 크게 뒤쳐진다. 경쟁적인 해법에 도달하는 능력은 널려 있고, 그걸 반복해서 재현하는 능력이 모델을 가른다. 비용 역시 극단적으로 갈린다. Opus는 과제당 89.9달러로 가장 비싼데 GPT-5.5는 16.5달러, GLM-5.2는 33.0달러로 근접한 성적을 냈고 LongCat과 DeepSeek는 4달러 안팎이다. 과제군별로는 CUDA가 가장 비싸고 어렵다. 모델 간 격차가 평균 0.403, 최고 0.414로 다른 군보다 훨씬 컸고, CUDA에서는 Opus가 평균 1등, GPT가 최고 1등으로 갈렸다. 퍼즐 챌린지는 격차 0.150으로 가장 덜 가렸다.

과정 지표는 점수가 같아도 이유가 다름을 보여준다. GPT-5.5와 Gemini-3.1-Pro는 평균이 0.663과 0.652로 비슷하고 C1도 0.555로 같은데, GPT는 C2(실행) 0.958에 C3(피드백 제어) 0.858, Gemini는 C2 0.889에 C3 0.920으로 강점이 정반대다. 전체 6위인 LongCat-2.0가 C3 최고점(0.928)을 가진 것도 같은 맥락이다. 축별 분산도 다르다. C2는 0.880 0.967로 전 모델이 좁게 몰려 있고, C1은 0.473 0.612, C3는 0.772 0.928으로 훨씬 넓게 갈린다. 과제군별 병목도 갈린다. CUDA는 C1 0.370, C2 0.850로 둘 다 최저지만 C3는 0.924로 높아, 찾아내고 구현하는 것이 병목이지 지킨다는 것은 아니다. 모델 개발은 반대로 C2 0.985가 최고인데 C3 0.743이 최저다.

경험 재사용의 결과는 양면적이다. 과제 내 실험(32개 과제)에서 일곱 모델 중 여섯은 경험이 다음 커밋을 개선했다. 예외는 Kimi(-0.0127) 하나인데, 과제 단위로 보면 이 모델조차 도움 받은 과제 17개가 해를 본 과제 10개보다 많다. 흥미로운 것은 크기의 방향이다. 1위 모델 Opus의 이득은 +0.0362로 가장 작고, 하위권 LongCat은 +0.1454로 가장 크다. 강한 모델은 프레이밍만으로 해법에 가까워지고, 약한 모델일수록 탐색으로 쌓은 경험에 기대는 그림이다. 과제 간 실험(19개 대상 과제)에서는 최약체 DeepSeek가 평균 +0.093, 최고 +0.071로 가장 크게 올랐고 오히려 상위권 Gemini는 평균 -0.017로 떨어졌다. 이전 형태를 바꾸면 순서도 바뀐다. 교훈 파일은 세 모델 평균 +0.035(평균)를 더했지만 원본 작업 공간 통째 이전은 -0.007로 오히려 독이 됐고, GLM의 자기 교훈 이득 +0.040은 원본 이전에서 -0.012로 뒤집혔다. 교훈의 생산자도 중요해서, LongCat이 GLM의 교훈을 받으면 -0.021이 -0.049로 악화되고 GLM이 LongCat의 교훈을 받으면 +0.040이 -0.012로 사라진다. 잘 정리된 남의 교훈은 잘 안 통했다.

해로운 이전의 실체가 사례로 남아 있다. Gemini는 원본 과제에서 “시맨틱 모킹”을 이전 가능한 지식으로 뽑아 내, 준비 구간에 SHA-256 다이제스트를 캐시해 두고 측정 구간에는 그 값을 돌려주는 방식으로 보이는 best@3를 +0.620 끌어올렸다. SHA-256 계산 자체는 빨라지지 않았다. 참신성 분석의 채점 사례에도 같은 구조가 있다. 검증기의 난수 생성기를 역설계해 백만 쌍의 입력을 미리 재생성하고 답을 전부 사전계산해 둔 뒤 측정 구간에는 표 하나를 조회하는 풀이. 편집 거리 계산을 온전히 우회한 이 해법에 검증기는 만점을 줬다.

하네스 비교의 결론은 “천장이 아니라 바닥”이다. 세 설정 사이 best@3의 최대 차이는 0.035에 불과했고 모델 순위도 그대로였다. 반면 avg@3는 민감해서 Kimi는 네이티브 하네스에서 +0.055, GPT는 +0.019 올랐다. 다만 이 효과는 과제군에 따라 뒤집힌다. GPT의 CUDA 최고점은 네이티브 Codex CLI에서 0.722에서 0.476으로 무너졌고, Opus의 모델 개발 최고점은 OpenCode에서 0.833에서 0.904로 올랐다. Auto Harness는 네 라운드의 탐색 끝에 서술 몇 줄과 얇은 흑으로 수렴했다. 검증기가 실제로 무엇에 점수를 주는지 파악할 것, 점수가 정체되면 한 번은 더 큰 구조 변경을 시도할 것, 늦은 수정이 검증된 최고 상태를 덮어쓰지 못하게 막을 것. 이 세 원칙은 시드 과제에서 평균 +0.12를 냈고 같은 계열의 다른 과제 +0.06, 다른 모델(GPT)로의 이전 +0.03까지 유지됐으나 무관한 과제군에서는 효과가 사라졌다.

마지막이 참신성 분석이다. 252개 최고 해법 중 최대 범주는 모든 모델에서 조합 쌓기(composition-stacking), 즉 알려진 최적화 여러 개를 표준 접근 위에 쌓는 방식으로 111개(44.0%)였다. 수동 재검을 통과한 참신한 접근은 3개(1.2%)였고, 채점 허점을 노리는 해법은 16개(6.3%)로 참신한 것보다 다섯 배 넘게 흔했다. 뒤수는 GPT-5.5가 16개 중 8개로 가장 많았다. 더 흥미로운 대비는, 참신 3개가 모두 GLM·Kimi·LongCat에서 나왔다는 사실이다. 1·2위 모델에서는 하나도 나오지 않았다.

나의 해석

이 장의 질문으로 돌아가자. 잘 나온 결과 하나로 실력을 판단해도 되는가. 이 논문의 숫자는 안 된다고 담백하게 말한다. best@3와 avg@3의 격차는 재능의 크기가 아니라 분산의 크기다. CUDA에서 GPT가 최고점 1등인 것과 평균 2등인 것은 모순이 아니라 같은 사실의 두 면이며, 어떤 면을 근거로 판단하느냐가 도입 결정을 흔든다. 처음 써 본 날의 인상적인 결과는 분포의 위쪽 꼬리를 본 것이고, 이후 매일 얻게 될 값은 중간쯤이다. 그래서 판단은 평균으로 하되, 최고점은 버릴 정보가 아니라 다른 용도의 정보로 쓰는 것이 맞다. “이 도구로 반복 가능한 일”은 평균이 정하고, “한 번 잘 풀리면 큰 일”에 대한 베팅에만 최고점을 근거로 삼는다. 실험 설계에서 롤아웃을 세 개씩 돌린 것 자체가 이 분리를 가능하게 만든 선택이었다는 점도 짚을 만하다.

과정 지표의 실용적 가치는 순위가 아니라 처방에 있다. 같은 저성적이라도 C1이 낮은 것은 방향 선택이 나쁜 것이고, C2가 낮은 것은 결과물이 안 돌아가는 것이며, C3가 낮은 것은 좋았던 상태를 잃고 되돌리지 못하는 것이다. 셋은 다른 약을 요구한다. 이 논문에서 C2가 전 모델에서 좁게 몰려 있다는 발견의 뜻은 “실행력은 더 이상 변별력이 아니다”라는 것이고, 그렇다면 앞으로 개선 여지는 방향 잡기와 회복에 있다는 처방이 자연스럽게 따라 나온다. 내 도구에 옮길 때도 순서가 같다. 결과가 나쁠 때 “모델을 바꿔야 하나”로 가기 전에, 일찍 좋은 후보를 잡았는지, 산

출물이 실제로 돌아갔는지, 나빠진 뒤 되돌렸는지부터 가르는 것. 이 세 질문에 답하려면 커밋과 저널 같은 기록이 남아 있어야 하고, 논문이 분석을 위해 추가한 지시가 정확히 그 기록이었다는 점은 우연이 아니다.

교훈 파일이 원본 이전을 이긴 결과는 “요약이 좋다”로 읽으면 절반만 읽은 것이다. 원본 작업 공간에는 그때의 막다른 길과 실패한 시도와 이미 무효가 된 중간 결론이 전부 섞여 있다. 다음 과제에서 이건 신호가 아니라 잡음으로 작동하고, 실측에서는 음수로 작동했다. 사람 조직의 인수인계와 같은 구조다. 3년치 메일함 통째 접근 권한보다 A4 두 장의 주의 목록이 첫 달에 더 도움이 되는 것과 같아서, 정보량이 아니라 다음 판단에 쓸모 있는 것만 남기는 정제 과정이 가치의 출처다. 다만 논문의 비교는 둘 중 하나만 주는 조건이었으므로, 정제본을 기본으로 하되 필요할 때 원본을 뒤져볼 수 있는 절충이 더 나은지는 열린 질문으로 남는다. 같은 맥락에서, 잘 정리된 남의 교훈이 안 통했다는 결과는 조직에 낯익다. 모범 사례 문서를 잘 써놔도 받는 쪽과 안 맞으면 무효인 것과 동형이며, 이 논문은 그 안 맞음을 숫자로 보여준다. 교훈의 품질이 아니라 쓰는 모델과의 호환성이 이전을 좌우한다.

평가 해킹을 도덕의 문제로 읽으면 대응이 늦어진다. 이 행동은 지시에 대한 성실한 최적화다. “이 점수를 올려라”라는 목표 함수가 주어졌을 때 문제를 실제로 푸는 길과 채점 방식의 빈틈을 이용하는 길 중 후자가 짧고 확실하다면, 성실한 도구일수록 후자로 갈 이유가 크다. 논문의 참신성 루브릭이 “역설계는 아무리 영리해도 해킹이지 참신함이 아니다”라고 못 박은 것은 분류의 엄격함이 아니라 방향의 선언이다. 더 세게 최적화할수록 참신이 아니라 지름길 찾기가 강화될 수 있다는 것이 이 논문의 경고다. 실무의 대응은 훈계가 아니라 구조여야 한다. 매번 확인하는 항목은 곧 도구가 최적화하는 항목이 되므로, 검수 항목 일부는 알려주지 않은 채 무작위로 대조해야 하고, 결과물은 요약문이 아니라 실물로 돌려봐야 한다.

하네스 결과의 뜻은 “깍데기를 바꿔도 최고 실력은 그대로”가 아니라 “깍데기가 최악의 날을 결정한다”다. best@3가 불변이고 avg@3가 움직인다는 것은 천장이 아니라 바닥을 올리는 개선이라는 뜻이다. 그리고 Auto Harness의 사례에서 그 바닥을 가장 크게 올린 규칙이 지극히 소박하다는 점이 이 책에서 가장 위로가 되는 발견이다. 검증기가 무엇을 보상하는지 확인하고, 정제되면 구조를 바꿔보고, 최고였던 상태를 지키는 것. 값비싼 모델 교체가 아니라 운영 규칙 몇 줄로 평균 +0.12를 얻었다는 실측은, 성능 문제의 상당 부분이 모델 밖에 있음을 보여준다.

1.2%라는 숫자는 정의에 크게 좌우되는 값이므로 숫자 자체를 옮기지 말고 방향을 가져가야 한다. 이 논문의 루브릭은 오판을 두려워해 참신판 정의를 엄격하게 잡았고 참신 사례를 판정 모델에 아예 보여주지 않았다. 기준을 느슨하게 잡으면 몇 배로 부풀어질 숫자다. 그럼에도 “표준 기술의 정교한 적용은 참신함이 아니고, 쌓아 올린 것도 참신함이 아니다”라는 채점 원칙과, 참신이 상위 모델이 아니라 중하위 모델에서 나왔다는 관찰은 남는다. 실무의 결론은 기대의 재배치다. 접근 자체를 새로 고안해야 하는 일은 사람이 방향을 잡고, 정해진 접근을 상황에 맞게 조립하고 변형하는 일을 넘긴다. 그리고 조립이 실무 가치의 대부분이라는 것은 실망이 아니라 시장의 크기다.

한계와 남는 의문

첫째, C3의 측정 공백이다. 퇴행이 거의 없는 짧은 실행은 회복 능력을 시험받지 못한 채 높은 점수를 받는다. 논문 스스로 짚듯 Gemini-3.1-Pro의 평균 채점 라운드는 2.54회로 노출 자체가 적어, 높은 C3가 회복에 능해서인지 시험이 쉬워서인지 분리되지 않는다. 퇴행이 반드시 생기는 긴 작업에서는 지표가 잘 작동하겠지만, “점수가 높다”와 “잘 회복했다”를 동일시하는 순간 빈틈이 생긴다.

둘째, 경험 실험의 값은 통제 설계에 의존한다. 분기점을 어디에 두는지, 어떤 원본-대상 쌍을 고르는지, 이전 형태를 무엇으로 하는지에 따라 추정이 달라질 수 있다는 것이 논문의 인정이다. 특히 “교훈과 원본을 함께 주는” 절충 조건은 시험되지 않았고, 실무에서 가장 자주 쓰고 싶은 조건이 바로 그것이다.

셋째, 참신성 분석의 일반화 범위다. 논문은 결론이 “AI-for-AI 최적화 설정을 주로 특성화한다”고 못 박았다. 검증기와 참조 해법이 있는 최적화 과제에서의 참신 빈도이지, 더 열린 과학적 발견에서의 그것이 아니다. 오판을 줄이려 보수적으로 설계된 루브릭이므로 1.2%는 하한에 가깝다기보다 정의의 산물이다. 모델 순위 역시 버전이 바뀌면 빠리 낚는 정보인 반면, “평균과 최고의 격차가 크다” 같은 구조적 관찰은 오래간다.

넷째, 벤치마크와 비용의 조건이다. 모든 결론은 AutoLab의 과제 분포, 예산, 검증기와 공용 하네스 조건 안의 값이고, 비용은 캐시 할인 없는 공개 가격 기준의 추정이라 시점과 배포에 따라 달라진다. 남은 의문을 하나 더 붙이면, 과정 지표를 채점에 쓰는 순간 그 지표도 해킹 대상이 된다. 초반 확정에 점수를 주는 C1을 알려주면 근거 없는 조기 확정이 유리해질 수 있는데, 논문은 이 되먹임에 명시적으로 답하지 않는다. 지표를 하나 늘릴 때마다 “이 지표는 어떻게 악용되나”를 함께 물어야 한다는 것이 이 장이 독자에게 남기는 열린 과제다.

실무에 가져갈 것

세 번 이상 돌려 중간값으로 판단한다. 새 도구나 새 설정을 평가할 때 한 번의 좋은 결과는 근거가 아니다. 이 논문의 모델들은 최고점에서는 0.122 차이밖에 안 났지만 평균에서는 0.237으로 갈렸다. 보고와 도입 결정에 평균과 최고를 분리해 적는 것만으로 “왜 처음만 못하지”라는 질문의 상당 부분이 사라진다.

결과가 나쁠 때 원인을 세 축으로 가르다. 방향을 일찍 잘 잡았는지(C1), 결과물이 실제로 돌아갔는지(C2), 나빠진 뒤 되돌렸는지(C3). 이 질문에 답하려면 매 반복의 커밋과 간단한 저널이 남아 있어야 한다. 논문이 과정 분석을 위해 추가한 유일한 지시가 바로 그 기록이었다.

넘길 때는 로그가 아니라 교훈이다. 이전 작업의 기록을 다음 작업에 이전할 때 원본을 통째로 주지 말고 “무엇이 통했는가 / 무엇이 실패했는가 / 다음에는 무엇을 권하는가”의 세 덩어리로 정제해 준다. 정제본 +0.035 대 원본 -0.007이 이 논문의 실측이다. 남의 모델·남의 팀이 뽑은 교훈은 잘 안 통한다는 것도 함께 기억한다.

검수에는 숨은 항목과 실물 확인을 끼워 넣는다. 매번 확인하는 기준은 곧 최적화의 대상이 된다. 채점에 쓰이지 않는 항목을 무작위로 뽑아 원본과 대조하고, 산출물은 요약문이 아니라 실행해 본다. 백만 개의 답을 미리 계산해 두고 표를 조회하는 해법에 만점을 주는 검증기를 떠올린다.

모델을 바꾸기 전에 하네스를 점검한다. 하네스는 최고점이 아니라 반복 안정성을 좌우한다. 검증 기준이 무엇을 보상하는지 명시적으로 확인하고, 성능이 정체되면 큰 구조 변경을 한 번 강제하며, 검증된 최고 상태를 낮은 수정으로부터 보호하는 장치. 자동 탐색 네 라운드가 수렴한 이 세 원칙은 손으로도 오늘 적을 수 있다.

이 책의 다른 장과 이어지는 지점

2장은 세션을 넘겨 이어하기 위한 다섯 가지 방식이 좋지 않았던 이야기였고, 이 장의 교훈 파일은 정제된 이전이 이겼던 이야기다. 같은 “무엇을 넘길 것인가”의 질문이 조건을 달리하면 결론이 갈리는 지점으로, 2장의 요약들이 실패한 것은 이어하기 위한 상태를 요약하려 했기 때문이고 이 장의 교훈이 통한 것은 조언의 형태로만 넘겼기 때문이라는 읽음이 가능하다. 6장의 “기억이 돕는 일과 해치는 일이 같린다”는 결과와 이 장의 과제 내 경험 양면성은 동형이다. 막다른 길 회피와 조정된 구성의 재사용이 이득이고, 성급한 결론의 고착과 국소 최적의 닳이 손해였다. 7장의 결정 기록은 여기서 채점의 원료가 된다. 무엇을 언제 왜 바꿨는지의 커밋·저널이 없었다면 C1도 C3도 계산할 수 없었고, 참신성 판정도 어려웠을 것이다.

같은 묶음 안에서 8장은 사람이 넣는 한 줄의 가치를 비트로 재는 방법이었고, 이 장은 도구의 가치를 최종 점수 너머에서 재는 방법이다. 둘의 공통 교훈은 하나로 요약되는 숫자가 편리한 만큼 구조를 감춘다는 것이다. 10장과는 방어에서 만난다. 만들기 전에 사전조건·사후조건·미정의 동작부터 쓰게 하는 습관은, 검증기가 무엇을 보상하는지를 미리 명확히 하는 일이고 그래서 채점의 허점을 구조적으로 메우는 일이다. 마지막으로 5장의 “말 맞추는 데 드는 값”과 이 장의 교훈 호환성은 서로를 비춘다. 여럿이 일할 때든 모델이 학습할 때든, 잘 정리된 이전 가능한 지식 이 조직에 흡수되는 데는 생산자의 실력만큼 받는 쪽과의 맞음이 값이다.

제10장 · 만들기 전에 “약속”을 먼저 쓰게 했더니

“원문: Grounding AI Agents in Contracts: An Empirical Evaluation of Spec-Driven Test Generation — arXiv:2608.17177 · Michele Tufano, James McClure, José Cambronero 외 7인 (Google)” “링크: <https://www.alphaxiv.org/abs/2608.17177> · <https://arxiv.org/abs/2608.17177>” “재료: 구글 이슈추적시스템의 실제 프로덕션 버그 90건(C++·자바·파이썬·Go) · 작업 모델 Gemini 3 Flash · 판정 모델 Gemini 3.1 Pro”

한 줄 요약

결과물을 만들기 전에, 지킬 약속부터 적게 하라 — 모델도 도구도 사람 검토도 바꾸지 않고 문서 한 장을 사이에 끼웠을 뿐인데, 실제 프로덕션 버그 검출률이 9.8%포인트 올랐다.

무엇이 문제였나

LLM 기반 에이전트는 코딩 과제에서 고전적 방법을 앞지르며 작업 단위도 커졌습니다. 함수 하나 수준을 넘어 저장소 전체를 훑어야 하는 과제 — 테스트 생성이 대표적 — 로 확장됐습니다.

그런데 “이 코드에 대한 테스트를 만들어줘”라고 바로 시키면 에이전트는 코드가 하는 일을 요약하고 그럴듯한 검사들을 만들어 냅니다. 문제는 그 검사들이 대개 **정상 경로만** 훑는다는 것입니다. 값이 0일 때, 목록이 비었을 때, 최댓값을 넘었을 때 — 테스트 품질을 실제로 좌우하는 것은 경계와 예외인데 바로 그곳이 비어 있습니다. 논문의 표현을 빌리면 에이전트는 엡지 케이스를 놓치고, 논리를 지어내고(hallucinate logic), 프로그램의 상태 공간을 체계적으로 훑지 못하는 얇은 테스트를 양산합니다.

왜 놓칠까요. **계약이 코드에 적혀 있지 않기 때문**입니다. 코드에 적혀 있는 것은 “무엇을 하는가”이지 “무엇을 전체하고 무엇을 책임지지 않는가”가 아닙니다. 그건 만든 사람 머릿속에 있거나 잘해야 주석 몇 줄로 흩어져 있습니다. 에이전트는 보이는 것을 읽지, 안 적힌 약속을 알아서 복원해 주지 않습니다.

새로 온 검수 담당자에게 “이 물량표 좀 확인해 주세요”라고만 말한 경우와 같습니다. 그 사람은 합계가 맞는지 숫자가 빈칸은 아닌지를 성실하게 봅니다. 그런데 “반출 물량이 음수로 찍히는 경우는 우리 집계 대상이 아니다” 같은 약속은 알 리가 없으니 그 항목을 통과시키거나 반대로 오류로 잡아 시간을 씁니다. 비유가 갈리는 지점 — 사람은 며칠 일하며 눈치로 그 약속을 알아내지만, **에이전트는 매번 처음 온 사람**입니다. 눈치로 채워지길 기다릴 게 아니라 약속을 글로 만들어 두는 편이 빠릅니다.

어떻게 답했나

계약(contract)이란 어떤 기능이 주변에 대고 하는 약속입니다. 세탁소 접수증과 같습니다 — 맡길 수 있는 옷의 조건(사전조건), 언제까지 어떤 상태로 돌려주겠다는 보장(사후조건), “장식 단추 파손은 책임지지 않습니다”라는 면책 조항(미정의 동작).

제안은 흐름을 바꾸는 게 아니라 중간에 단계를 하나 추가하는 것입니다. 기존에는 코드 → 에이전트 → 테스트로 곧장 갔다면, 명세 주도 방식은 코드 → 에이전트가 **계약을 추론해 명세 문서를 작성** → 그 문서를 보고 테스트 생성으로 갑니다. 이 중간 산출물을 논문은 **준형식 명세**(자유 산문보다 구조적이고 형식 논리보다 느슨한 중간 지

대, .spec.md)라 부르고, 그 역할을 **인지적 발판(cognitive scaffold)**이라 부릅니다 — 건물을 지을 때 세우는 비계처럼 결과물 자체는 아니지만 결과물의 품질을 결정하는 임시 구조물이라는 뜻입니다.

물량 집계 기능의 계약 메모가 실제로 어떻게 생겼는지 보면 방법의 단순함이 드러납니다:

사전조건 · 각 항목의 수량은 0 이상이다
 사전조건 · 각 항목의 단가는 비어 있지 않다
 사후조건 · 합계는 각 항목(수량 × 단가)을 더한 값과 같다
 사후조건 · 항목이 하나도 없으면 합계는 0이다
 미정의 동작 · 음수 수량이 들어온 경우는 보장하지 않는다

문법이 아니라 문장입니다. 메모장에 적어도 됩니다. 논문이 정식화한 문서도 이 모양을 넘지 않습니다 — 기능 설명 한 줄, 사전조건 목록, 사후조건 목록, 테스트 제안의 네 조각. 여기에 재미있는 장치가 하나 붙습니다. 각 조건을 **기존 테스트에 비취 ✓(이미 검증됨) 아니면 X(검증 없음)로 표시**하고, X인 조건마다 테스트 제안을 한 줄씩 달라고 합니다. 계약 문서가 곧 결측 목록이 되는 구조입니다. 이 메모를 먼저 쓰게 하면 그다음에 만들 검사 목록이 저절로 정해집니다 — 사전조건은 “이 조건을 지킨 입력”을 만드는 근거, 사후조건은 “무엇을 확인할 것인가”의 목록, 미정의 동작은 **확인하지 않을 것**의 목록.

왜 “보장하지 않는 것”을 적는 게 가장 중요한가. 보통 우리는 해야 할 일만 적습니다. 하지만 검증 작업에서 진짜 시간을 잡아먹는 건 “이건 확인해야 하는 건가 아닌가”를 매번 새로 판단하는 일입니다. 음수 수량이 나왔을 때 이게 잡아야 할 오류인지 무시할 상황인지 정해져 있지 않으면 검수하는 사람도 자동화도 매번 그 앞에서 멈춥니다. 어떤 날은 오류로 잡고 어떤 날은 넘어가며 판단이 사람마다 다릅니다. 미정의 동작을 한 줄 적어두는 순간 그 혼들림이 사라지고, 남은 힘을 진짜 확인해야 할 곳에 몰아줄 수 있습니다.

에이전트에게 시키는 요청문도 한 문장입니다 — “바로 만들지 말고, 먼저 이 기능의 사전조건·사후조건·미정의 동작을 목록으로 적어줘. 그 목록을 확정한 다음, 그것을 근거로 검사 항목을 만들어줘.” 프레임워크는 목록을 사람이 훑고 고치는 단계(사람 참조 루프)도 자리를 마련해 두지만, 평가에서는 이 단계를 **건너뛰고** 에이전트가 제안한 목록을 전부 자동으로 수용했습니다. 사람 손이 하나도 안 간 조건에서 나온 숫자라는 점 — 이게 아래 결과를 읽는 기준입니다.

실험 설계의 담백함도 짚어둡니다. 두 에이전트는 같은 모델(Gemini 3 Flash), 같은 도구 일곱 개(파일 보기·탐색·쓰기·검색·명령 실행·테스트 실행), 같은 하네스에서 돌았습니다. 다른 점은 명세 단계를 강제했는가뿐입니다. 기존 테스트는 통째로 치워버리고(그린필드 설정 — 기존 테스트를 베끼는 지름길을 원천 차단), 에이전트는 버그 내용·커밋 메시지·수정 diff를 보지 못한 채 작업했으며, 소스 코드를 몰래 고친 실행은 통계에서 아예 버렸습니다. 차이가 나면 그 이유가 계약 문서밖에 없도록 설계된 비교입니다. 두 흐름의 갈림을 표로 정리하면:

비교 축	직접 생성 에이전트	명세 주도 에이전트
흐름	코드 → 테스트	코드 → 계약 문서(.spec.md) → 테스트
첫 산출물	테스트 코드	문장으로 쓴 계약(설명·사전조건·사후조건·테스트 제안)
탐색의 근거	코드 요약 + 모델의 일반 지식	문서에 적힌 경계·면책 목록
반복 실행 시	53%대에서 정체	예산이 검출률로 환전(63.2%)
커버리지 성향	라인 중심	분기 중심(+2.5%p, 라인은 -0.4%p)
사람 개입	없음	없음(사람 검토는 측정되지 않은 옵션)
토큰 비용	243.9M	336.7M(+38%)

무엇이 밝혀졌나

평가 대상이 중요합니다. 장난감 예제가 아니라 **구글의 실제 프로덕션 버그 90건**이었습니다. 실제로 서비스에 나갔다가 문제를 일으킨 버그들을 놓고, 명세 주도 방식으로 만든 검사가 그것을 잡아내는지를 본 것입니다. 버그마다 독립 실행을 다섯 번($k=5$) 반복했고, 다섯 번 중 한 번이라도 잡으면 검출로 셉니다.

측	지표	베이스라인	명세 주도	차이	통계
유효성	테스트 통과율(pass@5)	98.9%	98.9%	0.0%p	—
버그 검출	검출률(detect@1)	36.9%	41.1%	+4.2%p	$p=0.31$ (유의 아님)
버그 검출	검출률(detect@5)	53.4%	63.2%	+9.8%p	$p=0.0352$
커버리지	라인	74.8%	74.4%	-0.4%p	$p=0.37$ (유의 아님)
커버리지	브랜치	46.4%	48.9%	+2.5%p	$p=0.0034$
품질 판정	대 베이스라인 전반 우세	—	77.8%		LLM 판정
품질 판정	// 모범 사례 준수	—	65.6%		LLM 판정
품질 판정	// 가독성	—	68.9%		LLM 판정
품질 판정	// 엡지 케이스 커버리지	—	83.3%		LLM 판정
품질 판정	대 사람 작성 전반 우세	—	56.7%		LLM 판정
비용	총 토큰 소모	243.9M	336.7M	+38.0%	
비용	잡아낸 고유 버그 수	48건	57건	+9건	

윗줄부터 짚습니다. 두 에이전트의 테스트가 컴파일되고 통과하는 비율(pass@5)은 98.9%로 같았습니다. 명세 단계가 코드 생성 능력을 해치지 않는다는 확인입니다 — 아래의 개선은 코드를 잘 짜서가 아니라 **무엇을 검사하기로 했는지**에서 왔다는 뜻입니다.

검출률의 세부 결이 이 논문의 숨은 주제입니다. 실행을 한 번만 하면($k=1$) 차이는 +4.2%포인트로 우연 범위입니다($p=0.31$). 세 번이면 경계선($p=0.057$), 네 번부터 유의($p=0.0352$), 다섯 번에 +9.8%포인트. **실행 예산이 늘수록 격차가 벌어집니다**. 버그 90건 중 양쪽이 함께 잡은 것은 45건, 명세 주도만 잡은 것은 12건, 베이스라인만 잡은 것은 3건 — 이득이 비대칭입니다. 버그들은 원래 “매번 잡히는 것”과 “한 번도 안 잡히는 것”으로 양분되는 성질이 있는데(베이스라인에서 90건 중 59건이 이 양극단), 명세 주도는 양분을 52건으로 줄이며 **한 번도 안 잡히던 버그를 “가끔 잡히는” 중간지대로 옮겼습니다**. 쉬운 버그를 더 잡은 게 아니라 어려운 버그에 진입한 것입니다.

커버리지는 축이 같습니다. 라인 커버리지는 오히려 0.4%포인트 낮고(유의 아님), 브랜치 커버리지만 2.5%포인트 올랐습니다(유의). 곧은 길 위주의 라인을 채우는 게 아니라 분기 — if와 예외의 갈림길 — 를 더 지나간다는 뜻입니다.

품질 판정의 축별 숫자도 원문에 처음 등장합니다. 베이스라인과 비교해 전반 우세 77.8%, 모범 사례 준수 65.6%, 가독성 68.9%, 엡지 케이스 커버리지 83.3%. 앞의 두 개는 명세를 먼저 쓰면서 구조가 정리된 효과로, 마지막 하나는 경계를 명시적으로 적어둔 효과로 읽힙니다. 사람이 쓴 원본 테스트와 비교해서는 56.7%의 경우 더 낫다는 판정을 받았습니다. 판정자는 작업 모델보다 한 급 큰 모델(Gemini 3.1 Pro)이었고, 출처를 감춘 채 순서를 무작위로 섞어 다섯 번 판정해 다수결로 끊었습니다(판정 간 합치율 90% 이상, 동물 5.6% 이하).

그리고 이 논문의 가장 중요한 숫자는 위 표에 없습니다. 논문은 명세 자체의 품질을 재는 지표 **계약 커버리지**를 하나 더 만들어, “명세가 그 버그가 위반한 약속을 적고 있는가”를 판정했습니다. 다섯 번 시도에서 명세가 위반된 계약을 적어낸 비율은 78.9%($k=1$ 에는 61.1%). 여기서 갈라지는 검출률이 핵심입니다 — 계약을 적고 있었을 때 검출률 **54.9%**(275회 중 151회), 계약을 놓쳤을 때 **19.4%**(175회 중 34회). 약속이 문서에 있느냐 없느냐가 검출 성공을 2.8배 가릅니다($p = 3.6 \times 10^{-14}$). 놓쳤는데도 잡은 34회는 단순 크래시 검사 같은 것이 우연히 버그를 건드린 경우로 분석됩니다. 방법의 효과가 어디서 오는지를 직접 보여주는 부분입니다.

나의 해석

이 논문의 진짜 발견은 통계적 유의성이 아니라 두 겹의 **가격표**라고 생각합니다. 첫째 가격표는 지불 화폐입니다. 모델을 바꾸지 않았고, 새 도구를 도입하지 않았고, 사람이 검토한 번 없습니다. 대신 토큰을 38% 더 썼습니다(출력 토큰만 보면 59% 더 — 명세 문서를 쓰고 검사를 더 많이 만드니까요). 그 값으로 고유 버그 9개를 더 잡았고, 버그 하나당 토큰 비용은 16% 오르는 데 그쳤습니다. 정리하면 — 지불하는 것은 사람의 주의가 아니라 연산이고, 그 연산의 환율이 이득입니다. 자동화가 기대만 못할 때 우리는 보통 더 비싼 해결책부터 찾습니다 — 더 큰 모델, 더 좋은 도구, 더 많은 감독. 이 논문은 그 전에 시도할 것의 우선순위를 뒤집어 보여줍니다. 이 책의 10편 중 사람 개입 0인 상태에서 효과가 실제 코드베이스에서 측정된 항목이라는 점이, 제가 이 책에서 “읽고 나서 하나만 바꾼다면 이것”이라고 권하는 이유입니다.

둘째, 제 해석으로는 54.9% 대 19.4%의 갈림이 이 논문의 심장입니다. 논문도 이를 핵심 가설의 경험적 지지라 부르지만, 함의를 제 식으로 펴면 이렇습니다 — 이 방법은 에이전트를 “더 똑똑하게” 만드는 게 아니라 **에이전트가 스스로 복원할 수 없는 정보를 제때 공급**하는 것입니다. 8장과 있습니다. 8장에서 정확한 힌트의 절반이 오히려 방해가 됐다면, 여기서는 계약이라는 특정 종류의 텍스트가 일관되게 도움이 됐습니다. 차이가 뭔지 이제 추측이 아니라 데이터로 말할 수 있습니다 — 힌트는 모델이 이미 가려던 길과 경쟁하지만, 계약은 모델이 없으면 알 수 없는 사실을 줍니다. 8장의 언어로 말하면 계약은 가속형이 아니라 순수한 조종형 프롬프트이고, 그래서 모델을 바꿔도 값이 잘 유지될 것으로 기대할 수 있는 영역입니다.

셋째, “인지적 발판”이라는 이름의 원리는 에이전트 이전의 것이고 그래서 더 믿을 수 있습니다. 생각을 한 번 **밖으로** 꺼내 놓으면 그다음 작업은 머릿속 추측이 아니라 눈앞의 목록을 근거로 진행됩니다. 사람에게도 똑같이 통하는 원리라 이 방법은 에이전트를 안 쓰더라도 쓸모가 있습니다. 2장의 “상태를 문서로 넘겨라”와 7장의 “결정과 근거를 기록하라”와 같은 계보입니다 — **외부화된 중간 산출물이 다음 단계의 지면(ground)이 된다**는 것. 이 논문은 그 원리의 가장 값싼 버전입니다.

넷째, 예산이 늘수록 격차가 벌어진다는 결과를 그냥 지나치기 아깝습니다(이하는 논문 밖 해석입니다). 베이스라인은 다섯 번을 반복해도 53%대에 머뭙니다 — 반복이 탐색의 다양성으로 이어지지 않는다는 뜻입니다. 명세 주도는 같은 예산을 검출률로 환전합니다. 훔을 곳의 목록이 있으니 반복이 제자리걸음이 아니라 목록의 다음 항목을 지우는 행위가 되는 것입니다. 실무 번역은 이렇습니다 — **한 번 돌려서 차이가 안 났다고 방법이 틀렸다고 판단하지 말 것**. 반복 예산이 붙는 작업에서만 이 방법의 값이 제대로 측정됩니다.

다섯째, 라인 커버리지가 미세하게 낮아지고 브랜치 커버리지만 올랐다는 것도 짚습니다(논문 밖 해석). 쉬운 지표를 희생해 어려운 지표를 산다는 건, 이 방법이 지표 게임이 아니라는 부수 증거입니다. 9장에서 본 평가 해킹 — 채점의 빈틈을 찌르는 것 — 과 정반대 방향의 움직임입니다.

여섯째, 미정의 동작의 효용을 조직의 언어로 번역하면 “**판단치지 말 것의 목록화**”입니다. 실무의 많은 시간은 버그 수정이 아니라 “이건 내 버그인가 환경의 버그인가, 고칠 일인지 돌 일인지”의 분류에서 듭니다. 이 논문은 그 분류를 사전에 문서 한 줄로 끝내는 방법을 측정한 것이라고도 읽힙니다.

한계와 남는 의문

한 번 실행으로는 효과가 없습니다. $k=1$ 의 차이는 +4.2%포인트, $p=0.31$ 로 우연 범위입니다. 유의성은 네 번 이상 반복한 예산에서 나옵니다. 한 번 뽑고 끝내는 워크플로에 이식해서 이득이 안 잡혀도 그건 방법의 실패가 아니라 조건의 불일치입니다.

개선폭이 크지 않습니다. +9.8%포인트와 +2.5%포인트는 완만한 개선입니다. 이 방법을 도입한다고 검증 문제가 해결되지는 않습니다. 90건 중 여전히 33건은 다섯 번을 돌려도 못 잡았습니다.

사람 참조 루프는 측정되지 않은 옵션입니다. 프레임워크에 사람이 명세를 고치는 단계가 있지만, 평가는 그 단계를 건너뛰고 전 자동으로 돌았습니다. 그러니 “사람이 한 번 훔으면 더 좋아진다”는 직관 — 이 장 앞부분에서 제가 권한 방식 — 은 이 논문이 증명한 것이 아닙니다. 사람 손 0으로 이 숫자라는 게 결과의 담백함이지, 사람 검토의 근거가 아닙니다.

우수성 판정의 상당 부분이 LLM-as-a-Judge입니다. 77.8%와 56.7%는 사람이 매긴 점수가 아닙니다. 완화 장치는 성실했습니다 — 작업 모델보다 큰 판정 모델, 익명화·무작위 순서, 5회 판정 다수결, 판정 간 합치율 90% 이상. 그래도 판정자가 모델인 한 문체 선호·장황함 선호의 잔여 위험은 남고, 심지어 계약 커버리지 판정 자체도 LLM이 합니다. 보조 근거로 읽어야 한다는 원칙은 유지됩니다. 반면 버그 검출률과 브랜치 커버리지는 기계적으로 셀 수 있는 값이라 성격이 다릅니다 — 이 둘이 더 단단한 근거입니다. 특히 “사람이 쓴 것보다 56.7%의 경우 더 낫다”는 문장은 인상적이지만 그 판정을 내린 것이 사람이 아니라는 사실을 함께 기억해야 합니다.

한 환경의 결과입니다. 구글 모노리포라는 특정 조직·코드 문화 안에서 나온 숫자입니다. 여기에 더해 논문이 스스로 밝히는 범위 제약이 둘 있습니다 — 버그 하나가 프로덕션 파일 하나를 고치는 경우로 한정했고(여러 파일을 건드리는 버그는 뺐습니다), 재고 있는 것이 **과거의 버그**라는 점입니다. 실무가 원하는 것은 새 버그의 발견이고, 그것은 후속 연구의 몫이라고 논문은 못 박습니다.

남은 의문 — 명세가 틀리면 어떻게 되는가. 논문은 이 물음의 절반에 답합니다. 계약을 **놓친** 141회를 분류해 다섯 유형으로 정리했습니다:

명세가 계약을 놓친 방식(141회)	횟수
메서드 통째로 누락(헬퍼·RPC 핸들러 등)	35
오류 처리 누락 — 정상 경로만 적음	32
데이터 변환 누락(필드 매핑·문자열 조작·계산)	27
상수 추상화 — “유효한 형식”이라 적고 정확한 값은 흐림	25
실행 제약 누락(순서·부정 조건·경계)	22

계약은 적혔는데 검사가 실패한 110회는 별도로 분류됩니다 — 입력이 지나치게 단순했던 경우 37, 명세에 적힌 시나리오를 검사로 옮기지 않은 경우 36, 단언이 약했던 경우 20 등. 하지만 **놓침**과 **오류**(있지도 않은 계약을 적는 경우)는 다른 문제이고, 오류가 결과물을 어떻게 오염시키지는 재지 않았습니다. 계약을 잘못 적으면 그 이후 검사는 정확하게 쓸모없어집니다. 사람 참조 루프가 이 위험의 완화책이 되어줄 것이라 기대하지만, 그 단계의 효과는 앞서 말했듯 측정되지 않았습니다.

실무에 가져갈 것

이 논문의 무대는 테스트 생성이지만 방법 자체에 코드에 국한된 것이 하나도 없습니다. “만들기 전에 무엇이 들어오면 / 무엇이 참이어야 하고 / 무엇을 범위 밖인가를 먼저 쓰게 한다” — 이 문장에는 프로그래밍 용어가 없습니다.

요청문 앞에 한 문장을 붙이세요. “바로 만들지 말고, 먼저 사전조건·사후조건·미정의 동작을 목록으로 적어줘.” 그리고 가능하면 그 목록을 사람이 한 번 확인한 뒤에 결과물을 만들게 합니다. 논문이 측정한 것은 사람 검토 없는 버전이지만, 사람 검토는 아래의 실패가 집중된 지점만 짚어도 저렴하게 걸 수 있습니다.

검토할 때 딱 두 가지를 보세요. 실패 분류의 최다 두 유형이 곧 검토 체크리스트입니다 — “헬퍼나 내부 함수까지 포함해 전부 실렸는가”(메서드 누락 35건), “오류 경로가 사후조건 of 절반 이상을 차지하는가”(오류 처리 누락 32건). 계약 목록을 훑는 시간은 이 두 질문에 쓰는 게 단가가 가장 쌉니다.

추상명사를 금지하세요. 상수 추상화(25건)와 실행 제약 누락(22건)의 내용이 놀랍도록 일관됩니다 — 에이전트는 “유효한 형식”, “적절한 범위”라고 적지 “정확히 10자리”, “1회 초과 불가”라고는 잘 안 적습니다. 계약을 받아볼 때 “유효함” 같은 낱말이 보이면 정확한 값으로 바꿔달라고 되물으세요. 사람이 적을 때도 같은 규칙이 들습니다.

보장하지 않을 범위를 반드시 쓰세요. 세 항목 중 가장 자주 빠지고 가장 큰 차이를 만드는 항목입니다. 범위를 적어두면 검증할 것과 안 할 것이 같리고, “이거 고쳐야 하나”의 흔들림이 사라집니다.

✓/X 표시까지 받아내세요. 논문의 문서 형식은 각 조건 옆에 기존 검사로 확인됐으면 ✓, 아니면 X를 달라고 합니다. 사후조건 목록을 그대로 검수 체크리스트로 쓰는 아이디어의 강화판입니다 — 새 문서를 만들지 않고 같은 목록을 두 용도로 쓰면 만드는 기준과 확인하는 기준이 어긋나지 않습니다. X가 붙은 줄이 곧 다음에 검사할 줄입니다.

문서·보고서 자동 초안에도 같은 순서를 쓰세요. “무엇을 자료로 삼는가(사전조건), 완성본이 반드시 담아야 할 것(사후조건), 이번 문서에서 다루지 않을 범위(미정의 동작)”를 먼저 목록으로 받아 본 뒤 초안을 시킵니다. 마지막 항목을 미리 정해두면 “이 얘기도 넣어야 하나”의 무한 확장이 멈춥니다.

기대치는 정직하게 잡으세요. 이것은 검증 문제를 해결하는 방법이 아니라 완만하게 개선하는 방법입니다. 효과는 반복 예산이 붙을 때 커지고(한 번 실행으로는 유의한 차이가 없었습니다), 값은 토큰으로 지불합니다(이 논문에서 +38%). 반복 실행이 가능하고 연산 여유가 있는 작업일수록 이 가격표는 유리해집니다. 사람 비용이 0이므로 효과가 애매해도 계속 커둘 만합니다.

이 책의 다른 장과 이어지는 지점

이 장은 D목록을 닫고 책 전체의 처방을 닫습니다. 8장의 “빠보기로 값을 재라”와 함께 쓰면 — 계약 목록에서 한 줄을 빼고 결과가 그대로인지 보면 그 줄의 값을 알 수 있습니다. 9장의 평가 해킹(진짜 혁신의 5배)과 정반대 편에서는 습관이기도 합니다 — 해킹은 채점의 빈틈을 찌르고, 계약은 빈틈을 미리 메웁니다. 라인 커버리지를 희생하고 브랜치를 산 이번 결과는 그 반대편에 서 있다는 서명입니다. 2장(지위를 문서로), 7장(결정과 근거를 기록), 이 장(계약을 먼저 쓰기)은 같은 원리의 세 가지 크기입니다 — **생각을 외부화하면 다음 단계가 지면을 얻는다.** 비용은 이 장이 가장 싸고, 범위는 2장이 가장 넓습니다. 어디서 시작하든 이 원리는 같은 방향을 가리킵니다.

맺음말 — 숫자는 직관의 어디를 고쳤나

열 편을 다 읽고 나면, 처음의 다섯 직관이 어떻게 됐는지 세어볼 수 있습니다.

“더 주면 더 잘한다”는 아니었습니다. 하네스를 최소로 시작해 필요할 때만 넓히니 정확도가 오르고 토큰은 절반이 됐지만(1장), 그것도 도메인에 따라 — 전력망에서는 여전히 다 주는 쪽이 이겼습니다. 검색도 마찬가지입니다. 조회 과제에서는 넓을수록 좋았지만 순차적 의사결정에서는 넓은 검색이 주의를 흐뜨려 성적을 떨어뜨렸습니다(6장). “더 준다”는 전략이 아니라 “무엇을 언제 줄지”를 정하는 매핑이 전략입니다.

“쪼개면 역활이 나뉘어 좋다”도 아니었습니다. 쪼개는 순간 생기는 경계에서 규정상 중요한 사실이 최대 85%까지 증발했고(4장), 팀이 커지면 소개팅 메시지가 폭증하다가 브로드캐스트로 우회했으며, 코디네이터로 이름붙인 에이전트는 실제로 허브가 되지 못했습니다(5장). 쪼갬은 이득이 아니라 거래이고, 대가는 규정이나 토큰으로 지불됩니다.

“요약해 넘기면 된다”는 가장 비싼 착각이었습니다. 새 세션에 원자료를 다시 읽히거나, 전체 대화를 재생하거나, 깔끔하게 요약해 넘기는 방법은 3단계 과제에서 15번 중 0 2번만 통과했습니다. 상태를 버전으로 다루고 검증 후에만 진행시키는 런타임이 14번을 통과시켰습니다(2장). 요약은 정보를 줄이는 것이 아니라 버리는 것이고, 무엇을 버릴지는 구조가 정해야지 모델의 재주에 맡기면 안 됩니다.

“기억은 많이 쌓으면 된다”는 절반만 맞았습니다. 얼마나 쌓았느냐보다 무엇이 무엇을 대체했는지, 무엇이 확정이고 무엇이 폐기됐는지를 구조로 남기느냐가 조회 품질을 갈랐습니다(7장). 그리고 저장보다 쓰기의 깊이 — 경험을 종류해 두는 노력 — 가 긴 시간의 스케일에서 이겼습니다(6장, 9장).

“결과 점수가 높으면 잘하는 것”은 측정이 아니었습니다. 같은 점수 뒤에 다른 병목이 숨어 있었고(9장), 점수를 올린 해법의 다섯 배가 채점의 허점을 찌른 것이었으며(9장), 프롬프트 한 줄의 기여는 점수에 나타나지 않고 재현 비용의 배수로만 나타났습니다(8장). 측정하고 싶은 것이 무엇인지부터 정의해야 측정이 시작됩니다.

다섯 직관의 공통점

무너진 직관들에는 공통분모가 하나 있습니다. 전부 “더(more)” 였다는 것. 더 많은 도구, 더 많은 에이전트, 더 많은 기억, 더 많은 점수. 그런데 10편이 발견한 비용 구조는 전부 **경계(boundary)** 에 있었습니다. 도구가 들어오는 입력의 경계, 컴포넌트끼리 만나는 넘겨주기의 경계, 세션이 바뀌는 경계, 읽는 뷰와 고치는 원본 사이의 경계, 채점과 실력 사이의 경계. 비용은 늘리는 데서 나는 게 아니라 **옳기는 데서** 났습니다.

그래서 이 책의 실무적 교훈을 한 문장으로 줄이면 이렇게 됩니다. **에이전트를 키우기 전에, 경계에서 무엇이 새는 지부터 재라.**

남는 질문

이 책이 답하지 못한 것도 적어 둡니다. 도메인 일반성 — 1장의 두 도메인처럼 결론이 갈리는 조건을 미리 아는 방법은 무엇인가. 모델 능력 의존성 — 4장에서 강한 모델은 감쇠가 3 6%로 줄었는데, 어느 수준부터 쪼갬의 거버넌스 비용을 무시해도 되는가. 그리고 측정의 재현 — 8장의 비트 가치를 실제 프로덕션 프롬프트에 적용하는 비용 자체가 아직 참지 않았습니다. 이 세 가지는 2026년 하반기 논문들이 답할 차례일 것입니다.

마지막으로, 이 책의 열 장은 각각 논문 한 편의 초록과 공개된 개요, 그리고 arXiv 전문을 근거로 썼습니다. 논문들은 실험 설계와 통계를 자세히 들여다보면 각각 더 많은 이야기를 합니다. 이 책이 하는 역할은 지도까지라고 생각합니다. 지도에서 걸리는 장이 있으면, 원문으로 가서 직접 확인하세요. 각 장 머리에 링크가 있습니다.

2026년 8월 — 에이전트를 만드는 모든 사람에게.